

Федеральное государственное автономное образовательное
учреждение высшего образования
Национальный исследовательский университет «Высшая школа экономики»
Факультет экономических наук
Образовательная программа «Экономика и экономическая политика»
Образовательный трек «Количественные методы в экономике и финансах»

Микроэконометрика качественных данных

Домашнее задание № 1:

«Модели бинарного выбора»

Домашнее задание студента 1 курса направление 38.04.01 – Экономика

Группа МЭКЭП251

СМИРНОВА Владимира Евгеньевича

Лектор и семинарист:

Доцент: Факультет экономических наук, Департамент прикладной экономики

ПОТАНИН Богдан Станиславович

Москва 2026

Оглавление

ОПИСАНИЕ ЗАДАНИЯ	5
ЗАДАНИЯ	6
Часть 1. Теория и гипотезы.	6
1.1. Выберите независимые переменные	6
1.2. Сформулируйте по крайней мере одну гипотезу о наличии эффекта взаимодействия и еще одну о наличии нелинейного эффекта (например, квадратичного)	9
1.3. Создайте новую бинарную переменную на удовлетворённость игрой, объединив любые две соседние категории переменной «game»	10
Часть 2. Линейно-вероятностная модель.	12
2.1. Оцените линейно-вероятностную модель бинарного выбора	12
2.2. Перечислите основные недостатки линейно-вероятностной модели	13
2.3. Оцените и проинтерпретируйте, независимо от значимости, предельные эффекты на вероятность подписки каждой из используемых вами независимых переменных, предварительно записав формулы, по которым осуществлялся расчет	15
2.4*. Протестируйте гипотезы о значимости коэффициентов с помощью бутстрапа	17
2.5**. Протестируйте гипотезы о значимости коэффициентов используя состоятельную (скорректированную на гетероскедастичность) оценку асимптотической ковариационной матрицы	18
Часть 3. Пробит модель.	20
3.1. Оцените пробит модель бинарного выбора	20
3.2. Проинтерпретируйте оценки коэффициентов для каждой независимой переменной	21
3.3. Оцените вероятность того, что индивид удовлетворен игрой, для индивида с произвольными (например, вашими) характеристиками	22
3.4. Для произвольных непрерывной и бинарной независимых переменных оцените средний предельный эффект на вероятность удовлетворенности игрой, предварительно записав формулы (с подставленными реализациями оценок), по которым осуществлялся расчет	23
3.5. Посчитайте долю верных прогнозов и сопоставьте её с результатом наивного прогноза и линейно-вероятностной модели	24
3.6. На уровне значимости 5% проверьте гипотезу о том, что предельный эффект на вероятность удовлетворенности игрой по произвольной (на ваш выбор) независимой переменной является значимым для индивида с произвольными характеристиками	24
3.7*. Повторите предыдущий пункт для переменной, имеющей взаимодействие	25
3.8**. Воспользуйтесь дельта-методом для того, чтобы вручную рассчитать асимптотическую дисперсию предельного эффекта любой непрерывной переменной, входящей нелинейно	26
Часть 4. Тестирование корректности спецификации пробит модели.	30
4.1. При помощи LM-теста проверьте гипотезу о соблюдении допущения о нормальном распределении случайных ошибок в пробит модели	30

4.2. Предположите, какие переменные могут влиять на дисперсию случайной ошибки	30
4.3. Для модели с гетероскедастичной случайной ошибкой рассчитайте предельный эффект	32
4.4. Для переменной, входящей в линейный индекс нелинейно, при помощи LR теста проверьте гипотезы о том, что:	33
4.5. При помощи LR теста проверьте, можно ли оценивать совместную модель для мужчин и для женщин, либо стоит оценить две различные модели	35
4.6*. При помощи LR теста проверьте, можно ли оценивать совместную модель для людей, проживающих в населенных пунктах различного типа	35
4.7**. Для индивида с произвольными характеристиками оцените асимптотическую дисперсию предельного эффекта любой непрерывной переменной, входящей сразу в оба уравнения, на вероятность удовлетворенности игрой.	36
Часть 5. Логит модель.	38
5.1. Оцените логит модель, предварительно записав максимизируемую функцию правдоподобия и указав, чем логит модель отличается от пробит модели	38
5.2. Проинтерпретируйте значения оценок изменений в отношениях шансов по каждой независимой переменной, входящей линейно.	39
5.3*. Запишите выражения для расчета изменений в отношениях шансов по каждой независимой переменной, входящей нелинейно.	39
5.4**. Для произвольной независимой переменной, входящей нелинейно, проверьте гипотезу о том, что при её изменении на единицу отношение шансов возрастет на 10%.	40
Часть 6. Система бинарных уравнений.	42
6.1. Оцените систему бинарных уравнений, одно из которых описывает вероятность удовлетворенности игрой, а второе – вероятность того, что индивид станет играть за кошек.	42
6.2. Проинтерпретируйте оценки коэффициентов при независимых переменных и коэффициента корреляции между случайными ошибками рассматриваемых уравнений.	44
6.3. При помощи LR теста проверьте, имеется ли необходимость в том, чтобы оценивать оба уравнения совместно.	45
6.4. Для индивида с произвольными характеристиками оцените:	46
6.5*. Для индивида с произвольными характеристиками оцените предельный эффект общей для двух уравнений переменной на вероятность того, что индивид удовлетворен игрой, при условии, что он играл за кошек	47
6.6*. Оцените средний эффект воздействия и средний эффект воздействия на подвергшихся воздействию прохождения игры за кошек на удовлетворенность игрой.	47
6.7**. Замените в рассматриваемой системе бинарную переменную удовлетворенности игрой на порядковую «game»	48
Часть 7. Сравнение моделей	50
7.1. Определите, какая из оцененных вами моделей лучше прогнозирует удовлетворенность игрой.	50

7.2. Выберите лучшую из оцененных вами моделей руководствуясь информационными критериями.	50
7.3**. Руководствуясь информационным критерием Акаике и качеством вневыборочного прогноза (разделите выборку на тестовую и тренировочную части) определите оптимальные маргинальные распределения для случайных ошибок и копулу	51
Часть 8. Модель бинарного выбора со случайными ошибками, имеющими распределение Стьюдента	52
8.1***. Используя воображение придумайте и кратко опишите экономическую задачу, для решения которой необходимо применить модель бинарного выбора.	52
8.2***. Симулируйте процесс генерации данных, соответствующий вашей задаче в логике бинарной модели со случайными ошибками, имеющими распределение Стьюдента	53
8.3***. Оцените параметры вашей модели с использованием бинарной модели со случайными ошибками, имеющими распределение Стьюдента с df степенями свободы.	53
8.4***. Напишите функцию, позволяющую рассчитывать предельный эффект на вероятность по произвольной непрерывной переменной в отношении индивида с произвольными характеристиками: для простоты переменными, входящими нелинейно, можно пренебречь	53
8.5***. Симулируйте процесс генерации данных таким образом, чтобы дисперсия случайной ошибки зависела по крайней мере от двух независимых переменных, одна из которых не входит в основное уравнение	54
8.6***. Повторите предыдущие пункты, предполагая, что степени свободы df не фиксированы, а являются оцениваемым параметром	55

ОПИСАНИЕ ЗАДАНИЯ

Игровая студия разработала новый градостроительный симулятор про кошек и собак. Игроки были приглашены на закрытое бета-тестирование с целью описать свои **впечатления** от однократного прохождения половины игры. Вас наняли для того, чтобы проанализировать, как различные **социо-демографические факторы** влияют на **удовлетворенность игроков** от прохождения разработанной игры. Также, вас отдельно попросили тщательно проанализировать, как на удовлетворенность от игры влияет **выбор игрока проходить игру за кошек или за собак**.

В качестве выборки используйте данные «homework.rds». Чтобы считать соответствующие данные в R необходимо воспользоваться функцией «readRDS».

Данные содержат информацию о следующих индивидуальных характеристиках:

- game – степень удовлетворенности игрой (0 – низкая, 1 – средняя, 2 – высокая)
- choice – за кого проходил игру игрок (1 – кошки, 0 – собаки)
- income – доход в рублях
- age – возраст в годах
- hours – среднее количество игровых часов в неделю
- health – здоровье (bad – плохое, medium – среднее, good – хорошее)
- marriage – семейный статус (1 – в браке, 0 – холостой)
- chl – факт наличия детей (1 – есть, 0 – нет)
- male – пол (1 – мужской, 0 – женский)
- residence – место проживания (capital – столица региона, city – город, village – деревня)
- cat – факт наличия кота (1 – есть кот, 0 – нет кота)
- dog – факт наличия собаки (1 – есть собака, 0 – нет собаки)
- bugs – число багов, в которыми пользователь столкнулся на протяжении игры
- price – стоимость компьютера игрока в рублях
- design – какой из двух видов дизайна был случайным образом предложен игроку в меню, в котором осуществлялся выбор в пользу прохождения игры за кошек или за собак (1 – первый дизайн, 0 – второй дизайн)
- educ – уровень образования (basic – среднее, vocational – среднее специальное, higher – высшее, phd – кандидат наук)

ЗАДАНИЯ

Часть 1. Теория и гипотезы.

1.1. Выберите независимые переменные

Кратко теоретически обоснуйте выбор каждой из них: не обязательно со ссылками на литературу, достаточно здравого смысла. Укажите и кратко обоснуйте предполагаемые направления эффектов. При этом вам понадобится как минимум одна непрерывная переменная (например, возраст или доход) и одна дамми переменная (например, половая принадлежность или брак). Не рекомендуется брать больше трех различных независимых переменных, не считая их нелинейных преобразований: квадрат, логарифм, перемножение с целью получения переменной взаимодействия и т. д.

Ответ:

Предоставлю ниже сводную таблицу, которая покрывает данный и следующий пункты. При необходимости далее предоставлю дополнительные комментарии касательно проделанных манипуляций.

Отмечу, что была ещё идея использовать $\text{choice} * \text{male}$, так как, возможно, могут иметь место гендерные различия в предпочтениях (например, девушки могут чаще выбирать кошек, а мужчины – собак). Но вариант $\text{choice} * \text{age}$ предполагается как более широкой направленности и охватывает больше потенциальных гипотез касательно формата взаимодействия переменных в данных.

Переменная	Формат включения в спецификацию	Причина включения в спецификацию	Предполагаемые направления эффекта
game	На основе переменной game создаётся бинарная переменная satisfied, которую мы и рассматриваем как целевую для большинства частей домашнего задания	Зависимая переменная. Исходная переменная game отражает степень удовлетворённости игрой: • 0 – низкая, • 1 – средняя, • 2 – высокая. Для моделей бинарного выбора она преобразуется в бинарную переменную удовлетворённости satisfied: • satisfied = 1, если игрок имеет среднюю или высокую удовлетворённость игрой; • satisfied = 0, если игрок имеет низкую	Для целевой переменной столбец не имеет смысла

		удовлетворённость игрой.	
age	Непрерывная переменная, включается в модель в исходном виде	Возраст может влиять на восприятие игры, игровые предпочтения и ожидания от градостроительного симулятора. Предполагается, что игроки разного возраста могут по-разному оценивать игровой процесс.	Положительный эффект (+) Можно предположить, что с возрастом игроки спокойнее и внимательнее воспринимают игровой процесс и поэтому могут получать больше удовлетворения от игры.
male	Бинарная переменная: • male = 1 для мужчин, • male = 0 для женщин	Пол может быть связан с различиями в игровых предпочтениях, отношении к жанру симулятора и восприятию игрового опыта.	Неоднозначное направление эффекта (без конкретной эмпирики сложно предположить). Пол может быть связан с различиями в игровых предпочтениях, однако без предварительного анализа данных нельзя уверенно утверждать, что мужчины будут более или менее удовлетворены игрой, чем женщины.
choice	Бинарная переменная: • choice = 1, если игрок проходил игру за кошек; • choice = 0, если игрок проходил игру за собак	Мы хотим проанализировать, влияет ли выбор прохождения игры за кошек или собак на удовлетворённость игрока (может быть, мы заметим, что при выборе игры за собак или за кошек имеют место быть специфичные для типа животного особенности поведения пользователей)	Неоднозначное направление эффекта (без конкретной эмпирики сложно предположить). Заранее нельзя однозначно сказать, будет ли прохождение игры за кошек

			повышать или снижать удовлетворённость относительно прохождения за собак.
age^2 (age^2)	Квадрат возраста	Переменная включается для проверки гипотезы о нелинейном влиянии возраста. Например, удовлетворённость может расти с возрастом до некоторого уровня, а затем снижаться, либо наоборот.	Отрицательное направление эффекта (-) Положительное влияние возраста может ослабевать при больших значениях возраста. Например, после некоторого возраста игрокам может быть сложнее или менее интересно проходить игру, поэтому удовлетворённость может начать снижаться.
choice * age	Переменная взаимодействия выбора персонажа-животного и возраста игрока	Включается для проверки гипотезы о том, что эффект выбора игры за кошек по сравнению с игрой за собак может зависеть от возраста игрока. Например, молодые и более взрослые игроки могут по-разному воспринимать прохождение за кошек.	Неоднозначное направление эффекта (без конкретной эмпирики сложно предположить). Взаимодействие показывает, меняется ли эффект выбора игры за кошек с возрастом. Как уже было указано в столбце слева, можно предположить, что разные возрастные группы по-разному воспринимают игру за кошек относительно игры за собак, но

			направление этого различия заранее не очевидно.
--	--	--	---

Таблица 1 Кодбук для переменных

1.2. Сформулируйте по крайней мере одну гипотезу о наличии эффекта взаимодействия и еще одну о наличии нелинейного эффекта (например, квадратичного)

Теоретически обоснуйте выдвигаемые вами гипотезы. Включите соответствующие переменные в вашу модель. При этом переменная, входящая нелинейно, должна иметь и линейную часть, например,

$$\beta_1 X_1 + \beta_2 X_1^2$$

Ответ:

Итоговая спецификация:

$$satisfied_i = \beta_0 + \beta_1 choice_i + \beta_2 age_i + \beta_3 age_i^2 + \beta_4 male_i + \beta_5 (choice_i \cdot age_i) + \varepsilon_i, \\ i = 1, \dots, n$$

где:

- i – индекс игрока, то есть номер наблюдения в выборке (давайте здесь сразу договоримся, что данное обозначение актуально для всех последующих индексов i в работе);
- n – общее число игроков в выборке;
- $satisfied_i$ – бинарная переменная удовлетворённости i -го игрока;
- $choice_i$ – переменная выбора стороны прохождения для i -го игрока: 1 – кошки, 0 – собаки;
- age_i – возраст i -го игрока;
- age_i^2 – квадрат возраста i -го игрока;
- $male_i$ – пол i -го игрока: 1 – мужчина, 0 – женщина;
- $choice_i \cdot age_i$ – переменная взаимодействия выбора стороны прохождения и возраста для i -го игрока;
- $\beta_0, \beta_1, \dots, \beta_5$ – оцениваемые параметры модели;
- ε_i – случайная ошибка для i -го игрока, отражающая ненаблюдаемые факторы, влияющие на удовлетворённость игрой.

Идейно гипотезы сформулированы в таблице выше. Несколько более формальная запись:

Гипотеза о нелинейном эффекте возраста

Идейно можно предположить, что возраст влияет на удовлетворённость игрой нелинейно. С одной стороны, более взрослые игроки могут спокойнее и внимательнее воспринимать градостроительный симулятор, поэтому вероятность удовлетворённости может расти с возрастом. С другой стороны, после некоторого возраста игрокам может быть сложнее или менее интересно проходить игру, поэтому положительный эффект возраста может ослабевать или становиться отрицательным. Именно для проверки этой идеи в модель включаются переменные age_i и age_i^2 :

$$H_0: \beta_3 = 0$$

$$H_1: \beta_3 \neq 0$$

где β_3 – коэффициент при переменной age_i^2 (заметим, что коэффициент может быть под другим номером в оцениваемой модели, данный пример и примеры далее условные, важна сама суть). Нулевая гипотеза означает отсутствие квадратичного, то есть нелинейного, эффекта возраста. Альтернативная гипотеза означает, что влияние возраста на вероятность удовлетворённости игрой является нелинейным.

Так как содержательно предполагается, что положительный эффект возраста может ослабевать при больших значениях возраста, ожидаемый знак коэффициента при age_i^2 – отрицательный:

$$\beta_3 < 0$$

Однако для статистической проверки можно (и даже лучше!) использовать двустороннюю альтернативу $H_1: \beta_3 \neq 0$, потому что заранее нельзя полностью исключить другую форму нелинейности.

Гипотеза об эффекте взаимодействия выбора стороны прохождения и возраста

Также можно предположить, что эффект прохождения игры за кошек по сравнению с прохождением за собак зависит от возраста игрока. Например, молодые и более взрослые игроки могут по-разному воспринимать игровые механики, визуальный стиль или сюжетные элементы, связанные с кошками и собаками. Поэтому один и тот же выбор стороны прохождения может по-разному влиять на удовлетворённость у игроков разных возрастов. И снова же, именно для проверки этой идеи в модель включается переменная взаимодействия $choice_i \cdot age_i$.

$$H_0: \beta_5 = 0$$

$$H_1: \beta_5 \neq 0$$

где β_5 – коэффициент при переменной взаимодействия $choice_i \cdot age_i$. Нулевая гипотеза означает, что влияние выбора прохождения игры за кошек относительно собак не зависит от возраста игрока. Альтернативная гипотеза означает, что эффект выбора прохождения за кошек меняется в зависимости от возраста.

1.3. Создайте новую бинарную переменную на удовлетворённость игрой, объединив любые две соседние категории переменной «game»

Данная переменная выступает в качестве зависимой при оценивании моделей бинарного выбора. Для краткости далее в условии будем считать, что 1 значение соответствует тому, что индивид удовлетворен игрой, а 0 тому, что он не удовлетворен. Приведите и далее в тексте вашей работы используйте более подробную содержательную интерпретацию 1 и 0 значений созданной вами переменной, учитывая то, что к одному из них относятся сразу две категории.

Ответ:

Созданная переменная расшифровывается в таблице выше. Продублирую здесь ещё раз:

Для моделей бинарного выбора она преобразуется в бинарную переменную удовлетворённости satisfied:

- satisfied = 1, если игрок имеет среднюю или высокую удовлетворённость игрой;
- satisfied = 0, если игрок имеет низкую удовлетворённость игрой.

Здесь имеет смысл обратить внимание, что переменная game имеет несколько классов. Так как решается задача бинарной классификации (хотя, в контексте эконометрики,

скорее, корректно назвать её задачей бинарного выбора), то переменная кодируется в формат 0 или 1.

Каким именно образом это можно сделать – решает ЛПР; однако отмечу, что, например, мой вариант кодировки опирается на мои предположения (например, что однозначно неудовлетворенными можно считать тех, кто имеет именно низкую удовлетворенность игрой, а средняя удовлетворенность это всё же категория «удовлетворенных», а не наоборот) и игнорирует получившийся дисбаланс классов. Если же оперировать бинарной переменной, где средняя неудовлетворённость относится к блоку низкой удовлетворенности, то баланс классов соблюдается. В нашей задаче всё же считаю, что это не главный критерий для итогового качества решения, а некоторая бизнес-логика лучше просматривается именно в первом варианте.

Так, подсвечу, что я объединяю категории 1 и 2, поскольку средняя и высокая удовлетворённость означают, что игровой опыт не был негативным. Категория 0 соответствует низкой удовлетворённости, то есть явной неудовлетворённости игрой. Поэтому переменная *satisfied* принимает значение 1 для игроков со средней или высокой удовлетворённостью и 0 для игроков с низкой удовлетворённостью.

Часть 2. Линейно-вероятностная модель.

2.1. Оцените линейно-вероятностную модель бинарного выбора

Предварительно запишите регрессионное уравнение. Укажите оцениваемые параметры и метод получения оценок. Результат представьте в форме таблицы (можно, например, использовать выдачу из stata, R или python).

Ответ:

Сформулированная спецификация:

$$satisfied_i = \beta_0 + \beta_1 choice_i + \beta_2 age_i + \beta_3 age_i^2 + \beta_4 male_i + \beta_5 (choice_i \cdot age_i) + \varepsilon_i, \\ i = 1, \dots, n$$

где:

- i – индекс игрока, то есть номер наблюдения в выборке;
- n – общее число игроков в выборке;
- $satisfied_i$ – бинарная переменная удовлетворённости i -го игрока;
- $choice_i$ – переменная выбора стороны прохождения для i -го игрока: 1 – кошки, 0 – собаки;
- age_i – возраст i -го игрока;
- age_i^2 – квадрат возраста i -го игрока;
- $male_i$ – пол i -го игрока: 1 – мужчина, 0 – женщина;
- $choice_i \cdot age_i$ – переменная взаимодействия выбора стороны прохождения и возраста для i -го игрока;
- $\beta_0, \beta_1, \dots, \beta_5$ – оцениваемые параметры модели;
- ε_i – случайная ошибка для i -го игрока, отражающая ненаблюдаемые факторы, влияющие на удовлетворённость игрой.

Параметры модели оцениваются с помощью метода наименьших квадратов (МНК). В линейно-вероятностной модели предполагается, что условная вероятность удовлетворённости игрока задаётся линейной функцией регрессоров:

$$satisfied_i = x_i \beta + \varepsilon_i$$

Результат указан ниже:

Dependent variable: satisfied				
Residuals				
Min	1Q	Median	3Q	Max
-0.99108	0.00877	0.07468	0.14546	0.59822
Coefficients				
Переменная	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.3119***	0.04163	7.493	7.91e-14
choice	0.5117***	0.02744	18.650	< 2e-16
age	0.009614***	0.002240	4.291	1.81e-05
$I(age^2)$	-0.00005572*	0.00002773	-2.009	0.0446
male	-0.06512***	0.01068	-6.099	1.15e-09
choice:age	-0.003502***	0.0007308	-4.791	1.70e-06
Качество модели				
Тип модели	Linear model			
Формула	satisfied ~ choice + age + $I(age^2)$ + male + choice:age			
Residual standard error	0.3763			
Degrees of freedom	4994			
R^2	0.2367			
Adjusted R^2	0.2360			
F-statistic	309.8 (df = 5; 4994)			
p-value (F-test)	< 2.2e-16			
Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1				

Таблица 2 Результаты оценки линейной модели удовлетворенности

2.2. Перечислите основные недостатки линейно-вероятностной модели

Напишите, можно ли интерпретировать оценки коэффициентов, их значимость (с использованием обычной оценки ковариационной матрицы), коэффициент детерминации и F-статистику? Если да, то приведите интерпретацию, а если нет, то объясните (без непосредственной реализации), почему она в данном случае невозможна и предложите альтернативный способ оценки качества модели.

Ответ:

Итак, линейно-вероятностная модель имеет несколько существенных недостатков.

Во-первых, модель задаёт вероятность как линейную функцию регрессоров:

$$P(satisfied_i = 1 | x_i) = x_i\beta.$$

Однако вероятность должна лежать в интервале $[0; 1]$, а линейная модель может давать предсказанные значения меньше 0 или больше 1. Поэтому некоторые прогнозы невозможно интерпретировать как вероятности.

Во-вторых, в линейно-вероятностной модели возникает гетероскедастичность. Так как $satisfied_i$ – бинарная переменная, условная дисперсия ошибки равна:

$$Var(\varepsilon_i | x_i) = x_i\beta(1 - x_i\beta).$$

Следовательно, дисперсия ошибки зависит от регрессоров. Из-за этого МНК-оценки остаются состоятельными при корректной спецификации условного среднего, но обычные стандартные ошибки, t-статистики и p-value могут быть некорректными.

В-третьих, модель предполагает линейную зависимость вероятности от факторов. На практике влияние переменных на вероятность может быть нелинейным.

Интерпретация коэффициентов

Оценки коэффициентов интерпретировать можно; они показывают изменение вероятности события $satisfied_i = 1$ при изменении соответствующей переменной на единицу при прочих равных.

Однако из-за наличия взаимодействия эффект переменной $choice_i$ зависит от возраста:

$$\frac{\partial P(satisfied_i = 1 | x_i)}{\partial choice_i} = \hat{\beta}_{cho} + \hat{\beta}_{choi : age} age_i.$$

По оценкам из таблицы 2:

$$\frac{\partial P(satisfied_i = 1 | x_i)}{\partial choice_i} = 0.5117 - 0.003502 age_i.$$

То есть прохождение игры за кошек повышает вероятность удовлетворённости по сравнению с прохождением за собак, но этот положительный эффект уменьшается с возрастом.

Коэффициент при $male_i$ равен -0.06512 , то есть мужчины при прочих равных имеют вероятность быть удовлетворёнными игрой примерно на 6.5 процентного пункта ниже, чем женщины.

Интерпретация значимости

Значимость коэффициентов, рассчитанную по обычной ковариационной матрице, корректно интерпретировать нельзя, потому что в модели присутствует гетероскедастичность. Поэтому обычные t-статистики и p-value можно рассматривать только как предварительные. Для корректной проверки значимости нужно использовать бутстрап или робастную к гетероскедастичности оценку ковариационной матрицы.

Интерпретация F-статистики

Обычную F-статистику также нельзя корректно интерпретировать из-за гетероскедастичности. Формально она проверяет гипотезу:

$$H_0: \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0.$$

В таблице 2:

$$F = 309.8,$$

p-value меньше 0.001. Формально это указывает на совместную значимость регрессоров, но из-за гетероскедастичности такой вывод требует отдельного обсуждения (полагаю, имеет смысл подумать над этим отдельно). Для корректной проверки совместной значимости следует использовать некоторый робастный тест или же бутстрап.

Недостатки через призму машинного обучения

Здесь продемонстрирую несколько другой подход к разъяснению проблематичности линейно-вероятностной модели без контекста рассматриваемой задачи.

Вспомним, что такое Misclassification loss:

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i] = \frac{1}{l} \sum_{i=1}^l [\text{sign}\langle w, x_i \rangle \neq y_i] \rightarrow \min_w$$

функционал является дискретным относительно весов, и поэтому искать его минимум с помощью градиентных методов мы не сможем. Попытаемся свести задачу к минимизации гладкого функционала¹.

¹ Учебник по машинному обучению. Глава 2.2 Линейные модели [Электронный ресурс] URL: <https://education.yandex.ru/handbook/ml/article/linear-models> (дата обращения 15.05.2026)

После ряда преобразований запишем отступ (будем считать его кусочно-заданной функцией). Итак, величина $M = y_i \langle w, x_i \rangle$ называется отступом (margin) классификатора. Такая функция потерь называется misclassification loss.

Абсолютная величина M характеризует степень уверенности классификатора в своём ответе.

Вспомним, что кусочно-заданную функцию от отступа можно аппроксимировать некоторой непрерывной функцией сверху – используем т. н. «верхние оценки».

Посмотрим, что произойдет с задачей классификации при решении её как задачи регрессии с квадратичной ошибкой в качестве функционала потерь (то есть, когда «верхняя» оценка для «ступеньки» из себя представляет MSE):

$$\begin{aligned} y^{(i)} &\in \{+1, -1\} \subset \mathbb{R} \\ L_{\text{MSE}} &= (y^{(i)} - x^{(i)\top} w)^2 = \frac{\left((y^{(i)})^2 - y^{(i)} \cdot x^{(i)\top} w\right)^2}{(y^{(i)})^2} \\ &= (1 - y^{(i)} x^{(i)\top} w)^2 = (1 - M^{(i)})^2 \end{aligned}$$

Здесь заметим минус. При увеличении положительного отступа ошибка растёт квадратично, т. е. мы штрафует модель, если объект находится глубоко в своем классе (если модель уверена в классификации объекта).

2.3. Оцените и проинтерпретируйте, независимо от значимости, предельные эффекты на вероятность подписки каждой из используемых вами независимых переменных, предварительно записав формулы, по которым осуществлялся расчет

Результат представьте в форме таблицы, где для переменных, входящих нелинейно, рассчитан средний предельный эффект. Также, для этих переменных должно быть указано, при каких значениях независимой переменной их предельный эффект является положительным, а при каких – отрицательным.

Ответ:

Оценённая линейно-вероятностная модель имеет вид:

$$\begin{aligned} \hat{P}(\text{satisfied}_i = 1 \mid X_i) \\ = 0.3119 + 0.5117\text{choice}_i + 0.009614\text{age}_i - 0.00005572\text{age}_i^2 \\ - 0.06512\text{male}_i - 0.003502(\text{choice}_i \cdot \text{age}_i). \end{aligned}$$

Поскольку age входит в модель линейно, квадратично и во взаимодействии с choice, его предельный эффект рассчитывается как:

$$ME_{\text{age},i} = \hat{\beta}_{\text{age}} + 2\hat{\beta}_{\text{age}^2}\text{age}_i + \hat{\beta}_{\text{choice}:\text{age}}\text{choice}_i.$$

После подстановки оценок:

$$ME_{\text{age},i} = 0.009614 - 0.00011144\text{age}_i - 0.003502\text{choice}_i.$$

Для бинарной переменной choice рассчитывается дискретный эффект перехода от игры за собак к игре за кошек:

$$ME_{\text{choice},i} = \hat{\beta}_{\text{choice}} + \hat{\beta}_{\text{choice}:\text{age}}\text{age}_i = 0.5117 - 0.003502\text{age}_i.$$

Для бинарной переменной male эффект равен коэффициенту при данной переменной:

$$ME_{male} = \hat{\beta}_{male} = -0.0651.$$

Переменная	Тип эффекта	Формула	Значение	Интерпретация
choice	Средний дискретный эффект	$\hat{\beta}_{choice} + \hat{\beta}_{choice:age}age_i$	0.3897	Игра за кошек вместо игры за собак в среднем увеличивает вероятность удовлетворённости на 38.97 п.п.
age	Средний предельный эффект	$\hat{\beta}_{age} + 2\hat{\beta}_{age^2}age_i + \hat{\beta}_{choice:age}choice_i$	0.0037	Увеличение возраста на 1 год в среднем повышает вероятность удовлетворённости на 0.37 п.п.
male	Дискретный эффект	$\hat{\beta}_{male}$	-0.0651	Мужчины при прочих равных имеют вероятность удовлетворённости примерно на 6.51 п.п. ниже , чем женщины.

Note: Значения эффектов интерпретируются в процентных пунктах, поскольку зависимая переменная является бинарной, а модель оценена как линейная вероятностная модель.

Таблица 3 Предельные эффекты в линейно-вероятностной модели

Для переменных, входящих нелинейно или через взаимодействие, знак эффекта зависит от значений других переменных.

Для возраста при $choice_i = 0$, то есть для игроков за собак:

$$ME_{age,i} = 0.009614 - 0.00011144age_i.$$

Эффект положителен при:

$$age_i < 86.27,$$

и отрицателен при:

$$age_i > 86.27.$$

Для возраста при $choice_i = 1$, то есть для игроков за кошек:

$$ME_{age,i} = 0.006112 - 0.00011144age_i.$$

Эффект положителен при:

$$age_i < 54.85,$$

и отрицателен при:

$$age_i > 54.85.$$

Для переменной choice:

$$ME_{choice,i} = 0.5117 - 0.003502age_i.$$

Эффект положителен при:

$$age_i < 146.15,$$

и отрицателен при:

$$age_i > 146.15.$$

Поскольку возраст больше 146 лет практически невозможен в выборке, можно считать, что прохождение игры за кошек для наблюдений из выборки положительно связано с вероятностью удовлетворённости, но этот положительный эффект уменьшается с возрастом.

2.4*. Протестируйте гипотезы о значимости коэффициентов с помощью бутстрапа

Результат представьте в форме таблицы. При этом предварительно (словами или самостоятельно нарисованной схемой) опишите алгоритм, который вы использовали для построения бутстрапированных доверительных интервалов.

Ответ:

Для каждого коэффициента (j подразумевает здесь его номер) рассматривается нулевая гипотеза:

$$H_0: \beta_j = 0$$

против альтернативной гипотезы:

$$H_1: \beta_j \neq 0.$$

Проверка проводится на основе бутстап-95%-х доверительных интервалов. Если ноль не попадает в доверительный интервал, то коэффициент считается статистически значимым на 5%-м уровне значимости.

Алгоритм построения бутстрапированных доверительных интервалов был следующим.

Сначала из исходной выборки объёма n случайным образом отбиралась новая выборка того же объёма n с возвращением. Затем на полученной бутстрап-выборке заново оценивалась линейно-вероятностная модель:

$$satisfied_i = \beta_0 + \beta_1 choice_i + \beta_2 age_i + \beta_3 age_i^2 + \beta_4 male_i + \beta_5 (choice_i \cdot age_i) + u_i.$$

Полученные оценки коэффициентов сохранялись. Данная процедура повторялась 1000 раз. После этого для каждого коэффициента были рассчитаны бутстап-стандартная ошибка и 95%-й доверительный интервал как 2.5%-й и 97.5%-й квантили бутстрап-распределения оценок:

$$CI_{0.95}^{boot} = [q_{0.025}(\hat{\beta}_j^{boot}), q_{0.975}(\hat{\beta}_j^{boot})].$$

По результатам бутстрапа ноль не попадает в 95%-е доверительные интервалы для всех коэффициентов модели. Следовательно, на 5%-м уровне значимости нулевая гипотеза $H_0: \beta_j = 0$ отвергается для всех коэффициентов.

Таким образом, переменные $choice$, age , age^2 , $male$ и $choice:age$ (знак произведения, который нужно использовать в R для спецификации; в общем, речь о перекрестной переменной $choice * age$) являются статистически значимыми по результатам проведения бутстрапа. Прохождение игры за кошек положительно связано с вероятностью удовлетворённости, возраст имеет нелинейный эффект, мужчины в среднем имеют более низкую вероятность удовлетворённости, а отрицательный коэффициент при взаимодействии $choice:age$ показывает, что положительный эффект прохождения игры за кошек уменьшается с возрастом.

Результаты представлены в таблице 4.

Переменная	Оценка	Бутстрап SE	CI 2.5%	CI 97.5%	Значима на 5%
(Intercept)	0.3119	0.0437	0.2234	0.3969	Да
choice	0.5117	0.0300	0.4560	0.5764	Да
age	0.0096	0.0022	0.0052	0.0141	Да
$I(age^2)$	-0.0001	0.0000	-0.0001	0.0000	Да
male	-0.0651	0.0109	-0.0856	-0.0443	Да
choice:age	-0.0035	0.0008	-0.0050	-0.0019	Да

Note: Приведены бутстрап-стандартные ошибки и 95%-е доверительные интервалы.

Таблица 4 Бутстрап-оценки стандартных ошибок и доверительных интервалов

2.5**. Протестируйте гипотезы о значимости коэффициентов используя состоятельную (скорректированную на гетероскедастичность) оценку асимптотической ковариационной матрицы

Результат представьте в форме таблицы (в том числе с p-value), предварительно выписав используемую для расчетов формулу.

Ответ:

Состоятельная оценка асимптотической ковариационной матрицы, скорректированная на гетероскедастичность:

$$As.Cov(\hat{\beta}) = (X^T X)^{-1} \left(\sum_{i=1}^n \hat{p}_i (1 - \hat{p}_i) x_i^T x_i \right) (X^T X)^{-1},$$

где X – матрица регрессоров, x_i – вектор регрессоров для i -го наблюдения, $\hat{p}_i = x_i^T \hat{\beta}$ – предсказанная вероятность удовлетворённости игрой.

Для каждого коэффициента проверяется гипотеза:

$$H_0: \beta_j = 0$$

против альтернативной гипотезы:

$$H_1: \beta_j \neq 0.$$

Тестовая статистика рассчитывается по формуле:

$$t_j = \frac{\hat{\beta}_j}{SE_{robust}(\hat{\beta}_j)}.$$

При верной нулевой гипотезе данная статистика имеет асимптотическое стандартное нормальное распределение:

$$t_j \xrightarrow{a} N(0,1).$$

Результаты проверки представлены в таблице 4.

По результатам проверки все коэффициенты являются статистически значимыми на 5%-м уровне значимости, поскольку для всех переменных p-value меньше 0.05.

Следовательно, нулевая гипотеза $H_0: \beta_j = 0$ отвергается для коэффициентов при choice, age, $I(age^2)$, male и choice:age. Это означает, что даже после коррекции стандартных ошибок на гетероскедастичность выбранные переменные оказывают статистически значимое влияние на вероятность удовлетворённости игрой.

<i>Dependent variable:</i>				
satisfied				
Коэффициенты (robust SE)				
Переменная	Estimate	Robust SE	t value	Pr(> t)
(Intercept)	0.3119***	0.0445	7.0081	0.000
choice	0.5117***	0.0300	17.0431	0.000
age	0.0096***	0.0022	4.2965	0.000
$I(age^2)$	-0.0001*	0.0000	-2.0753	0.038
male	-0.0651***	0.0107	-6.0809	0.000
choice:age	-0.0035***	0.0008	-4.4592	0.000

Note: Приведены оценки коэффициентов с робастными стандартными ошибками.
Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 5 Результаты оценки модели с робастными стандартными ошибками

Часть 3. Пробит модель.

3.1. Оцените пробит модель бинарного выбора

Предварительно запишите максимизируемую функцию правдоподобия (поясните все используемые обозначения), указав оцениваемые параметры и метод получения оценок, а также их основные свойства. Результат представьте в форме таблицы (можно, например, использовать выдачу из stata, R или python).

Ответ:

В пробит-модели условная вероятность события задаётся через функцию распределения стандартного нормального распределения:

$$P(satisfied_i = 1 | x_i) = \Phi(x_i\beta),$$

где $\Phi(\cdot)$ – функция распределения стандартного нормального распределения.

В работе используется следующий линейный индекс:

$$x_i\beta = \beta_0 + \beta_1 choice_i + \beta_2 age_i + \beta_3 age_i^2 + \beta_4 male_i + \beta_5(choice_i \cdot age_i).$$

Тогда:

$$\begin{aligned} P(satisfied_i = 1 | x_i) \\ = \Phi(\beta_0 + \beta_1 choice_i + \beta_2 age_i + \beta_3 age_i^2 + \beta_4 male_i + \beta_5(choice_i \cdot age_i)), \end{aligned}$$

а

$$P(satisfied_i = 0 | x_i) = 1 - \Phi(x_i\beta).$$

Функция правдоподобия имеет вид:

$$L(\beta; y | X) = \prod_{i=1}^n \Phi(x_i\beta)^{satisfied_i} (1 - \Phi(x_i\beta))^{1-satisfied_i}.$$

Максимизируемый логарифм функции правдоподобия:

$$\ln L(\beta; y | X) = \sum_{i=1}^n [satisfied_i \ln \Phi(x_i\beta) + (1 - satisfied_i) \ln (1 - \Phi(x_i\beta))].$$

где i – индекс игрока, n – число наблюдений, $satisfied_i$ – бинарная переменная удовлетворённости игрока, x_i – вектор регрессоров, β – вектор оцениваемых параметров, $x_i\beta$ – линейный индекс модели.

Оцениваются параметры:

$$\beta = (\beta_0, \beta_1, \beta_2, \beta_3, \beta_4, \beta_5)'.$$

Dependent variable: satisfied				
Coefficients				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.4708**	0.1674	-2.812	0.00493
choice	1.3880***	0.1137	12.204	< 2e-16
age	0.02753**	0.009343	2.946	0.00322
$I(age^2)$	-0.0001796	0.0001172	-1.532	0.12563
male	-0.2715***	0.04378	-6.202	5.57e-10
choice:age	-0.00005578	0.003189	-0.017	0.98604
Качество модели				
Тип модели	Probit model			
Семейство распределения	Binomial			
Link function	Probit			
Формула	satisfied ~ choice + age + $I(age^2)$ + male + choice:age			
Null deviance	5574.5 (df = 4999)			
Residual deviance	4333.5 (df = 4994)			
AIC	4345.5			
Fisher scoring iterations	5			
Signif. codes: *** 0.001; ** 0.01; * 0.05; . 0.1; 1				

Таблица 6 Результаты оценки probit-модели

3.2. Проинтерпретируйте оценки коэффициентов для каждой независимой переменной

Поясните, как полученные результаты соотносятся с высказанными вами ранее предположениями.

Ответ:

В пробит-модели коэффициенты показывают не непосредственное изменение вероятности, а направление влияния переменной на латентную склонность игрока быть удовлетворённым игрой. Если коэффициент положительный, то рост переменной увеличивает вероятность $satisfied_i = 1$; если отрицательный – снижает её. Точную величину влияния на вероятность следует интерпретировать через предельные эффекты.

По результатам таблицы 5 коэффициент при переменной *choice* положителен и статистически значим на уровне 1%:

$$\hat{\beta}_{choice} = 1.3880.$$

Это означает, что прохождение игры за кошек связано с более высокой вероятностью удовлетворённости игрой по сравнению с прохождением за собак. Ранее направление эффекта *choice* было обозначено как неоднозначное, поэтому результат показывает, что в данных эффект оказался положительным.

Коэффициент при переменной *age* положителен и статистически значим на уровне 1%:

$$\hat{\beta}_{age} = 0.02753.$$

Это означает, что при увеличении возраста латентная склонность к удовлетворённости игрой возрастает. Этот результат соответствует первоначальному предположению о положительном влиянии возраста: более взрослые игроки могут спокойнее и внимательнее воспринимать игровой процесс.

Коэффициент при age^2 отрицателен:

$$\hat{\beta}_{age^2} = -0.0001796,$$

однако он статистически незначим на стандартных уровнях значимости, так как $p\text{-value} = 0.12563$. Знак коэффициента соответствует высказанной ранее гипотезе о том, что положительный эффект возраста может ослабевать при больших значениях возраста.

Однако статистически значимых оснований утверждать наличие квадратичного эффекта возраста в пробит-модели нет.

Коэффициент при переменной *male* отрицателен и статистически значим на уровне 1%:

$$\hat{\beta}_{male} = -0.2715.$$

Это означает, что при прочих равных мужчины имеют более низкую склонность быть удовлетворёнными игрой, чем женщины. Ранее эффект пола был обозначен как неоднозначный, поэтому результат показывает, что в данных связь оказалась отрицательной.

Коэффициент при переменной взаимодействия *choice* · *age* практически равен нулю:

$$\hat{\beta}_{choice \cdot age} = -0.00005578,$$

и статистически незначим, так как *p*-value = 0.98604. Следовательно, нет статистических оснований утверждать, что эффект прохождения игры за кошек по сравнению с прохождением за собак зависит от возраста игрока. Это не подтверждает ранее выдвинутую гипотезу о наличии эффекта взаимодействия между выбором стороны прохождения и возрастом.

Таким образом, результаты пробит-модели подтверждают положительное влияние выбора игры за кошек и возраста, а также отрицательное влияние мужского пола на вероятность удовлетворённости игрой. При этом гипотезы о квадратичном эффекте возраста и о взаимодействии выбора стороны прохождения с возрастом в пробит-модели статистически не подтверждаются.

3.3. Оцените вероятность того, что индивид удовлетворен игрой, для индивида с произвольными (например, вашими) характеристиками

Запишите формулу, по которой осуществлялся расчет (подставьте в нее полученные реализации оценок).

Ответ:

Предлагаю здесь прописать характеристики произвольного индивида Владимира. Владимир будет произвольным индивидом здесь и в прочих пунктах работы далее, так что имеет смысл зафиксировать данные характеристики.

Характеристика	Значение
choice	1, проходил игру за кошек
age	22 года
male	1, мужчина
choice * age	1 * 22 = 22

Таблица 7 Характеристики произвольного индивида Владимира

Линейный индекс равен:

$$x_i \hat{\beta} = \hat{\beta}_0 + \hat{\beta}_1 choice_i + \hat{\beta}_2 age_i + \hat{\beta}_3 age_i^2 + \hat{\beta}_4 male_i + \hat{\beta}_5 (choice_i \cdot age_i).$$

Подставим оценки из таблицы 5:

$$x_i \hat{\beta} = -0.4708 + 1.3880 \cdot 1 + 0.02753 \cdot 22 - 0.0001796 \cdot 22^2 - 0.2715 \cdot 1 - 0.00005578 \cdot 22.$$

$$x_i \hat{\beta} = -0.4708 + 1.3880 + 0.60566 - 0.08693 - 0.2715 - 0.00123.$$

$$x_i \hat{\beta} \approx 1.1632.$$

Следовательно:

$$P(satisfied_i = 1 | x_i) = \Phi(1.1632) \approx 0.8776.$$

Таким образом, для Владимира, мужчины 22 лет, проходившего игру за кошек, оценённая вероятность быть удовлетворённым игрой составляет примерно:

87.8%.

3.4. Для произвольных непрерывной и бинарной независимых переменных оцените средний предельный эффект на вероятность удовлетворенности игрой, предварительно записав формулы (с подставленными реализациями оценок), по которым осуществлялся расчет

Результат представьте в форме таблицы.

Ответ:

В качестве непрерывной независимой переменной рассмотрим age_i , а в качестве бинарной независимой переменной – $male_i$.

В пробит-модели вероятность удовлетворённости задаётся как:

$$P(satisfied_i = 1 | x_i) = \Phi(x_i \hat{\beta}),$$

где линейный индекс равен:

$$x_i \hat{\beta} = -0.4708 + 1.3880choice_i + 0.02753age_i - 0.0001796age_i^2 - 0.2715male_i - 0.00005578(choice_i \cdot age_i).$$

Для непрерывной переменной age_i предельный эффект рассчитывается как производная вероятности по возрасту:

$$\frac{\partial P(satisfied_i = 1 | x_i)}{\partial age_i} = \varphi(x_i \hat{\beta})(\hat{\beta}_{age} + 2\hat{\beta}_{age^2} age_i + \hat{\beta}_{choice:age} choice_i),$$

где $\varphi(\cdot)$ – плотность стандартного нормального распределения.

После подстановки оценок:

$$\frac{\partial P(satisfied_i = 1 | x_i)}{\partial age_i} = \varphi(x_i \hat{\beta})(0.02753 - 0.0003592age_i - 0.00005578choice_i).$$

Средний предельный эффект возраста равен:

$$AME_{age} = \frac{1}{n} \sum_{i=1}^n \varphi(x_i \hat{\beta})(0.02753 - 0.0003592age_i - 0.00005578choice_i) = 0.0038.$$

Для бинарной переменной $male_i$ рассчитывается дискретный эффект перехода от $male_i = 0$ к $male_i = 1$:

$$AME_{male} = \frac{1}{n} \sum_{i=1}^n [\Phi(x_i \hat{\beta} | male_i = 1) - \Phi(x_i \hat{\beta} | male_i = 0)] = -0.0662.$$

Переменная	Тип эффекта	Формула	Эффект
age	Средний предельный эффект	$\phi(x_i\hat{\beta}) (\beta_{age} + 2\beta_{age^2age_i} + \beta_{choice:agechoice_i})$	0.0038
male	Средний дискретный эффект	$\Phi(x_i\hat{\beta} male_i = 1) - \Phi(x_i\hat{\beta} male_i = 0)$	-0.0662

*Note: $\phi(\cdot)$ обозначает плотность стандартного нормального распределения,
а $\Phi(\cdot)$ — функцию распределения стандартного нормального распределения.*

Таблица 8 Средние предельные и дискретные эффекты для probit-модели

3.5. Посчитайте долю верных прогнозов и сопоставьте её с результатом наивного прогноза и линейно-вероятностной модели

Сделайте вывод о предсказательной силе пробит модели.

Ответ:

Наивный прогноз строился как прогноз наиболее часто встречающегося класса для всех наблюдений. Для определения метки класса использую стандартный порог по вероятности 0.5. Он достаточно простой и понятный, особенно для такой метрики, как Ассигасу (собственно, метрика доли верных прогнозов).

Модель	Доля верных прогнозов
Наивный прогноз	0.7544
Линейно-вероятностная модель	0.7784
Пробит-модель	0.7742

Note: Чем выше доля верных прогнозов, тем выше классификационная точность модели.

Таблица 9 Результаты по Ассигасу

Таким образом, пробит-модель предсказывает удовлетворённость игроков лучше, чем наивный прогноз:

$$0.7742 > 0.7544.$$

Это означает, что пробит-модель обладает предсказательной силой и использует информацию о включённых регрессорах. Однако доля верных прогнозов пробит-модели немного ниже, чем у линейно-вероятностной модели:

$$0.7742 < 0.7784.$$

Следовательно, по критерию доли верных прогнозов пробит-модель немного уступает линейно-вероятностной модели, хотя разница между ними мала. В целом можно сделать вывод, что пробит-модель улучшает качество прогноза по сравнению с наивным прогнозом, но не даёт заметного преимущества над линейно-вероятностной моделью.

Причина, скорее всего, кроется в том, что имеет место быть дисбаланс классов, и порог в 0.5 не является наилучшим решением в данном случае.

3.6. На уровне значимости 5% проверьте гипотезу о том, что предельный эффект на вероятность удовлетворенности игрой по произвольной (на ваш выбор) независимой переменной является значимым для индивида с произвольными характеристиками

Ответ:

Снова проверяем для Владимира.

Так как *male* является бинарной переменной, её предельный эффект рассчитывается как дискретное изменение вероятности при переходе от *male* = 0 к *male* = 1 при неизменных остальных характеристиках:

$$ME_{male} = P(satisfied_i = 1 | male_i = 1, x_{-male}) - P(satisfied_i = 1 | male_i = 0, x_{-m}).$$

В пробит-модели:

$$ME_{male} = \Phi(x_i \hat{\beta} | male_i = 1) - \Phi(x_i \hat{\beta} | male_i = 0).$$

Для Владимира:

$$\begin{aligned} x_i \hat{\beta} | male_i = 1 \\ &= -0.4708 + 1.3880 \cdot 1 + 0.02753 \cdot 22 - 0.0001796 \cdot 22^2 - 0.2715 \cdot 1 \\ &\quad - 0.00005578 \cdot 22. \\ x_i \hat{\beta} | male_i = 1 &\approx 1.1632. \end{aligned}$$

Если бы при тех же остальных характеристиках индивид был женщиной, то есть $male_i = 0$, линейный индекс был бы равен:

$$\begin{aligned} x_i \hat{\beta} | male_i = 0 \\ &= -0.4708 + 1.3880 \cdot 1 + 0.02753 \cdot 22 - 0.0001796 \cdot 22^2 - 0.00005578 \\ &\quad \cdot 22. \\ x_i \hat{\beta} | male_i = 0 &\approx 1.4347. \end{aligned}$$

Тогда оценённый предельный эффект равен:

$$\widehat{ME}_{male} = \Phi(1.1632) - \Phi(1.4347) \approx 0.8776 - 0.9242 = -0.0466.$$

Следовательно, для индивида с выбранными характеристиками мужской пол снижает оценённую вероятность удовлетворённости игрой примерно на 4.66 процентного пункта.

Проверим гипотезы:

$$\begin{aligned} H_0: ME_{male} &= 0 \\ H_1: ME_{male} &\neq 0. \end{aligned}$$

Для проверки используется z-статистика, построенная с помощью дельта-метода:

$$z = \frac{\widehat{ME}_{male}}{\widehat{se}(\widehat{ME}_{male})}.$$

При верной нулевой гипотезе:

$$z \xrightarrow{a} N(0,1).$$

Переменная	Предельный эффект	Стандартная ошибка	z-статистика	p-value
male	-0.0467***	0.0079	-5.9016	0.000

*Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1*

Таблица 10 Результаты проверки

3.7*. Повторите предыдущий пункт для переменной, имеющей взаимодействие

Ответ:

Так как $choice_i$ – бинарная переменная, её предельный эффект корректнее считать, как дискретный эффект перехода от прохождения игры за собак к прохождению игры за кошек при неизменных остальных характеристиках (простыми словами – просто как разницу между вероятностями):

$$\begin{aligned} ME_{choic} &= P(satisfied_i = 1 | choice_i = 1, x_{-choi}) - P(satisfied_i = 1 | choice_i \\ &= 0, x_{-choice}). \end{aligned}$$

В пробит-модели:

$$ME_{choice} = \Phi(x_i\hat{\beta} \mid choice_i = 1) - \Phi(x_i\hat{\beta} \mid choice_i = 0).$$

Так как $choice_i$ входит во взаимодействие с age_i , при $choice_i = 1$ взаимодействие равно $1 \cdot age_i$, а при $choice_i = 0$ – $0 \cdot age_i$.

Для Владимира:

$$\begin{aligned} x_i\hat{\beta} \mid choice_i = 1 \\ &= -0.4708 + 1.3880 \cdot 1 + 0.02753 \cdot 22 - 0.0001796 \cdot 22^2 - 0.2715 \cdot 1 \\ &\quad - 0.00005578 \cdot (1 \cdot 22). \\ x_i\hat{\beta} \mid choice_i = 1 &\approx 1.1632. \end{aligned}$$

Если бы Владимир проходил игру за собак, то $choice_i = 0$, а взаимодействие $choice_i \cdot age_i = 0$:

$$\begin{aligned} x_i\hat{\beta} \mid choice_i = 0 &= -0.4708 + 0.02753 \cdot 22 - 0.0001796 \cdot 22^2 - 0.2715 \cdot 1. \\ x_i\hat{\beta} \mid choice_i = 0 &\approx -0.2236. \end{aligned}$$

Тогда оценённый дискретный эффект равен:

$$\widehat{ME}_{choice} = \Phi(1.1632) - \Phi(-0.2236) \approx 0.8776 - 0.4115 = 0.4661.$$

Следовательно, для мужчины 22 лет переход от прохождения игры за собак к прохождению игры за кошек увеличивает оценённую вероятность удовлетворённости примерно на 46.61 процентного пункта.

Проверим гипотезы:

$$\begin{aligned} H_0: ME_{choic} &= 0 \\ H_1: ME_{choice} &\neq 0. \end{aligned}$$

Для проверки используем z-статистику, построенную с помощью дельта-метода:

$$z = \frac{\widehat{ME}_{choic}}{\widehat{se}(\widehat{ME}_{choice})}.$$

При верной нулевой гипотезе:

$$z \xrightarrow{a} N(0,1).$$

Переменная	Предельный эффект	Стандартная ошибка	z-статистика	p-value
choice	0.4661***	0.0168	27.7826	0.000

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 11 Результаты проверки статистической значимости

3.8. Воспользуйтесь дельта-методом для того, чтобы вручную рассчитать асимптотическую дисперсию предельного эффекта любой непрерывной переменной, входящей нелинейно**

Запишите использовавшееся вами выражение, подставив в него численные значения оценок пробит модели.

Ответ:

Предельный эффект возраста равен:

$$ME_{age} = \frac{\partial P(satisfied_i = 1 | x_i)}{\partial age_i} = \varphi(x_i\beta)(\beta_2 + 2\beta_3 age_i + \beta_5 choice_i),$$

где $\varphi(\cdot)$ – плотность стандартного нормального распределения.

Рассчитаем асимптотическую дисперсию этого предельного эффекта для индивида Владимира:

$$choice_i = 1, age_i = 22, male_i = 1.$$

Линейный индекс:

$$\begin{aligned} x_i\hat{\beta} &= -0.4708 + 1.3880 \cdot 1 + 0.02753 \cdot 22 - 0.0001796 \cdot 22^2 - 0.2715 \cdot 1 - 0.00005578 \\ &\quad \cdot 22. \\ x_i\hat{\beta} &\approx 1.1632. \end{aligned}$$

Часть предельного эффекта внутри скобок равна:

$$\begin{aligned} \hat{D} &= \hat{\beta}_2 + 2\hat{\beta}_3 age_i + \hat{\beta}_5 choice_i. \\ \hat{D} &= 0.02753 + 2 \cdot (-0.0001796) \cdot 22 + (-0.00005578) \cdot 1. \\ \hat{D} &\approx 0.01957. \end{aligned}$$

Тогда сам предельный эффект:

$$\widehat{ME}_{age} = \varphi(1.1632) \cdot 0.01957 \approx 0.00397.$$

То есть для выбранного индивида увеличение возраста на один год увеличивает вероятность удовлетворённости игрой примерно на 0.397 процентного пункта.

Теперь применим дельта-метод. Предельный эффект является функцией от вектора оценённых параметров:

$$g(\hat{\beta}) = \varphi(x_i\hat{\beta})(\hat{\beta}_2 + 2\hat{\beta}_3 age_i + \hat{\beta}_5 choice_i).$$

Асимптотическая дисперсия предельного эффекта рассчитывается как:

$$As.\widehat{Var}(\widehat{ME}_{age}) = \nabla g(\hat{\beta})' \widehat{Cov}(\hat{\beta}) \nabla g(\hat{\beta}),$$

где $\nabla g(\hat{\beta})$ – градиент функции предельного эффекта по оцениваемым параметрам пробит-модели.

Обозначим:

$$\begin{aligned} z &= x_i\hat{\beta}, \\ D &= \hat{\beta}_2 + 2\hat{\beta}_3 age_i + \hat{\beta}_5 choice_i. \end{aligned}$$

Тогда:

$$\widehat{ME}_{age} = \varphi(z)D.$$

Градиент имеет вид:

$$\nabla g(\hat{\beta}) = \varphi(z)[q - zDx],$$

где

$$x = (1, choice_i, age_i, age_i^2, male_i, choice_i \cdot age_i)',$$

а

$$q = (0, 0, 1, 2age_i, 0, choice_i)'$$

Для Владимира:

$$\begin{aligned} x &= (1, 1, 22, 484, 1, 22)', \\ q &= (0, 0, 1, 44, 0, 1)'. \end{aligned}$$

После подстановки численных значений:

$$z = 1.1632, D = 0.01957, \varphi(z) \approx 0.2028.$$

Поэтому градиент равен:

$$\nabla g(\hat{\beta}) \approx (-0.0046, -0.0046, 0.1012, 6.6891, -0.0046, 0.1012)'.$$

Итоговое выражение для асимптотической дисперсии:

$$\begin{aligned} &\widehat{As.Var}(\widehat{ME}_{age}) \\ &= (-0.0046 \quad -0.0046 \quad 0.1012 \quad 6.6891 \quad -0.0046 \quad 0.1012) \widehat{Cov}(\hat{\beta}) \begin{pmatrix} -0.0046 \\ -0.0046 \\ 0.1012 \\ 6.6891 \\ -0.0046 \\ 0.1012 \end{pmatrix}. \end{aligned}$$

Предельный эффект возраста равен:

$$ME_{age} = \frac{\partial P(satisfied_i = 1 | x_i)}{\partial age_i} = \varphi(x_i \hat{\beta}) (\hat{\beta}_{age} + 2\hat{\beta}_{age^2} age_i + \hat{\beta}_{choice:age} choice_i).$$

Для индивида Владимира:

$$choice_i = 1, age_i = 22, male_i = 1.$$

Линейный индекс равен:

$$\begin{aligned} x_i \hat{\beta} &= -0.4708 + 1.3880 \cdot 1 + 0.02753 \cdot 22 - 0.0001796 \cdot 22^2 - 0.2715 \cdot 1 - 0.00005578 \\ &\quad \cdot 22 \approx 1.1632. \end{aligned}$$

Часть предельного эффекта внутри скобок:

$$D = 0.02753 + 2(-0.0001796) \cdot 22 - 0.00005578 \cdot 1 \approx 0.01957.$$

Следовательно:

$$\widehat{ME}_{age} = \varphi(1.1632) \cdot 0.01957 \approx 0.0040.$$

То есть для выбранного индивида увеличение возраста на один год повышает оценённую вероятность удовлетворённости игрой примерно на 0.4 процентного пункта.

Для расчёта асимптотической дисперсии используется дельта-метод. Предельный эффект является функцией от оценённых параметров:

$$g(\hat{\beta}) = \varphi(x_i \hat{\beta}) (\hat{\beta}_{age} + 2\hat{\beta}_{age^2} age_i + \hat{\beta}_{choice:age} choice_i).$$

Тогда:

$$As.\widehat{Var}(\widehat{ME}_{age}) = \nabla g(\hat{\beta})' \widehat{Cov}(\hat{\beta}) \nabla g(\hat{\beta}).$$

После подстановки численных значений градиента и ковариационной матрицы оценок пробит-модели получено:

$$As.\widehat{Var}(\widehat{ME}_{age}) = 0.000001090798.$$

Стандартная ошибка предельного эффекта равна:

$$\widehat{se}(\widehat{ME}_{age}) = \sqrt{0.000001090798} = 0.001044413.$$

Показатель	Значение
Предельный эффект возраста	0.0040
Асимптотическая дисперсия	0.00000109
Стандартная ошибка	0.0010

Note: Асимптотическая дисперсия и стандартная ошибка предельного эффекта возраста рассчитаны вручную с использованием дельта-метода.

Таблица 12 Сводная таблица по пункту 3.8

Часть 4. Тестирование корректности спецификации пробит модели.

4.1. При помощи LM-теста проверьте гипотезу о соблюдении допущения о нормальном распределении случайных ошибок в пробит модели

Укажите, к каким негативным последствиям может привести нарушение данного допущения.

Ответ:

Нулевая и альтернативная гипотезы имеют вид:

H_0 : случайные ошибки имеют нормальное распределение,
 H_1 : случайные ошибки не имеют нормального распределения.

При верной нулевой гипотезе:

$$LM \xrightarrow{a} \chi^2(2)$$

Тест	LM-статистика	df	p-value
LM-тест нормальности ошибок	2.2433	2	0.3257

Note: Поскольку p -value больше 0.05, нулевая гипотеза о нормальности ошибок не отвергается на 5%-м уровне значимости.

Таблица 13 Результаты LM-теста нормальности ошибок

Так как $p\text{-value} \geq 0.05$, нет оснований отвергать нулевую гипотезу на любом разумном уровне значимости. Следовательно, данные не дают статистически значимых свидетельств против нормальности случайных ошибок.

Касаясь негативных последствий. Нарушение допущения о нормальности может привести к неверной спецификации функции правдоподобия пробит-модели. В результате оценки коэффициентов, предельные эффекты и предсказанные вероятности могут быть несостоятельными, а выводы о значимости факторов – некорректными. Некорректная спецификация распределения случайной ошибки в модели бинарного выбора может привести к несостоятельности оценок.

4.2. Предположите, какие переменные могут влиять на дисперсию случайной ошибки

При этом по крайней мере одна переменная должна входить и в линейный индекс основного уравнения, и в линейный индекс уравнения дисперсии. При помощи LR теста проверьте гипотезу о гомоскедастичности случайных ошибок. Запишите, к каким негативным последствиям может привести нарушение данного допущения. Объясните преимущество LM теста над LR тестом в данном случае.

Ответ:

Предположим, что дисперсия случайной ошибки может зависеть от характеристик игрока. В качестве переменных уравнения дисперсии выберем:

$$w_i = (age_i, bugs_i, price_i).$$

Переменная age_i уже входит в основное уравнение, поэтому требование задания выполнено. Содержательно возраст может отражать различия в устойчивости предпочтений и восприятии игры; число багов может увеличивать непредсказуемость

оценки игры; стоимость компьютера может быть связана с общим качеством / положительным опытом прохождения.

Гетероскедастичная модель бинарного выбора задаётся через условную дисперсию:

$$Var(\varepsilon_i | w_i) = [g(w_i\gamma)]^2,$$

где $w_i\gamma$ – линейный индекс уравнения дисперсии, а γ – вектор коэффициентов. При $\gamma = (0, \dots, 0)'$ дисперсия не зависит от w_i , поэтому тестирование гетероскедастичности эквивалентно проверке гипотезы $H_0: \gamma = (0, \dots, 0)'$.

Используем спецификацию:

$$g(w_i\gamma) = \exp(w_i\gamma).$$

Тогда вероятность удовлетворённости в гетероскедастичной пробит-модели равна:

$$P(satisfied_i = 1 | x_i, w_i) = \Phi\left(\frac{x_i\beta}{\exp(w_i\gamma)}\right).$$

В лекции для гетероскедастичной пробит-модели аналогично записывается вероятность:

$$P(y_i = 1 | x_i, w_i) = \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right).$$

Проверяем гипотезы:

$$H_0: \gamma_{age} = \gamma_{bugs} = \gamma_{price} = 0,$$

H_1 : хотя бы один коэффициент в уравнении дисперсии не равен нулю.

Нулевая гипотеза означает гомоскедастичность случайных ошибок. Альтернативная гипотеза означает, что дисперсия случайной ошибки зависит хотя бы от одной из выбранных переменных.

LR-статистика рассчитывается как:

$$LR = 2(\ln L_{UR} - \ln L_R),$$

где $\ln L_{UR}$ – логарифм правдоподобия гетероскедастичной пробит-модели, а $\ln L_R$ – логарифм правдоподобия обычной пробит-модели. При верной нулевой гипотезе:

$$LR \xrightarrow{a} \chi^2(3),$$

так как проверяются три ограничения. Глобально, LR-тест имеет асимптотическое распределение $\chi^2(r)$, где r – число ограничений.

Тест	$\ln L_R$	$\ln L_{UR}$	LR-статистика	df	p-value
LR-тест гомоскедастичности	-2166.761	-2166.761	0.0000	3	1.0000

Note: Поскольку p-value равен 1.0000, нулевая гипотеза о гомоскедастичности не отвергается.

Таблица 14 Результаты тестирования. LR-тест

Делаем вывод, что случайные ошибки в рамках модели гомоскедастичны на всех разумных уровнях значимости.

4.3. Для модели с гетероскедастичной случайной ошибкой рассчитайте предельный эффект

на 1) вероятность удовлетворенности игрой и на 2) дисперсию случайной ошибки по переменной, входящей и в основное уравнение, и уравнение дисперсии. Предварительно запишите формулы, по которым осуществляется расчет.

В гетероскедастичной пробит-модели:

$$P(satisfied_i = 1 | x_i, w_i) = \Phi\left(\frac{x_i\beta}{\exp(w_i\gamma)}\right),$$

где

$$x_i\beta = \beta_0 + \beta_1 choice_i + \beta_2 age_i + \beta_3 age_i^2 + \beta_4 male_i + \beta_5(choice_i \cdot age_i),$$

а уравнение стандартного отклонения ошибки задаётся как:

$$\sigma_i = \exp(w_i\gamma).$$

Соответственно, дисперсия случайной ошибки равна:

$$Var(\varepsilon_i | w_i) = \sigma_i^2 = \exp(2w_i\gamma).$$

Так как в моём коде переменная возраста в уравнении дисперсии стандартизирована:

$$age_s_i = \frac{age_i - \bar{age}}{sd(age)},$$

то при расчёте эффекта по исходному возрасту нужно учитывать множитель:

$$\frac{\partial age_s_i}{\partial age_i} = \frac{1}{sd(age)}.$$

1. Предельный эффект возраста на вероятность удовлетворённости

Обозначим:

$$z_i = \frac{x_i\beta}{\exp(w_i\gamma)}.$$

Тогда:

$$P(satisfied_i = 1 | x_i, w_i) = \Phi(z_i).$$

Предельный эффект возраста на вероятность:

$$\frac{\partial P(satisfied_i = 1 | x_i, w_i)}{\partial age_i} = \varphi(z_i) \cdot \frac{\partial z_i}{\partial age_i}.$$

Так как age_i входит и в основное уравнение, и в уравнение дисперсии, получаем:

$$\begin{aligned} & \frac{\partial P(satisfied_i = 1 | x_i, w_i)}{\partial age_i} \\ &= \varphi(z_i) \cdot \frac{(\beta_{age} + 2\beta_{age^2} age_i + \beta_{choice : age} choice_i) - (x_i\beta) \frac{\gamma_{age_s}}{sd(age)}}{\exp(w_i\gamma)}. \end{aligned}$$

2. Предельный эффект возраста на дисперсию случайной ошибки

Поскольку:

$$Var(\varepsilon_i | w_i) = \exp(2w_i\gamma),$$

то предельный эффект возраста на дисперсию равен:

$$\frac{\partial Var(\varepsilon_i | w_i)}{\partial age_i} = 2 \exp(2w_i\gamma) \cdot \frac{\gamma_{age_s}}{sd(age)}.$$

Переменная	Зависимая величина	Формула	Средний эффект
age	Вероятность удовлетворенности	$ME_{age,i} = \phi(z_i) \exp(w_i\gamma) [A_i - x_i\beta \cdot \gamma_{age,s} sd(age)]$	0.003819
age	Дисперсия случайной ошибки	$ME_{\sigma^2,i} = 2 \exp(2w_i\gamma) \cdot \gamma_{age,s} sd(age)$	0.000000

Note: $A_i = \beta_{age} + 2\beta_{age^2}age_i + \beta_{choice:age}choice_i$. В таблице приведены средние эффекты переменной age на вероятность удовлетворенности и на дисперсию случайной ошибки в модели с гетероскедастичностью.

Таблица 15 Результаты оценивания

4.4. Для переменной, входящей в линейный индекс нелинейно, при помощи LR теста проверьте гипотезы о том, что:

1. Коэффициент при линейной части равняется нулю
2. Оба коэффициента равняются нулю
3. Коэффициент при линейной части совпадает по знаку и в k раз больше (по модулю), чем при нелинейной, где $k \neq 0$ можно выбрать произвольным, указав выбранное значение.
4. Коэффициент при линейной части совпадает по знаку и в k раз больше, чем при нелинейной, а коэффициент при произвольной бинарной переменной равняется t, где $t \neq 0$ можно выбрать произвольным, указав выбранное значение.

Ответ:

В качестве переменной, входящей в линейный индекс нелинейно, рассмотрим возраст age_i , так как в модели присутствуют age_i и age_i^2 :

$$x_i\beta = \beta_0 + \beta_1choice_i + \beta_2age_i + \beta_3age_i^2 + \beta_4male_i + \beta_5(choice_i \cdot age_i).$$

Здесь β_2 – коэффициент при линейной части возраста, а β_3 – коэффициент при нелинейной части age_i^2 .

Неограниченная модель – исходная пробит-модель:

$$P(satisfied_i = 1 | x_i) = \Phi(x_i\beta).$$

Для всех тестов используется статистика:

$$LR = 2(\ln L_{UR} - \ln L_R).$$

1. Проверка гипотезы $\beta_{age} = 0$

Проверим гипотезу:

$$H_0: \beta_2 = 0,$$

$$H_1: \beta_2 \neq 0.$$

При верной нулевой гипотезе:

$$LR \xrightarrow{a} \chi^2(1).$$

Ограниченная модель отличается тем, что из неё исключается линейная часть возраста age_i , но остаётся age_i^2 .

2. Проверка гипотезы $\beta_{age} = 0$ и $\beta_{age^2} = 0$

Проверим гипотезу:

$$H_0: \beta_2 = 0, \beta_3 = 0,$$

H_1 : хотя бы один из коэффициентов β_2, β_3 не равен нулю.

При верной нулевой гипотезе:

$$LR \xrightarrow{a} \chi^2(2).$$

Ограниченная модель исключает и age_i , и age_i^2 .

3. Проверка гипотезы $\beta_{age} = k\beta_{age^2}$

Выберем произвольное значение:

$$k = 100.$$

Тогда проверяем гипотезу:

$$H_0: \beta_2 = 100\beta_3,$$

$$H_1: \beta_2 \neq 100\beta_3.$$

Так как $k > 0$, данное ограничение означает, что коэффициент при линейной части возраста совпадает по знаку с коэффициентом при нелинейной части и в 100 раз больше него по модулю.

При верной нулевой гипотезе:

$$LR \xrightarrow{a} \chi^2(1).$$

4. Проверка гипотезы $\beta_{age} = k\beta_{age^2}$ и $\beta_{male} = t$

В качестве произвольной бинарной переменной возьмём $male_i$. Выберем:

$$k = 100, t = -0.2.$$

Проверяем гипотезу:

$$H_0: \begin{cases} \beta_2 = 100\beta_3, \\ \beta_4 = -0.2, \end{cases}$$

H_1 : хотя бы одно из ограничений не выполняется.

При верной нулевой гипотезе:

$$LR \xrightarrow{a} \chi^2(2).$$

№	Нулевая гипотеза	$\ln L_R$	$\ln L_{UR}$	LR-статистика	df	p-value
1	$\beta_{age} = 0$	-2171.078	-2166.761	8.6340	1	0.0033
2	$\beta_{age} = 0, \beta_{age^2} = 0$	-2193.430	-2166.761	53.3384	2	0.0000
3	$\beta_{age} = 100\beta_{age^2}$	-2220.460	-2166.761	107.3979	1	0.0000
4	$\beta_{age} = 100\beta_{age^2}, \beta_{male} = -0.2$	-2233.778	-2166.761	134.0336	2	0.0000

Note: Во всех тестах, кроме случая с $\beta_{age} = 0$, значение p-value округлено до 0.0000; это означает, что нулевая гипотеза отвергается на стандартных уровнях значимости.

Таблица 16 Результаты LR-тестов линейных ограничений

4.5. При помощи LR теста проверьте, можно ли оценивать совместную модель для мужчин и для женщин, либо стоит оценить две различные модели

Ответ:

Проверяем гипотезу:

H_0 : совместная модель для мужчин и женщин допустима

то есть коэффициенты при choice, age, age² и choice:age одинаковы для мужчин и женщин.

H_1 : для мужчин и женщин следует оценивать разные модели.

LR-статистика:

$$LR = 2(\ln L_{UR} - \ln L_R),$$

где $\ln L_R$ – логарифм правдоподобия совместной модели, а $\ln L_{UR}$ – сумма логарифмов правдоподобия двух отдельных моделей.

При верной нулевой гипотезе:

$$LR \xrightarrow{a} \chi^2(4).$$

Степеней свободы 4, потому что в совместной модели уже есть дамми male, то есть различие в константе между мужчинами и женщинами разрешено. Проверяется равенство четырёх остальных коэффициентов – при choice, age, age² и choice:age.

Тест	$\ln L_R$	$\ln L_{UR}$	LR-статистика	df	p-value
LR-тест совместной модели для мужчин и женщин	-2166.761	-2164.075	5.3729	4	0.2511

Note: Поскольку p-value больше 0.05, нулевая гипотеза о допустимости совместной модели для мужчин и женщин не отвергается.

Таблица 17 Результаты LR-теста совместной модели для мужчин и женщин

4.6*. При помощи LR теста проверьте, можно ли оценивать совместную модель для людей, проживающих в населённых пунктах различного типа

(рассмотрите все три возможных типа населённого пункта).

Ответ:

Итак, в рамках задания давайте проверим, можно ли оценивать одну совместную пробит-модель для игроков, проживающих в населённых пунктах трёх типов. Типы следующие: деревня, город и столица региона. Либо же сделаем выбор в пользу оценки трёх отдельных моделей.

Ограниченная модель – совместная пробит-модель для всех наблюдений с добавлением дамми-переменных для типа населённого пункта:

$$satisfied_i \sim choice_i + age_i + age_i^2 + male_i + choice_i \cdot age_i + residence_i.$$

Неограниченная модель – три отдельные пробит-модели: для жителей деревни, города и столицы региона.

Проверяем гипотезы:

H_0 : совместная модель для всех типов населённых пунктов допустима,

H_1 : для разных типов населённых пунктов следует оценивать разные модели.

LR-статистика рассчитывается как:

$$LR = 2(\ln L_{UR} - \ln L_R),$$

где $\ln L_R$ – логарифм правдоподобия совместной модели, а $\ln L_{UR}$ – сумма логарифмов правдоподобия трёх отдельных моделей.

При верной нулевой гипотезе:

$$LR \xrightarrow{a} \chi^2(r).$$

В данном случае:

$$r = 18 - 8 = 10.$$

Три отдельные модели имеют по 6 параметров каждая, то есть всего 18 параметров.

Совместная модель имеет 8 параметров: константа, choice, age, age², male, choice:age и две дамми-переменные для трёх типов населённого пункта. Результаты ниже:

Тест	$\ln L_R$	$\ln L_{UR}$	LR-статистика	df	p-value
LR-тест совместной модели для типов населенного пункта	-2121.262	-2118.639	5.2470	10	0.8741

Note: Поскольку p -value больше 0.05, нулевая гипотеза о допустимости совместной модели для типов населенного пункта не отвергается.

Таблица 18 Результаты LR-теста совместной модели для типов населенного пункта

4.7. Для индивида с произвольными характеристиками оцените асимптотическую дисперсию предельного эффекта любой непрерывной переменной, входящей сразу в оба уравнения, на вероятность удовлетворенности игрой.**

Запишите использовавшуюся вами формулу.

Снова возьмем переменную age.

Так как в уравнении дисперсии использовались стандартизированные переменные, то для Владимира:

$$age_{si} = \frac{22 - \bar{age}}{sd(age)}.$$

В гетероскедастичной пробит-модели:

$$P(satisfied_i = 1 | x_i, w_i) = \Phi\left(\frac{x_i\beta}{\exp(w_i\gamma)}\right).$$

Обозначим:

$$\mu_i = x_i\beta,$$

$$\sigma_i = \exp(w_i \gamma),$$

$$z_i = \frac{\mu_i}{\sigma_i}.$$

Тогда вероятность удовлетворённости равна:

$$P(satisfied_i = 1 | x_i, w_i) = \Phi(z_i).$$

Предельный эффект возраста на вероятность удовлетворённости:

$$ME_{age} = \frac{\partial P(satisfied_i = 1 | x_i, w_i)}{\partial age_i} = \varphi(z_i) \cdot \frac{\frac{\partial \mu_i}{\partial age_i} - \mu_i \frac{\partial \ln \sigma_i}{\partial age_i}}{\sigma_i}.$$

Так как:

$$\frac{\partial \mu_i}{\partial age_i} = \beta_{age} + 2\beta_{age^2} age_i + \beta_{choic} : age choice_i,$$

а

$$\frac{\partial \ln \sigma_i}{\partial age_i} = \frac{\gamma_{age.s}}{sd(age)},$$

получаем:

$$ME_{age} = \varphi(z_i) \cdot \frac{\beta_{age} + 2\beta_{age^2} age_i + \beta_{choic} : age choice_i - \mu_i \frac{\gamma_{age.s}}{sd(age)}}{\sigma_i}.$$

Для оценки асимптотической дисперсии применяется дельта-метод. Предельный эффект рассматривается как функция от оценённых параметров:

$$g(\hat{\theta}) = \widehat{ME}_{age},$$

где

$$\hat{\theta} = (\hat{\beta}', \hat{\gamma}')'.$$

Тогда:

$$\widehat{As.Var}(\widehat{ME}_{age}) = \nabla g(\hat{\theta})' \widehat{Cov}(\hat{\theta}) \nabla g(\hat{\theta}).$$

Переменная	Предельный эффект	Асимптотическая дисперсия	Стандартная ошибка
age	0.00397	0.000000	0.000617

Note: Предельный эффект переменной age и его стандартная ошибка рассчитаны с использованием дельта-метода.

Таблица 19 Предельный эффект возраста, рассчитанный по дельта-методу

Часть 5. Логит модель.

5.1. Оцените логит модель, предварительно записав максимизируемую функцию правдоподобия и указав, чем логит модель отличается от пробит модели

Результат представьте в форме таблицы (можно, например, использовать выдачу из stata, R или python).

Ответ:

Функция распределения стандартного логистического распределения имеет вид:

$$\Lambda(t) = \frac{1}{1 + e^{-t}}.$$

Поэтому в логит-модели:

$$P(satisfied_i = 1 | x_i) = \Lambda(x_i\beta) = \frac{1}{1 + e^{-x_i\beta}}.$$

В данной работе используется следующий линейный индекс:

$$x_i\beta = \beta_0 + \beta_1 choice_i + \beta_2 age_i + \beta_3 age_i^2 + \beta_4 male_i + \beta_5 (choice_i \cdot age_i).$$

Тогда:

$$P(satisfied_i = 0 | x_i) = 1 - \Lambda(x_i\beta).$$

Логарифм функции правдоподобия логит-модели имеет вид:

$$\ln L(\beta; y | X) = \sum_{i=1}^n \left[satisfied_i \ln \left(\frac{1}{1 + e^{-x_i\beta}} \right) + (1 - satisfied_i) \ln \left(1 - \frac{1}{1 + e^{-x_i\beta}} \right) \right].$$

Параметры

$$\beta = (\beta_0, \beta_1, \beta_2, \beta_3, \beta_4, \beta_5)'$$

оцениваются методом максимального правдоподобия. Как и для пробит-модели, аналитического решения для оценок нет, поэтому используются численные методы оптимизации.

Dependent variable: satisfied				
Coefficients				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7673349**	0.2884804	-2.660	0.00782
choice	2.2381396***	0.2146085	10.429	< 2e-16
age	0.0456080**	0.0162787	2.802	0.00508
$I(age^2)$	-0.0003052	0.0002052	-1.488	0.13684
male	-0.4597397***	0.0759776	-6.051	1.44e-09
choice:age	0.0060889	0.0062584	0.973	0.33059
Качество модели				
Тип модели	Logit model			
Семейство распределения	Binomial			
Link function	Logit			
Формула	satisfied ~ choice + age + $I(age^2)$ + male + choice:age			
Null deviance	5574.5 (df = 4999)			
Residual deviance	4335.1 (df = 4994)			
AIC	4347.1			
Fisher scoring iterations	5			
Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1				

Таблица 20 Оценённая logit-модель

5.2. Проинтерпретируйте значения оценок изменений в отношениях шансов по каждой независимой переменной, входящей линейно.

Переменная	Оценка коэффициента	$\exp(\hat{\beta})$	Интерпретация
choice	2.2381	9.3759	При переходе от прохождения игры за собак к прохождению игры за кошек отношение шансов быть удовлетворённым игрой увеличивается примерно в 9.38 раза, при прочих равных условиях.
age	0.0456	1.0467	При увеличении возраста на один год отношение шансов быть удовлетворённым игрой увеличивается примерно в 1.047 раза, то есть на 4.67%, при прочих равных условиях.
male	-0.4597	0.6314	Для мужчин отношение шансов быть удовлетворёнными игрой составляет примерно 0.631 от отношения шансов для женщин, при прочих равных условиях. Иначе говоря, у мужчин отношение шансов ниже примерно на 36.86%.

Note: Значения $\exp(\hat{\beta})$ интерпретируются как отношения шансов. Значение больше 1 означает рост отношения шансов, значение меньше 1 — снижение отношения шансов.

Таблица 21 Интерпретация коэффициентов logit-модели через отношение шансов

5.3*. Запишите выражения для расчета изменений в отношениях шансов по каждой независимой переменной, входящей нелинейно.

Рассчитайте соответствующие предельные эффекты для индивида с произвольными характеристиками. Результаты расчетов представьте в форме таблицы.

В логит-модели отношение шансов удовлетворённости игрой равно:

$$\frac{P(satisfied_i = 1 | x_i)}{1 - P(satisfied_i = 1 | x_i)} = \exp(x_i \hat{\beta}).$$

Используем оценённую логит-модель:

$$x_i \hat{\beta} = -0.7673 + 2.2381choice_i + 0.0456age_i - 0.0003052age_i^2 - 0.4597male_i + 0.0060889(choice_i \cdot age_i).$$

Переменная age_i входит в модель нелинейно, так как присутствуют age_i и age_i^2 . Кроме того, переменные $choice_i$ и age_i входят во взаимодействие $choice_i \cdot age_i$, поэтому эффект каждой из них зависит от значения другой переменной.

Рассмотрим произвольного индивида Владимира.

1. Изменение отношения шансов при увеличении возраста на 1 год

Так как возраст входит в модель через age_i , age_i^2 и $choice_i \cdot age_i$, изменение логарифма отношения шансов при увеличении возраста с age_i до $age_i + 1$ равно:

$$\Delta \ln Odds_{age} = \hat{\beta}_{age} + \hat{\beta}_{age^2}((age_i + 1)^2 - age_i^2) + \hat{\beta}_{choice:age}choice_i.$$

Поскольку

$$(age_i + 1)^2 - age_i^2 = 2age_i + 1,$$

получаем:

$$\Delta \ln Odds_{age} = \hat{\beta}_{age} + \hat{\beta}_{age^2}(2age_i + 1) + \hat{\beta}_{choice:age}choice_i.$$

Для Владимира:

$$\Delta \ln Odds_{age} = 0.0456080 - 0.0003052(2 \cdot 22 + 1) + 0.0060889 \cdot 1.$$

$$\Delta \ln Odds_{age} \approx 0.03796.$$

Тогда изменение отношения шансов:

$$\frac{Odds(age_i + 1)}{Odds(age_i)} = \exp(0.03796) \approx 1.0387.$$

То есть при увеличении возраста Владимира на один год отношение шансов быть удовлетворённым игрой увеличивается примерно в 1.039 раза, или примерно на 3.87%.

2. Изменение отношения шансов при переходе от собак к кошкам

Так как $choice_i$ входит в модель напрямую и через взаимодействие $choice_i \cdot age_i$, изменение логарифма отношения шансов при переходе от $choice_i = 0$ к $choice_i = 1$ равно:

$$\Delta \ln Odds_{choi} = \hat{\beta}_{choic} + \hat{\beta}_{choic : age} age_i.$$

Для Владимира:

$$\Delta \ln Odds_{choice} = 2.2381396 + 0.0060889 \cdot 22.$$

$$\Delta \ln Odds_{choic} \approx 2.3721.$$

Тогда изменение отношения шансов:

$$\frac{Odds(choice_i = 1)}{Odds(choice_i = 0)} = \exp(2.3721) \approx 10.72.$$

То есть для мужчины 22 лет переход от прохождения игры за собак к прохождению игры за кошек увеличивает отношение шансов быть удовлетворённым игрой примерно в 10.72 раза.

Переменная	Изменение	Формула	Значение
age	Увеличение возраста на 1 год	$\exp(\hat{\beta}_{age} + \hat{\beta}_{age^2}(2age_i + 1) + \hat{\beta}_{choice:age}choice_i)$	1.0387
choice	Переход от собак к кошкам	$\exp(\hat{\beta}_{choic} + \hat{\beta}_{choic:age}age_i)$	10.72

Note: Значения показывают, во сколько раз изменяется отношение шансов при соответствующем изменении переменной. Для переменных, входящих в модель нелинейно или через взаимодействие, эффект зависит от значений age_i и $choice_i$.

Таблица 22 Изменение отношения шансов для переменных, входящих нелинейно и во взаимодействие

5.4.** Для произвольной независимой переменной, входящей нелинейно, проверьте гипотезу о том, что при её изменении на единицу отношение шансов возрастет на 10%.

Запишите тестовую статистику, а также формулу, по которой рассчитывалась стандартная ошибка оценки изменения отношений шансов.

В логит-модели отношение шансов равно:

$$Odds_i = \frac{P(satisfied_i = 1 | x_i)}{1 - P(satisfied_i = 1 | x_i)} = \exp(x_i \beta).$$

При увеличении возраста на один год изменение логарифма отношения шансов равно:

$$\Delta \ln Odds_{age} = \beta_{age} + \beta_{age^2}((age_i + 1)^2 - age_i^2) + \beta_{choic : age} choice_i.$$

Так как

$$(age_i + 1)^2 - age_i^2 = 2age_i + 1,$$

то:

$$\Delta \ln Odds_{age} = \beta_{age} + \beta_{age^2}(2age_i + 1) + \beta_{choice:age}choice_i.$$

Следовательно, само изменение отношения шансов равно:

$$OR_{age} = \exp(\beta_{age} + \beta_{age^2}(2age_i + 1) + \beta_{choice:age}choice_i).$$

Проверим гипотезу о том, что при увеличении возраста на один год отношение шансов возрастает на 10%, то есть становится равным 1.10:

$$H_0: OR_{age} = 1.10,$$

$$H_1: OR_{age} \neq 1.10.$$

Для Владимира:

$$\widehat{OR}_{age} = \exp(0.0456080 - 0.0003052(2 \cdot 22 + 1) + 0.0060889 \cdot 1).$$

$$\widehat{OR}_{age} \approx \exp(0.03796) \approx 1.0387.$$

То есть, по точечной оценке, при увеличении возраста Владимира на один год отношение шансов удовлетворённости возрастает примерно на 3.87%, а не на 10%.

Стандартная ошибка по дельта-методу

Обозначим оцениваемую функцию:

$$g(\beta) = \exp(\beta_{age} + \beta_{age^2}(2age_i + 1) + \beta_{choice:age}choice_i).$$

Тогда стандартная ошибка оценки изменения отношения шансов рассчитывается по дельта-методу:

$$\widehat{se}(\widehat{OR}_{age}) = \sqrt{\nabla g(\hat{\beta})' \widehat{Cov}(\hat{\beta}) \nabla g(\hat{\beta})}.$$

Для данной функции градиент имеет вид:

$$\nabla g(\hat{\beta}) = \widehat{OR}_{age} \cdot q,$$

где

$$q = (0, 0, 1, 2age_i + 1, 0, choice_i)'$$

Для Владимира:

$$q = (0, 0, 1, 45, 0, 1)'.$$

Тогда:

$$\widehat{se}(\widehat{OR}_{age}) = \sqrt{(\widehat{OR}_{age} q)' \widehat{Cov}(\hat{\beta}) (\widehat{OR}_{age} q)}.$$

Тестовая статистика:

$$z = \frac{\widehat{OR}_{age} - 1.10}{\widehat{se}(\widehat{OR}_{age})}.$$

При верной нулевой гипотезе:

$$z \xrightarrow{a} N(0,1).$$

Переменная	Изменение	$\widehat{OR}$	SE	H_0	z	p -value
age	age + 1	1.0387	0.0087	1.1	-7.0804	0.000

Note: Проверяется нулевая гипотеза о том, что отношение шансов при увеличении возраста на один год равно 1.1. Поскольку p -value близко к нулю, нулевая гипотеза отвергается.

Таблица 23 Тест гипотезы об отношении шансов для переменной age

Часть 6. Система бинарных уравнений.

6.1. Оцените систему бинарных уравнений, одно из которых описывает вероятность удовлетворенности игрой, а второе – вероятность того, что индивид станет играть за кошек.

При спецификации уравнений соблюдайте наличие ограничений исключения.

Ответ:

В предыдущих частях в качестве основной спецификации для удовлетворённости использовалась модель:

$$satisfied_i = f(choice_i, age_i, age_i^2, male_i, choice_i \cdot age_i).$$

Сохраним эту логику и в системе бинарных уравнений. Первое уравнение будет описывать вероятность удовлетворённости игрой:

$$satisfied_i^* = \beta_0 + \beta_1 choice_i + \beta_2 age_i + \beta_3 age_i^2 + \beta_4 male_i + \beta_5 (choice_i \cdot age_i) + \varepsilon_{1i}.$$

Наблюдаемая бинарная переменная определяется так:

$$satisfied_i = \begin{cases} 1, & \text{если } satisfied_i^* > 0, \\ 0, & \text{если } satisfied_i^* \leq 0. \end{cases}$$

Второе уравнение описывает вероятность того, что игрок выберет прохождение за кошек:

$$choice_i^* = \gamma_0 + \gamma_1 age_i + \gamma_2 male_i + \gamma_3 design_i + \gamma_4 cat_i + \gamma_5 dog_i + \varepsilon_{2i}.$$

$$choice_i = \begin{cases} 1, & \text{если } choice_i^* > 0, \\ 0, & \text{если } choice_i^* \leq 0. \end{cases}$$

Случайные ошибки двух уравнений имеют совместное стандартное двумерное нормальное распределение:

$$\begin{pmatrix} \varepsilon_{1i} \\ \varepsilon_{2i} \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right).$$

Здесь ρ – коэффициент корреляции между случайными ошибками двух уравнений. В лекционной постановке именно ρ отражает связь между ненаблюдаемыми факторами разных бинарных уравнений.

Ограничения исключения соблюдаются за счёт того, что переменные $design_i$, cat_i и dog_i включаются в уравнение выбора стороны прохождения, но не включаются напрямую в уравнение удовлетворённости. Это содержательно оправдано следующим образом:

$$design_i$$

может влиять на то, выберет ли игрок кошек или собак, поскольку это дизайн меню выбора стороны прохождения. При этом после контроля самого выбора стороны прохождения нет очевидной причины считать, что дизайн меню напрямую влияет на итоговую удовлетворённость игрой.

$$cat_i, dog_i$$

отражают наличие у игрока кота или собаки и могут быть связаны с предпочтением выбрать кошек или собак. Однако сами по себе эти переменные не обязательно напрямую определяют удовлетворённость игровым процессом после контроля $choice_i$, возраста и пола.

Показатель	Значение
Метод оценивания	Maximum likelihood
Log-likelihood	-5264.3111
AIC	10554.6221
Количество наблюдений	5000

Таблица 24 Общая информация о модели с взаимодействием

Ordinal equation: choice				
Coefficients				
Переменная	Estimate	Std. Error	z value	Pr(> z)
age	0.0064957***	0.0012609	5.1517	2.581e-07
male	-0.2206462***	0.0371291	-5.9427	2.804e-09
design	0.5540397***	0.0508938	10.8862	< 2.2e-16
cat	0.5089820***	0.0409273	12.4362	< 2.2e-16
dog	0.5065452***	0.0382616	13.2390	< 2.2e-16
Thresholds				
Popor	Estimate	Std. Error	z value	Pr(> z)
cut1	0.756448***	0.061783	12.243	< 2.2e-16

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 25 Результаты оценки уравнения choice

Ordinal equation: satisfied				
Coefficients				
Переменная	Estimate	Std. Error	z value	Pr(> z)
choice	1.70745541***	0.18338736	9.3106	< 2.2e-16
age	0.02619122**	0.00922819	2.8382	0.004537
$I(age^2)$	-0.00017802	0.00011545	-1.5419	0.123099
male	-0.24162540***	0.04633547	-5.2147	1.841e-07
choice_age	0.00030863	0.00311828	0.0990	0.921158
Thresholds				
Попор	Estimate	Std. Error	z value	Pr(> z)
cut1	0.64347***	0.18314	3.5136	0.0004421
Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1				

Таблица 26 Результаты оценки уравнения *satisfied* с взаимодействием

Параметр	Estimate	Std. Error	z value	Pr(> z)
cov(satisfied, choice)	-0.24029*	0.11435	-2.1013	0.03561
Note: Отрицательная и статистически значимая корреляция указывает на наличие связи между ненаблюдаемыми компонентами уравнений <i>satisfied</i> и <i>choice</i> .				
Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1				

Таблица 27 Корреляция между порядковыми уравнениями

6.2. Проинтерпретируйте оценки коэффициентов при независимых переменных и коэффициента корреляции между случайными ошибками рассматриваемых уравнений.

Уравнение выбора прохождения за кошек

Уравнение выбора имеет вид:

$$choice_i^* = \gamma_0 + \gamma_1 age_i + \gamma_2 male_i + \gamma_3 design_i + \gamma_4 cat_i + \gamma_5 dog_i + \varepsilon_{2i}.$$

Переменная	Оценка	p-value	Интерпретация
age	0.0065	0.0000	Возраст положительно и статистически значимо связан с вероятностью выбора кошек. Более взрослые игроки чаще выбирают прохождение за кошек.
male	-0.2206	0.0000	Мужчины статистически значимо реже выбирают прохождение за кошек по сравнению с женщинами.
design	0.5540	0.0000	Первый дизайн меню статистически значимо повышает склонность выбрать кошек.
cat	0.5090	0.0000	Наличие кота положительно и статистически значимо связано с выбором прохождения за кошек.
dog	0.5065	0.0000	Наличие собаки также положительно и статистически значимо связано с выбором кошек.

Note: Интерпретация приведена для уравнения *choice*. Положительный коэффициент означает увеличение латентной склонности выбрать прохождение за кошек, отрицательный коэффициент — снижение такой склонности.

Таблица 28 Интерпретация коэффициентов уравнения *choice*

Таким образом, все переменные в уравнении выбора статистически значимы на уровне 5%. Особенно важно, что *design*, *cat* и *dog*, использованные как ограничения

исключения, значимо влияют на выбор стороны прохождения. Это подтверждает их релевантность для уравнения $choice_i$.

Уравнение удовлетворённости игрой

Уравнение удовлетворённости имеет вид:

$$satisfied_i^* = \beta_0 + \beta_1 choice_i + \beta_2 age_i + \beta_3 age_i^2 + \beta_4 male_i + \beta_5 (choice_i \cdot age_i) + \varepsilon_{1i}.$$

Переменная	Оценка	p-value	Интерпретация
choice	1.7075	0.0000	Выбор прохождения за кошек положительно и статистически значимо связан с вероятностью удовлетворённости игрой.
age	0.0262	0.0045	Возраст положительно и статистически значимо связан с удовлетворённостью. Более взрослые игроки в среднем имеют более высокую склонность быть удовлетворёнными.
age^2	-0.0002	0.1231	Квадратичный эффект возраста отрицательный, но статистически незначимый на уровне 5%. Значит, убедительных свидетельств нелинейного влияния возраста в системе бинарных уравнений нет.
male	-0.2416	0.0000	Мужчины статистически значимо менее склонны быть удовлетворёнными игрой по сравнению с женщинами.
choice_age	0.0003	0.9212	Взаимодействие выбора кошек и возраста статистически незначимо. Нет оснований утверждать, что эффект выбора кошек существенно различается в зависимости от возраста.

Note: Интерпретация приведена для уравнения *satisfied*. Положительный коэффициент означает увеличение латентной склонности быть удовлетворённым игрой, отрицательный коэффициент — снижение такой склонности.

Таблица 29 Интерпретация коэффициентов уравнения *satisfied*

Главный содержательный результат во втором уравнении – положительный и значимый коэффициент при *choice*. Это означает, что после учёта возможной связи между выбором стороны прохождения и удовлетворённостью, прохождение за кошек всё равно связано с более высокой удовлетворённостью игрой.

Интерпретация корреляции случайных ошибок

Оценка корреляции между случайными ошибками двух уравнений равна:

$$\hat{\rho} = -0.2403,$$

при

$$p\text{-value} = 0.0356.$$

На уровне значимости 5% коэффициент корреляции статистически значим. Следовательно, нулевая гипотеза об отсутствии корреляции между случайными ошибками двух уравнений отвергается.

Отрицательный знак означает, что ненаблюдаемые факторы, повышающие склонность выбрать прохождение за кошек, связаны с более низкой ненаблюдаемой компонентой удовлетворённости игрой. Иными словами, после контроля наблюдаемых характеристик существуют ненаблюдаемые особенности игроков, которые одновременно связаны с выбором стороны прохождения и удовлетворённостью.

6.3. При помощи LR теста проверьте, имеется ли необходимость в том, чтобы оценивать оба уравнения совместно.

Проверяем гипотезы:

$$H_0: \rho = 0,$$

$$H_1: \rho \neq 0.$$

Нулевая гипотеза означает, что случайные ошибки уравнения удовлетворённости и уравнения выбора кошек не коррелированы. В этом случае совместная оценка системы не нужна, и можно оценивать два уравнения отдельно.

Альтернативная гипотеза означает, что ошибки коррелированы, то есть есть ненаблюдаемые факторы, одновременно связанные с выбором кошек и удовлетворённостью игрой. Тогда совместная оценка системы бинарных уравнений оправдана.

LR-статистика рассчитывается как:

$$LR = 2(\ln L_{UR} - \ln L_R),$$

где:

$$\ln L_{UR}$$

– логарифм правдоподобия совместной модели, то есть системы бинарных уравнений;

$$\ln L_R$$

– логарифм правдоподобия ограниченной модели при $\rho = 0$. При $\rho = 0$ совместная функция правдоподобия распадается на произведение двух отдельных функций правдоподобия, поэтому:

$$\ln L_R = \ln L_{choic} + \ln L_{satisfied}.$$

При верной нулевой гипотезе:

$$LR \xrightarrow{a} \chi^2(1),$$

поскольку проверяется одно ограничение: $\rho = 0$.

Тест	$\ln L_R$	$\ln L_{UR}$	LR-статистика	df	p-value
LR-тест необходимости совместного оценивания	-5267.516	-5264.311	6.4088	1	0.0114

Note: Поскольку p -value меньше 0.05, нулевая гипотеза отвергается. Это указывает на необходимость совместного оценивания уравнений.

Таблица 30 Результаты LR-теста необходимости совместного оценивания

6.4. Для индивида с произвольными характеристиками оцените:

1) Вероятность того, что игрок удовлетворен игрой 2) Вероятность того, что игрок проходил игру за кошек 3) Вероятность того, что игрок неудовлетворен игрой и играл за собак 4) Вероятность того, что игрок удовлетворен игрой, при условии, что он играл за кошек

Вероятность	Обозначение	Значение
Игрок удовлетворён игрой	$P(satisfied_i = 1)$	0.6973
Игрок проходил игру за кошек	$P(choice_i = 1)$	0.5905
Игрок неудовлетворён и играл за собак	$P(satisfied_i = 0, choice_i = 0)$	0.2325
Игрок удовлетворён при условии, что играл за кошек	$P(satisfied_i = 1 choice_i = 1)$	0.8812

Note: В таблице приведены оцененные безусловные, совместные и условные вероятности для переменных *satisfied* и *choice*.

Таблица 31 Оцененные вероятности событий

6.5*. Для индивида с произвольными характеристиками оцените предельный эффект общей для двух уравнений переменной на вероятность того, что индивид удовлетворен игрой, при условии, что он играл за кошек

Запишите использовавшуюся для расчетов формулу. Протестируйте значимость этого предельного эффекта.

Считаем снова для Владимира.

$$P(satisfied_i = 1 | choice_i = 1) = \frac{\Phi_2(a_i, b_i; \rho)}{\Phi(b_i)}$$

$$z = \frac{\widehat{ME}_{age}}{\widehat{se}(\widehat{ME}_{age})}.$$

Предельный эффект возраста равен 0.0039, то есть при увеличении возраста на один год вероятность удовлетворённости игрой при условии выбора кошек возрастает примерно на 0.39 процентного пункта. Поскольку $p\text{-value} = 0.0001 < 0.05$, эффект статистически значим на уровне 5%.

Характеристика	Значение
age	22
male	1
design	1
cat	1
dog	0
choice	1
choice · age	22

Таблица 32 Характеристики выбранного индивида Владимира. Напоминание и доработка

Переменная	Условие	Условная вероятность	Предельный эффект	Стандартная ошибка
age	choice = 1	0.8812	0.0039***	0.0010

Note: Предельный эффект возраста рассчитан для выбранного индивида Владимира при условии $choice = 1$.

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 33 Предельный эффект возраста и проверка значимости

6.6*. Оцените средний эффект воздействия и средний эффект воздействия на подвергшихся воздействию прохождения игры за кошек на удовлетворенность игрой.

Протестируйте значимость этих эффектов воздействия. Объясните разницу между рассчитанными вами эффектами воздействия, а также, чем они отличаются от оцененного в предыдущем пункте предельного эффекта.

Эффект	Описание	Оценка	SE	z	p
ATE	Средний эффект воздействия по всей выборке	0.4843***	0.0461	10.5020	0.000
ATET	Средний эффект воздействия среди выбравших кошек	0.5204***	0.0676	7.6953	0.000

Note: ATE показывает средний эффект воздействия по всей выборке, а ATET показывает средний эффект воздействия среди игроков, фактически выбравших проживание за кошек.
Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 34 Средний эффект воздействия прохождения игры за кошек

6.7**. Замените в рассматриваемой системе бинарную переменную удовлетворенности игрой на порядковую «game».

Оцените по крайней мере два различных средних эффекта воздействия (самостоятельно сформулируйте эти средние эффекты воздействия и дайте их интерпретацию) и протестируйте их значимость.

Показатель	Значение
Метод оценивания	Maximum likelihood
Log-likelihood	-7370.4025
AIC	14768.8051
Количество наблюдений	5000

Таблица 35 Общая информация о совместной порядковой модели

Ordinal equation: choice				
Coefficients				
Переменная	Estimate	Std. Error	z value	Pr(> z)
age	0.0064254***	0.0012598	5.1005	3.387e-07
male	-0.2199059***	0.0371179	-5.9245	3.132e-09
design	0.5143619***	0.0694968	7.4012	1.350e-13
cat	0.5265283***	0.0424439	12.4053	< 2.2e-16
dog	0.5215195***	0.0389777	13.3799	< 2.2e-16
Thresholds				
Попор	Estimate	Std. Error	z value	Pr(> z)
cut1	0.752993***	0.062378	12.072	< 2.2e-16

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 36 Результаты оценки уравнения choice

Ordinal equation:				
game				
Coefficients				
Переменная	Estimate	Std. Error	z value	Pr(> z)
choice	1.7912***	0.18278	9.7994	< 2.2e-16
age	0.024748***	0.0072715	3.4034	0.0006654
$I(age^2)$	-0.00016656	0.000089192	-1.8675	0.0618368
male	-0.23118***	0.039546	-5.8458	5.042e-09
choice_age	0.00061201	0.0023115	0.2648	0.7911929
Thresholds				
Попор	Estimate	Std. Error	z value	Pr(> z)
cut1	0.66149***	0.16168	4.0913	4.289e-05
cut2	1.58485***	0.15308	10.3530	< 2.2e-16

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 37 Результаты оценки уравнения game

Параметр	Estimate	Std. Error	z value	Pr(> z)
cov(game, choice)	-0.28042*	0.12964	-2.1632	0.03053

Note: Отрицательная и статистически значимая корреляция указывает на наличие связи между ненаблюдаемыми компонентами уравнений game и choice.

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 38 Корреляция между порядковыми уравнениями

Эффект	Оценка	SE	Нижн. 95% ДИ	Верхн. 95% ДИ	p-value
ATE на $P(game = 2)$	0.617557***	0.045089	0.529184	0.7059	< 2.2e-16
ATE на $P(game = 0)$	-0.507874***	0.050449	-0.606751	-0.4090	< 2.2e-16

Note: Нулевая гипотеза: значение эффекта равно нулю. Стандартные ошибки рассчитаны дельта-методом.

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 39 Результаты тестов значимости эффектов воздействия

Эффект	Интерпретация	Оценка	SE	z	p
ATE на $P(game = 2)$	Эффект прохождения за кошек на вероятность высокой удовлетворенности	0.6176***	0.0451	13.6964	0.000
ATE на $P(game = 0)$	Эффект прохождения за кошек на вероятность низкой удовлетворенности	-0.5079***	0.0504	-10.0672	0.000

Note: Положительный эффект для $P(game = 2)$ означает рост вероятности высокой удовлетворенности при прохождении игры за кошек. Отрицательный эффект для $P(game = 0)$ означает снижение вероятности низкой удовлетворенности.

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Таблица 40 Средние эффекты воздействия прохождения игры за кошек

Часть 7. Сравнение моделей

7.1. Определите, какая из оцененных вами моделей лучше прогнозирует удовлетворенность игрой.

Модель	Доля верных прогнозов
Линейно-вероятностная модель	0.7784
Логит-модель	0.7750
Пробит-модель	0.7742
Гетероскедастичная пробит-модель	0.7742
Система бинарных уравнений	0.7690
Система с порядковой переменной game	0.7662
Наивный прогноз	0.7544

Note: Модели упорядочены по убыванию доли верных прогнозов. Наибольшую классификационную точность показывает линейно-вероятностная модель.

Таблица 41 Сравнение доли верных прогнозов моделей (Accuracy)

Здесь видим превосходство ЛВМ. Однако вспомним, что был ряд подозрений касемо причин данных результатов. Попробуем использовать метрику, дающую обоим классам одинаковую важность с точки зрения бизнеса.

Дополнительно для каждой модели был подобран оптимальный порог классификации, максимизирующий F1-score – своего рода метрика, которая предполагает, что оба класса для нас являются одинаково важными. В целом, стандартный порог 0.5 не обязательно является оптимальным с точки зрения баланса между precision и recall. Для каждой модели рассматривались пороги от 0.01 до 0.99, после чего выбирался порог, при котором F1-score достигал максимального значения. Результаты указаны ниже:

Модель	Оптимальный порог	Precision	Recall	F1-score
Логит-модель	0.38	0.7643	0.9870	0.8615
Система бинарных уравнений	0.32	0.7643	0.9870	0.8615
Система с порядковой переменной game	0.31	0.7643	0.9870	0.8615
Пробит-модель	0.44	0.7903	0.9454	0.8609
Гетероскедастичная пробит-модель	0.44	0.7903	0.9454	0.8609
Линейно-вероятностная модель	0.42	0.7753	0.9677	0.8608
Наивный прогноз	0.01	0.7544	1.0000	0.8600

Note: Модели упорядочены по убыванию значения F1-score. Оптимальный порог выбран для максимизации качества классификации.

Таблица 42 Сравнение моделей по оптимальному порогу и метрикам классификации

Полагаю, что мои догадки оказались верными. В альтернативном варианте сравнения ЛВМ оказывается позади всех прочих моделей, кроме наивного прогноза. А логит-модель достаточно логично занимает первое место с точки зрения метрики качества.

7.2. Выберите лучшую из оцененных вами моделей руководствуясь информационными критериями.

Систему бинарных уравнений лучше не сравнивать напрямую с одиночными пробит/логит по AIC/BIC, потому что её правдоподобие описывает совместное распределение двух переменных; систему с порядковой game тоже нельзя напрямую сравнивать с бинарными моделями, потому что там другая зависимая переменная. ЛВМ, конечно, тоже нежелательно, но всё же попробуем сравнить.

Модель	LogLik	Число параметров	AIC	BIC
Пробит-модель	-2166.761	6	4345.522	4384.626
Логит-модель	-2167.549	6	4347.099	4386.202
Гетероскедастичная пробит-модель	-2166.761	9	4351.522	4410.177
Линейно-вероятностная модель	-2204.622	7	4423.244	4468.864
Система бинарных уравнений	-5264.311	13	10554.622	10639.346
Система с порядковой переменной game	-7370.403	14	14768.805	14860.046

Note: Модели упорядочены по возрастанию AIC. Меньшие значения AIC и BIC указывают на более предпочтительную модель с учетом качества подгонки и числа параметров.

Таблица 43 Сравнение моделей по информационным критериям

Видим, что пробит- и логит-спецификации показывают себя лучше прочих моделей.

7.3. Руководствуясь информационным критерием Акаике и качеством вневыборочного прогноза (разделите выборку на тестовую и тренировочную части) определите оптимальные маргинальные распределения для случайных ошибок и копулу.**

Укажите, совпадают ли лучшие модели, выбранные по AIC и вневыборочному прогнозу. В данном задании рассмотрите по крайней мере 5 различных копул и две различные комбинации маргинальных распределений случайных ошибок. Результат представьте в форме таблицы.

Ответ:

Были оценены 10 моделей: 5 копул – Gaussian, Frank, Gumbel, Clayton, Joe – и 2 комбинации маргинальных распределений – probit-probit и logit-logit. Выборка была разделена на тренировочную и тестовую части в пропорции 70% / 30%.

Информационный критерий Акаике рассчитывался как:

$$AIC = -2\ln L + 2k.$$

По AIC лучшей является модель Frank + probit-probit, так как у неё минимальное значение:

$$AIC = 7367.032.$$

По вневыборочному прогнозу лучшими являются модели Gumbel + probit-probit, Clayton + probit-probit и Joe + probit-probit, так как они дают наибольшие значения:

$$Accuracy = 0.7747, F1 = 0.8593.$$

Следовательно, лучшие модели по AIC и по вневыборочному прогнозу не совпадают. Это связано с тем, что AIC оценивает внутривыборочную подгонку с учетом штрафа за сложность, а вневыборочный прогноз отражает качество предсказания на новых наблюдениях.

Копула	Маржинальные распределения	AIC на train	Accuracy на test	F1 на test
Frank	probit-probit	7367.032	0.7320	0.7947
Gaussian	probit-probit	7367.951	0.7380	0.8028
Frank	logit-logit	7369.095	0.7320	0.7947
Gaussian	logit-logit	7369.896	0.7400	0.8046
Gumbel	probit-probit	7382.697	0.7747	0.8593
Clayton	probit-probit	7382.697	0.7747	0.8593
Joe	probit-probit	7382.697	0.7747	0.8593
Gumbel	logit-logit	7384.806	0.7733	0.8577
Clayton	logit-logit	7384.806	0.7733	0.8577
Joe	logit-logit	7384.806	0.7733	0.8577

Note: Таблица сравнивает копула-модели по информационному критерию AIC на обучающей выборке и метрикам качества классификации на тестовой выборке. Меньшее значение AIC указывает на лучшую подгонку модели на train, а большие значения Accuracy и F1 — на более высокое качество прогноза на test.

Таблица 44 Сравнение копула-моделей по AIC и качеству прогноза

Часть 8. Модель бинарного выбора со случайными ошибками, имеющими распределение Стюдента

Рассмотрим распределение Стюдента с df степенями свободы, где df равняется сумме букв в ваших имени и фамилии.

Ответ:

$$df = 8 + 7 = 15$$

8.1*. Используя воображение придумайте и кратко опишите экономическую задачу, для решения которой необходимо применить модель бинарного выбора.**

Например, можно рассмотреть влияние различных факторов на вероятность дефолта банка. Укажите зависимую переменную и по крайней мере три независимых, а также кратко опишите предполагаемый механизм влияния независимых переменных на зависимую.

Ответ:

Рассмотрим задачу оценки вероятности оформления платной подписки после пробного периода.

Зависимая переменная:

$$subscribe_i = \begin{cases} 1, & \text{если пользователь оформил подписку,} \\ 0, & \text{иначе.} \end{cases}$$

Независимые переменные:

Переменная	Ожидаемое влияние	Обоснование
$income_i$	+	Более высокий доход снижает чувствительность к цене.
$hours_i$	+	Чем чаще пользователь использует сервис, тем выше ценность подписки.
$price_i$	—	Более высокая цена снижает вероятность покупки.

Модель:

$$subscribe_i^* = \beta_0 + \beta_1 income_i + \beta_2 hours_i + \beta_3 price_i + \varepsilon_i,$$

$$subscribe_i = 1, \text{ если } subscribe_i^* > 0.$$

Предполагаем:

$$\varepsilon_i \sim t(15).$$

8.2*. Симулируйте процесс генерации данных, соответствующий вашей задаче в логике бинарной модели со случайными ошибками, имеющими распределение Стьюдента**

(по аналогии с тем, как это делалось для обычной пробит модели для дефолта на семинаре). В тексте работы этот пункт отражать не нужно, достаточно реализовать его в коде. Все дальнейшие пункты выполняются на симулированных данных из выборки объемом 5000 наблюдений. Перед началом симуляций необходимо указать `set.seed(123)`.

Ответ:

Выполнил.

8.3*. Оцените параметры вашей модели с использованием бинарной модели со случайными ошибками, имеющими распределение Стьюдента с df степенями свободы.**

Результат представьте в форме таблицы, содержащей оценки коэффициентов и p-value тестов на значимость.

Переменная	Оценка	Стандартная ошибка	z-статистика	p-value
Константа	-1.5917	0.1494	-10.6526	0.0000
income	0.0095	0.0005	19.3319	0.0000
hours	0.1209	0.0087	13.8222	0.0000
price	-0.0019	0.0002	-12.0467	0.0000

Все коэффициенты статистически значимы на уровне 5%.

Коэффициент при *income* положителен, что соответствует предположению: пользователи с более высоким доходом чаще оформляют подписку. Коэффициент при *hours* также положителен: чем больше пользователь пользуется сервисом, тем выше вероятность подписки. Коэффициент при *price* отрицателен, то есть рост цены снижает вероятность оформления подписки.

8.4*. Напишите функцию, позволяющую рассчитывать предельный эффект на вероятность по произвольной непрерывной переменной в отношении индивида с произвольными характеристиками: для простоты переменными, входящими нелинейно, можно пренебречь.**

При помощи данной функции оцените предельный эффект произвольной непрерывной переменной на вероятность успеха для индивида с произвольными характеристиками.

Для расчёта был выбран индивид со следующими характеристиками:

income	hours	price
--------	-------	-------

90	8	700
----	---	-----

Предельный эффект был рассчитан для переменной *hours*.

Переменная	income	hours	price	Предельный эффект
hours	90	8	700	0.0251

Таким образом, для выбранного индивида увеличение времени использования сервиса на один час в неделю повышает вероятность оформления подписки примерно на 0.0251, то есть на 2.51 процентного пункта.

8.5*. Симулируйте процесс генерации данных таким образом, чтобы дисперсия случайной ошибки зависела по крайней мере от двух независимых переменных, одна из которых не входит в основное уравнение.**

Выполните одно задание на выбор: 1) Напишите функцию, осуществляющую LM тест на гомоскедастичность случайных ошибок в рамках вашей модели. Воспользуйтесь вашей функцией и опишите полученный результат. 2) Напишите функцию, при помощи которой можно оценить параметры модели бинарного выбора с гетероскедастичной случайной ошибкой, имеющей распределение Стьюдента с *df* степенями свободы. При помощи вашей функции и LR теста проверьте гипотезу о гомоскедастичности случайных ошибок.

Ответ:

Была симулирована выборка, где ошибка имеет вид:

$$\varepsilon_i = \sigma_i u_i, u_i \sim t(15),$$

$$\sigma_i = \exp(\gamma_1 hours_s_i + \gamma_2 student_i).$$

Переменная *hours_s* входит в уравнение дисперсии и связана с основной переменной *hours*, а *student* входит только в уравнение дисперсии.

Основное уравнение:

$$subscribe_i^* = \beta_0 + \beta_1 income_i + \beta_2 hours_i + \beta_3 price_i + \varepsilon_i.$$

В гетероскедастичной модели:

$$P(subscribe_i = 1 | x_i, w_i) = F_t\left(\frac{x_i \beta}{\exp(w_i \gamma)}; 15\right).$$

Результаты оценки:

Уравнение	Переменная	Оценка
Основное	Константа	-1.5103
Основное	income	0.0090
Основное	hours	0.1213
Основное	price	-0.0018
Дисперсии	hours_s	0.0932

Дисперсии	student	0.2780
-----------	---------	--------

Проверим гипотезу:

$$H_0: \gamma_{hours} = 0, \gamma_{student} = 0,$$

H_1 : хотя бы один коэффициент не равен нулю.

$$LR = 2(\ln L_{UR} - \ln L_R) \xrightarrow{a} \chi^2(2).$$

Тест	$\ln L_R$	$\ln L_{UR}$	LR	df	p-value
Гомоскедастичность t-модели	-2253.564	-2235.462	36.2025	2	0.0000

Так как $p\text{-value} < 0.05$, гипотеза о гомоскедастичности отвергается. Следовательно, дисперсия ошибки статистически значимо зависит от $hours_s$ и $student$.

8.6*. Повторите предыдущие пункты, предполагая, что степени свободы df не фиксированы, а являются оцениваемым параметром.**

При этом для идентифицируемости параметров необходимо стандартизировать распределение Стьюдента таким образом, чтобы дисперсия случайной ошибки равнялась 1, независимо от числа степеней свободы df. Подсказка: посмотрите функцию pt0 в пакете mnrm через help(pt0).

Ответ:

Не выполнено.