

Федеральное государственное автономное образовательное
учреждение высшего образования
Национальный исследовательский университет «Высшая школа экономики»
Факультет экономических наук
Образовательная программа «Экономика и экономическая политика»
Образовательный трек «Количественные методы в экономике и финансах»

Микроэконометрика качественных данных

Домашнее задание №2:

**«Модель Тобина. Модель Хекмана. Мо-
дель Ньюи. Модель с усечением по центру»**

Домашнее задание студента 1 курса направления 38.04.01 – Экономика
Группа МЭКЭП251

СМИРНОВА Владимира Евгеньевича

Лектор и семинарист:
Доцент: Факультет экономических наук,
Департамент прикладной экономики
ПОТАНИН Богдан Станиславович

Содержание

Часть 1.	Теория и гипотезы	3
1.1.	Выберите независимые переменные для уравнения зарплаты и уравнения занятости	3
Часть 2.	Модель Тобина	8
2.1.	Оцените Тобит модель, предварительно записав максимизируемую функцию правдоподобия. Результат представьте в форме таблицы	8
2.2.	Опишите преимущества Тобит модели над усеченной регрессией. Объясните, в каких случаях можно использовать усеченную регрессию, но не получится использовать Тобит модель: приведите гипотетический пример	10
2.3.	Проинтерпретируйте полученные значения оценок для каждой независимой переменной. Поясните, как полученные результаты соотносятся с высказанными вами ранее предположениями	11
2.4.	Расчёт характеристик для произвольного индивида	12
2.5.	Расчёт предельного эффекта для произвольного индивида	15
2.6.	Добавьте в модель нелинейный эффект. Повторите предыдущий пункт для переменной, имеющей нелинейный эффект	17
2.7.	LR-тест на гомоскедастичность в Тобит-модели	20
2.8.	Предельные эффекты в гетероскедастичной Тобит-модели	23
Часть 3.	Модель Хекмана	28
3.1.	Оцените модель Хекмана с помощью метода максимального правдоподобия, предварительно записав максимизируемую функцию правдоподобия и указав независимые переменные в уравнении занятости, которое должно иметь по крайней мере одну переменную, не входящую в уравнение зарплаты. Результат представьте в форме таблицы	28
3.2.	Опишите отличия модели Хекмана от модели Тобина	30
3.3.	Воспользуйтесь методом Хекмана, основанным на двухшаговой процедуре, и сравните оценки с полученными с использованием метода Хекмана, основанного на методе максимального правдоподобия. Опишите относительные преимущества и недостатки обоих методов	31
3.4.	Проинтерпретируйте значимость и значение оценки корреляции между случайными ошибками в обоих оцененных моделях. Укажите, можно ли было бы обойтись оцениванием обычной МНК модели	34
3.5.	Условные ожидания и предельные эффекты в модели Хекмана	35

Часть 4. Модель Ньюи	40
4.1. Опишите преимущества и недостатки метода Ньюи по сравнению с методом Хекмана	40
4.2. Взяв за основу любую модель бинарного выбора, произвольную сглаживающую функцию и используя leave-one-out кросс-валидацию для подбора степени полинома, оцените модель Ньюи, описав осуществленные для ее построения шаги. Результат представьте в форме таблицы, содержащей оценки и бутстрапированные стандартные ошибки. Сравните оценки модели Ньюи и моделей Хекмана, основанных на двухшаговой процедуре и ММП	41
Часть 4.1. Модель Хекмана и модель Ньюи. Логарифмированная целевая переменная	45
Часть 5. Модель с усечением по центру	50
5.1. Самостоятельно реализуйте модель усечённой регрессии, в которой значения зависимой переменной не наблюдаются в случае, когда зависимая переменная попадает в интервал (a, b) . Придумайте сюжет, в котором применяется такая модель и реализуйте его на симулированных данных. Затем продемонстрируйте, что ваша модель корректно оценивает регрессионные коэффициенты, а также рассчитайте стандартные ошибки оценок параметров модели	50
5.2. Напишите функцию, позволяющую оценивать условное математическое ожидание зависимой переменной в вашей модели, и продемонстрируйте её применение на конкретном примере	53

Часть 1. Теория и гипотезы

1.1. Выберите независимые переменные для уравнения заработной платы и уравнения занятости

Ответ:

В данной работе рассматривается влияние различных факторов на заработную плату женщин с учётом неслучайного отбора в число занятых. Используются два уравнения: уравнение заработной платы и уравнение занятости.

В уравнении заработной платы зависимой переменной выступает `wage` – часовая заработная плата женщины. В уравнении занятости зависимой переменной выступает `lfp` – бинарная переменная участия женщины в рабочей силе, где `lfp = 1`, если женщина работает / участвует в рабочей силе, и `lfp = 0`, если не работает / не участвует.

Для уравнения заработной платы были выбраны переменные `educ`, `exper` и `age`. Для

уравнения занятости были выбраны переменные `age`, `kids5` и `nwifeinc`. Таким образом, переменная `age` входит в оба уравнения и является общей непрерывной переменной. При этом переменные `kids5` и `nwifeinc` входят только в уравнение занятости, что соответствует требованию (в рамках задания) о наличии хотя бы одной переменной, которая присутствует в уравнении занятости, но отсутствует в уравнении заработной платы.

Переменная	<code>wage</code>
Уравнение	Уравнение заработной платы
Формат включения в спецификацию	Зависимая переменная
Причина включения в спецификацию	Переменная отражает часовую заработную плату женщины. Именно заработная плата является основным изучаемым исходом в данной работе.
Предполагаемое направление эффекта	—

Переменная	<code>lfp</code>
Уравнение	Уравнение занятости
Формат включения в спецификацию	Зависимая бинарная переменная
Причина включения в спецификацию	Переменная отражает участие женщины в рабочей силе: <code>lfp = 1</code> , если женщина работает / участвует в рабочей силе, и <code>lfp = 0</code> , если не работает / не участвует. Данная переменная используется для моделирования правила отбора, поскольку заработная плата фактически наблюдается только для женщин, находящихся в числе занятых.
Предполагаемое направление эффекта	Для зависимой переменной направление эффекта не указывается.

Переменная	educ
Уравнение	Уравнение зарплаты
Формат включения в спецификацию	Непрерывная переменная, включается в модель в исходном виде
Причина включения в спецификацию	Образование является одним из основных показателей человеческого капитала. Более высокий уровень образования может быть связан с большей производительностью, квалификацией и доступом к более оплачиваемым рабочим местам.
Предполагаемое направление эффекта	Положительный эффект (+). Ожидается, что увеличение числа лет образования повышает часовую заработную плату женщины.

Переменная	exper
Уравнение	Уравнение зарплаты
Формат включения в спецификацию	Непрерывная переменная, включается в модель в исходном виде
Причина включения в спецификацию	Опыт работы отражает накопление профессиональных навыков и практического человеческого капитала. Женщины с большим опытом могут иметь более высокую производительность и, следовательно, более высокую заработную плату.
Предполагаемое направление эффекта	Положительный эффект (+). Ожидается, что увеличение опыта работы повышает заработную плату.

Переменная	age
Уравнение	Уравнение зарплаты и уравнение занятости
Формат включения в спецификацию	Непрерывная переменная, включается в оба уравнения в исходном виде
Причина включения в спецификацию	Возраст может отражать положение женщины в жизненном цикле, накопленные характеристики и связь с рынком труда. Включение age в оба уравнения также удобно содержательно, поскольку возраст может быть связан как с уровнем заработной платы, так и с вероятностью занятости.
Предполагаемое направление эффекта	Неоднозначный эффект. В уравнении зарплаты возраст может быть положительно связан с накопленными характеристиками, но при контроле за опытом эффект может быть слабым или неоднозначным. В уравнении занятости возраст также может иметь неоднозначный эффект, – с одной стороны, более старшие женщины могут быть устойчивее связаны с рынком труда, с другой стороны, участие в рабочей силе может снижаться на более поздних этапах жизненного цикла.

Переменная	kids5
Уравнение	Уравнение занятости
Формат включения в спецификацию	Дискретная переменная, включается в модель в исходном виде
Причина включения в спецификацию	Переменная показывает число детей младше 5 лет. Наличие маленьких детей увеличивает домашнюю нагрузку и издержки выхода на рынок труда, например, из-за необходимости ухода за ребёнком. Поэтому данная переменная должна быть важна именно для решения о занятости.
Предполагаемое направление эффекта	Отрицательный эффект (-). Ожидается, что увеличение числа маленьких детей снижает вероятность занятости женщины.

Переменная	nwifeinc
Уравнение	Уравнение занятости
Формат включения в спецификацию	Непрерывная переменная, включается в модель в исходном виде
Причина включения в спецификацию	Переменная отражает семейный доход за вычетом дохода женщины. Чем выше доход семьи без учёта заработка женщины, тем ниже финансовая необходимость выхода женщины на рынок труда. Поэтому переменная содержательно подходит для объяснения решения работать или не работать.
Предполагаемое направление эффекта	Отрицательный эффект (-). Ожидается, что рост семейного дохода без дохода женщины снижает вероятность её занятости.

Итоговая спецификация уравнения зарплаты имеет вид:

$$wage_i^* = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 age_i + \varepsilon_i,$$

где:

- i – индекс женщины, то есть номер наблюдения в выборке;
- $wage_i^*$ – потенциальная часовая заработная плата i -й женщины;
- $educ_i$ – число лет образования i -й женщины;
- $exper_i$ – опыт работы i -й женщины;
- age_i – возраст i -й женщины;
- $\beta_0, \beta_1, \beta_2, \beta_3$ – оцениваемые параметры уравнения зарплаты;
- ε_i – случайная ошибка уравнения зарплаты.

Итоговая спецификация уравнения занятости имеет вид:

$$lfp_i^* = \gamma_0 + \gamma_1 age_i + \gamma_2 kids5_i + \gamma_3 nwifeinc_i + u_i,$$

$$lfp_i = \begin{cases} 1, & \text{если } lfp_i^* > 0, \\ 0, & \text{если } lfp_i^* \leq 0. \end{cases}$$

где:

- lfp_i^* – латентная склонность i -й женщины к участию в рабочей силе;
- lfp_i – наблюдаемая бинарная переменная занятости / участия в рабочей силе;

- age_i – возраст i -й женщины;
- $kids5_i$ – число детей младше 5 лет у i -й женщины;
- $nwifeinc_i$ – семейный доход i -й женщины за вычетом её собственного дохода;
- $\gamma_0, \gamma_1, \gamma_2, \gamma_3$ – оцениваемые параметры уравнения занятости;
- u_i – случайная ошибка уравнения занятости.

Часть 2. Модель Тобина

2.1. Оцените Тобит модель, предварительно записав максимизируемую функцию правдоподобия. Результат представьте в форме таблицы

Ответ:

Так как для неработающих женщин в данных значение заработной платы равно нулю, переменная **wage** рассматривается как цензурированная снизу в точке 0.

Предположим, что существует латентная переменная заработной платы:

$$wage_i^* = x_i\beta + \varepsilon_i,$$

где

$$x_i\beta = \beta_0 + \beta_1educ_i + \beta_2exper_i + \beta_3age_i,$$

$$\varepsilon_i \sim N(0, \sigma^2).$$

Наблюдаемая заработная плата задаётся правилом цензурирования (слева):

$$wage_i = \begin{cases} 0, & \text{если } wage_i^* \leq 0, \\ wage_i^*, & \text{если } wage_i^* > 0. \end{cases}$$

Для наблюдений с $wage_i = 0$ вклад в функцию правдоподобия равен вероятности того, что латентная заработная плата не превышает точку цензурирования:

$$P(wage_i^* \leq 0 \mid x_i) = \Phi\left(\frac{-x_i\beta}{\sigma}\right).$$

Для наблюдений с $wage_i > 0$ вклад в функцию правдоподобия задаётся плотностью нормального распределения:

$$f(wage_i | x_i) = \frac{1}{\sigma} \varphi \left(\frac{wage_i - x_i \beta}{\sigma} \right).$$

Следовательно, максимизируемая функция правдоподобия имеет вид:

$$L(\beta, \sigma) = \prod_{i:wage_i=0} \Phi \left(\frac{-x_i \beta}{\sigma} \right) \prod_{i:wage_i>0} \frac{1}{\sigma} \varphi \left(\frac{wage_i - x_i \beta}{\sigma} \right).$$

Логарифм функции правдоподобия:

$$\ln L(\beta, \sigma) = \sum_{i:wage_i=0} \ln \Phi \left(\frac{-x_i \beta}{\sigma} \right) + \sum_{i:wage_i>0} \left[-\ln \sigma + \ln \varphi \left(\frac{wage_i - x_i \beta}{\sigma} \right) \right].$$

Оцениваемая спецификация имеет вид:

$$wage_i^* = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 age_i + \varepsilon_i.$$

Оценивание выполнено методом максимального правдоподобия. Результаты представлены в Table 1.

Таблица 1: Результаты оценки Тобит-модели для часовой заработной платы

<i>Dependent variable:</i>				
wage				
Standardized residuals				
Min	1Q	Median	3Q	Max
-1.5320	-0.0145	0.3067	0.6916	5.9192
Coefficients: location model				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-4.9044***	1.4679	-3.3412	0.0008
educ	0.6296***	0.0807	7.8039	6.004e-15
exper	0.2293***	0.0247	9.2894	< 2.2e-16
age	-0.1071***	0.0249	-4.3012	1.699e-05
Scale model with log link				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.4974***	0.0369	40.5395	< 2.2e-16
Качество модели				
Тип модели				Tobit model
Распределение случайной ошибки				Gaussian
Точка левого цензурирования				0
Число наблюдений				753
Число оцениваемых параметров				5
Оценка σ				4.4701
Log-likelihood				-1462.673
AIC				2935.347
BIC				2958.467
Число итераций BFGS				20
<i>Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1</i>				

Согласно таблице (Table 1), все переменные в уравнении латентной заработной платы статистически значимы на уровне значимости 1%. Коэффициент при **educ** положителен и равен 0.6296, что означает положительную связь между числом лет образования и латентной часовой заработной платой. Коэффициент при **exper** также

положителен и равен 0.2293, то есть больший опыт работы связан с более высокой латентной заработной платой. Коэффициент при `age` отрицателен и равен -0.1071. Это означает, что при контроле за образованием и опытом работы более высокий возраст связан с меньшим значением латентной заработной платы. Оценка стандартного отклонения случайной ошибки составляет $\hat{\sigma} = 4.4701$, а значение логарифма правдоподобия равно -1462.673 .

2.2. Опишите преимущества Тобит модели над усеченной регрессией. Объясните, в каких случаях можно использовать усеченную регрессию, но не получится использовать Тобит модель: приведите гипотетический пример

Ответ:

Главное различие между Тобит-моделью и усечённой регрессией состоит в том, что в Тобит-модели наблюдения, попавшие в область цензурирования, сохраняются в выборке, но зависимая переменная фиксируется на пороговом значении. В усечённой регрессии такие наблюдения вообще отсутствуют в данных.

В рассматриваемой задаче мы наблюдаем как работающих, так и неработающих женщин. Для работающих женщин заработная плата положительна, а для неработающих значение `wage` равно 0. Следовательно, неработающие женщины не исчезают из выборки, а остаются в ней с нулевой заработной платой. Поэтому здесь естественно использовать Тобит-модель: она учитывает и положительные значения заработной платы, и факт нахождения части наблюдений в точке цензурирования.

Содержательно Тобит-модель задаётся следующим образом:

$$y_i^* = x_i\beta + \varepsilon_i,$$

$$y_i = \begin{cases} 0, & \text{если } y_i^* \leq 0, \\ y_i^*, & \text{если } y_i^* > 0. \end{cases}$$

То есть для всех индивидов наблюдается y_i , но для части индивидов оно принимает значение порога цензурирования. Преимущество Тобит-модели над усечённой регрессией состоит в том, что она использует больше информации: не только значения заработной платы среди работающих женщин, но и информацию о том, какие женщины имеют нулевую заработную плату. Если бы мы оценивали усечённую регрессию только по женщинам с `wage > 0`, то потеряли бы информацию о неработающих женщинах и о факторах, связанных с нулевой заработной платой.

В усечённой регрессии зависимая переменная наблюдается только при выполнении некоторого условия, например:

$y_i = y_i^*$ наблюдается только если $y_i^* > c$.

Если $y_i^* \leq c$, то индивид не получает значение c , а полностью отсутствует в выборке. Поэтому усечённая регрессия нужна тогда, когда у исследователя нет наблюдений в точке цензурирования и неизвестны характеристики индивидов, не попавших в выборку.

Например, представим исследование расходов клиентов на премиальную доставку еды. Пусть в базе сервиса сохраняются только заказы на сумму не менее 3000 рублей, а заказы на меньшую сумму не попадают в аналитическую базу. Тогда исследователь наблюдает только клиентов с расходами выше 3000 рублей. Клиенты с меньшими потенциальными расходами отсутствуют в данных, и неизвестно, сколько их было и какими характеристиками они обладали. В такой ситуации Тобит-модель использовать некорректно, потому что нет наблюдаемой массы на пороге 3000 рублей. Здесь более уместна усечённая регрессия.

Аналогично, если исследователь имеет данные только по работникам компании и не наблюдает неработающих людей вообще, то Тобит-модель использовать нельзя: неработающие индивиды не присутствуют в выборке с нулевой зарплатой, а полностью отсутствуют в данных. В этом случае при наличии известного правила попадания в выборку можно использовать усечённую регрессию.

2.3. Проинтерпретируйте полученные значения оценок для каждой независимой переменной. Поясните, как полученные результаты соотносятся с высказанными вами ранее предположениями

Ответ:

В оценённой Тобит-модели зависимой переменной является часовая заработная плата $wage$, цензурированная снизу в точке 0. Поэтому коэффициенты модели интерпретируются как влияние независимых переменных на латентную заработную плату $wage_i^*$, а не напрямую на наблюдаемую заработную плату $wage_i$. Иными словами, полученные оценки показывают, как переменные связаны с потенциальной часовой заработной платой женщины до учёта цензурирования.

Оценённая спецификация имеет вид:

$$wage_i^* = -4.9044 + 0.6296 educ_i + 0.2293 exper_i - 0.1071 age_i + \varepsilon_i.$$

Коэффициент при переменной $educ$ равен 0.6296 и статистически значим на уровне 1%. Это означает, что при прочих равных условиях увеличение образования женщины на один год связано с увеличением латентной часовой заработной

платы примерно на 0.6296 денежных единиц. Полученный знак коэффициента положительный, что соответствует предварительной гипотезе: более высокий уровень образования должен повышать заработную плату, поскольку образование отражает человеческий капитал, квалификацию и доступ к более оплачиваемым рабочим местам.

Коэффициент при переменной *exper* равен 0.2293 и также статистически значим на уровне 1%. Это означает, что при прочих равных условиях увеличение опыта работы на один год связано с увеличением латентной часовой заработной платы примерно на 0.2293 денежных единиц. Полученный результат также соответствует предварительной гипотезе. Опыт работы отражает накопление профессиональных навыков, специфического человеческого капитала и практических компетенций, поэтому его положительная связь с заработной платой является содержательно ожидаемой.

Коэффициент при переменной *age* равен -0.1071 и статистически значим на уровне 1%. Это означает, что при прочих равных условиях увеличение возраста женщины на один год связано со снижением латентной часовой заработной платы примерно на 0.1071 денежных единиц. В предварительных гипотезах эффект возраста рассматривался как неоднозначный: с одной стороны, возраст может отражать накопленные характеристики и положение на рынке труда, с другой стороны, при контроле за фактическим опытом работы и образованием его эффект может быть слабым или отрицательным. Полученный отрицательный знак можно объяснить тем, что в модели уже контролируются образование и опыт работы. Поэтому переменная *age* отражает не столько накопленный трудовой опыт, сколько прочие возрастные и когортные различия. При одинаковом уровне образования и одинаковом опыте более старший возраст может быть связан с меньшей латентной заработной платой, например, из-за перерывов в карьере, меньшей интенсивности участия в рынке труда или различий между поколениями женщин.

Таким образом, результаты по переменным *educ* и *exper* полностью согласуются с первоначальными предположениями, так как оба фактора положительно и статистически значимо связаны с латентной заработной платой. Результат по переменной *age* показывает отрицательный и статистически значимый эффект.

Важно подчеркнуть, что данные коэффициенты не являются предельными эффектами на наблюдаемую заработную плату $wage_i$. В данном пункте они интерпретируются именно как эффекты на латентную заработную плату $wage_i^*$.

2.4. Расчёт характеристик для произвольного индивида

Для индивида с произвольными характеристиками укажите, предварительно записав используемые для расчётов формулы:

А) $E(y^*)$

Б) $E(y)$

В) вероятность того, что индивид работает

Ответ:

Рассмотрим женщину со следующими характеристиками:

$$educ = 12, \quad exper = 10, \quad age = 40.$$

Ранее была оценена Тобит-модель:

$$wage_i^* = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 age_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2).$$

$$wage_i = \begin{cases} 0, & \text{если } wage_i^* \leq 0, \\ wage_i^*, & \text{если } wage_i^* > 0. \end{cases}$$

Оценки параметров:

$$\hat{\beta}_0 = -4.9044, \quad \hat{\beta}_{educ} = 0.6296, \quad \hat{\beta}_{exper} = 0.2293, \quad \hat{\beta}_{age} = -0.1071, \quad \hat{\sigma} = 4.4701.$$

Линейный индекс для выбранного индивида:

$$\hat{\mu}_i = x_i \hat{\beta} = -4.9044 + 0.6296 \cdot 12 + 0.2293 \cdot 10 - 0.1071 \cdot 40 \approx 0.6620.$$

Также:

$$\frac{\hat{\mu}_i}{\hat{\sigma}} = \frac{0.6620}{4.4701} \approx 0.1481, \quad \Phi(0.1481) \approx 0.5589, \quad \varphi(0.1481) \approx 0.3946.$$

А) Математическое ожидание латентной заработной платы

Так как $E(\varepsilon_i) = 0$, то:

$$E(wage_i^* | x_i) = x_i \beta.$$

Следовательно:

$$\hat{E}(wage_i^* | x_i) = \hat{\mu}_i = 0.6620.$$

Б) Математическое ожидание наблюдаемой заработной платы

Для Тобит-модели с левым цензурированием в нуле:

$$E(wage_i | x_i) = \Phi\left(\frac{x_i\beta}{\sigma}\right) x_i\beta + \sigma\varphi\left(\frac{x_i\beta}{\sigma}\right).$$

Подставляя оценки, получаем:

$$\hat{E}(wage_i | x_i) = 0.5589 \cdot 0.6620 + 4.4701 \cdot 0.3946 \approx 2.1338.$$

В) Вероятность того, что индивид работает

В логике Тобит-модели вероятность работы интерпретируется как вероятность положительной заработной платы:

$$P(wage_i > 0 | x_i) = P(wage_i^* > 0 | x_i) = \Phi\left(\frac{x_i\beta}{\sigma}\right).$$

Для выбранного индивида:

$$\hat{P}(wage_i > 0 | x_i) = \Phi(0.1481) \approx 0.5589.$$

Таблица 2: Прогнозные величины Тобит-модели для индивида с произвольными характеристиками

<i>Model: Tobit</i>		
Dependent variable: wage		
Характеристики индивида		
Переменная	Значение	Описание
educ	12	число лет образования женщины
exper	10	опыт работы женщины
age	40	возраст женщины
Расчетные величины		
Показатель	Значение	Описание
$\hat{\mu}_i = x_i\hat{\beta}$	0.6620	линейный индекс
$\hat{\mu}_i/\hat{\sigma}$	0.1481	стандартизированный индекс
$\Phi(\hat{\mu}_i/\hat{\sigma})$	0.5589	вероятность положительной заработной платы
$\varphi(\hat{\mu}_i/\hat{\sigma})$	0.3946	плотность стандартного нормального распределения
Итоговые прогнозы		
Показатель	Значение	Интерпретация
$\hat{E}(wage_i^* x_i)$	0.6620	ожидаемая латентная часовая заработная плата
$\hat{E}(wage_i x_i)$	2.1338	ожидаемая наблюдаемая часовая заработная плата
$\hat{P}(wage_i > 0 x_i)$	0.5589	вероятность положительной заработной платы / работы

Итак, для женщины с 12 годами образования, 10 годами опыта работы и возрастом 40 лет ожидаемая латентная часовая заработная плата составляет 0.6620, ожидаемая наблюдаемая часовая заработная плата составляет 2.1338, а вероятность положительной заработной платы / работы равна 0.5589, или примерно 55.89%.

2.5. Расчёт предельного эффекта для произвольного индивида

Для индивида с произвольными характеристиками рассчитайте предельный эффект любой переменной (не дамми), входящей линейно, на:

А) $E(y^*)$

Б) $E(y)$

В) вероятность того, что индивид работает

Ответ:

Рассчитаем предельные эффекты для переменной `exper`, то есть для опыта работы женщины. Используем того же индивида:

$$educ = 12, \quad exper = 10, \quad age = 40.$$

Из предыдущего пункта:

$$\hat{\beta}_{exper} = 0.2293, \quad \hat{\sigma} = 4.4701, \quad \hat{\mu}_i = 0.6620, \quad \frac{\hat{\mu}_i}{\hat{\sigma}} = 0.1481,$$

$$\Phi\left(\frac{\hat{\mu}_i}{\hat{\sigma}}\right) = 0.5589, \quad \varphi\left(\frac{\hat{\mu}_i}{\hat{\sigma}}\right) = 0.3946.$$

А) **Предельный эффект `exper` на $E(wage_i^*)$**

Для латентной переменной:

$$E(wage_i^* | x_i) = x_i \beta.$$

Поэтому предельный эффект переменной `exper` равен коэффициенту при ней:

$$\frac{\partial E(wage_i^* | x_i)}{\partial exper_i} = \beta_{exper}.$$

Следовательно:

$$\frac{\partial \hat{E}(wage_i^* | x_i)}{\partial exper_i} = 0.2293.$$

Б) **Предельный эффект `exper` на $E(wage_i)$**

Для наблюдаемой заработной платы:

$$\frac{\partial E(wage_i | x_i)}{\partial exper_i} = \Phi\left(\frac{x_i\beta}{\sigma}\right) \beta_{exper}.$$

Подставляя оценки:

$$\frac{\partial \hat{E}(wage_i | x_i)}{\partial exper_i} = 0.5589 \cdot 0.2293 \approx 0.1281.$$

Этот эффект меньше эффекта на латентную заработную плату, поскольку наблюдаемая заработная плата цензурирована снизу в нуле.

В) Предельный эффект exper на вероятность того, что индивид работает

Вероятность положительной заработной платы равна:

$$P(wage_i > 0 | x_i) = \Phi\left(\frac{x_i\beta}{\sigma}\right).$$

Тогда предельный эффект:

$$\frac{\partial P(wage_i > 0 | x_i)}{\partial exper_i} = \varphi\left(\frac{x_i\beta}{\sigma}\right) \frac{\beta_{exper}}{\sigma}.$$

Подставляя оценки:

$$\frac{\partial \hat{P}(wage_i > 0 | x_i)}{\partial exper_i} = 0.3946 \cdot \frac{0.2293}{4.4701} \approx 0.0202.$$

Таблица 3: Предельные эффекты переменной `exper` в Тобит-модели

<i>Model: Tobit</i>		
Dependent variable: wage		
Используемые расчетные величины		
Показатель	Значение	Описание
$\hat{\beta}_{exper}$	0.2293	коэффициент при <code>exper</code>
$\hat{\sigma}$	4.4701	стандартное отклонение ошибки
$\hat{\mu}_i = x_i\hat{\beta}$	0.6620	линейный индекс
$\Phi(\hat{\mu}_i/\hat{\sigma})$	0.5589	вероятность положительной заработной платы
$\varphi(\hat{\mu}_i/\hat{\sigma})$	0.3946	плотность стандартного нормального распределения
Предельные эффекты		
Показатель	Значение	Формула
Эффект на $E(wage_i^* x_i)$	0.2293	$\hat{\beta}_{exper}$
Эффект на $E(wage_i x_i)$	0.1281	$\Phi(\hat{\mu}_i/\hat{\sigma})\hat{\beta}_{exper}$
Эффект на $P(wage_i > 0 x_i)$	0.0202	$\varphi(\hat{\mu}_i/\hat{\sigma})\hat{\beta}_{exper}/\hat{\sigma}$

Итак, для выбранного индивида увеличение опыта работы на один год увеличивает ожидаемую латентную часовую заработную плату на 0.2293, ожидаемую наблюдаемую часовую заработную плату на 0.1281, а вероятность положительной заработной платы / работы – примерно на 0.0202, то есть на 2.02 процентного пункта.

2.6. Добавьте в модель нелинейный эффект. Повторите предыдущий пункт для переменной, имеющей нелинейный эффект

Ответ:

Добавим в Тобит-модель квадратичный эффект опыта работы. Итоговая спецификация имеет вид:

$$wage_i^* = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 exper_i^2 + \beta_4 age_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2).$$

Наблюдаемая заработная плата задаётся правилом левого цензурирования:

$$wage_i = \begin{cases} 0, & \text{если } wage_i^* \leq 0, \\ wage_i^*, & \text{если } wage_i^* > 0. \end{cases}$$

Результаты оценки Тобит-модели с квадратичным эффектом опыта представлены в Table 4.

Таблица 4: Результаты оценки Тобит-модели с нелинейным эффектом опыта

Dependent variable:				
wage				
Standardized residuals				
Min	1Q	Median	3Q	Max
-1.3167	-0.0342	0.3214	0.7157	6.0472
Coefficients: location model				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-6.4161***	1.5240	-4.2101	2.553e-05
educ	0.6114***	0.0804	7.6046	2.860e-14
exper	0.4536***	0.0678	6.6875	2.270e-11
$I(exper^2)$	-0.0077***	0.0021	-3.5927	0.0003
age	-0.0909***	0.0251	-3.6172	0.0003
Scale model with log link				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.4906***	0.0369	40.4126	< 2.2e-16
Качество модели				
Тип модели	Tobit model			
Нелинейный эффект	$exper^2$			
Распределение случайной ошибки	Gaussian			
Точка левого цензурирования	0			
Число наблюдений	753			
Число оцениваемых параметров	6			
Оценка σ	4.4399			
Log-likelihood	-1456.076			
AIC	2924.152			
BIC	2951.896			
Число итераций BFGS	23			
Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1				

Коэффициент при **exper** положителен, а коэффициент при $exper^2$ отрицателен. Оба коэффициента статистически значимы. Следовательно, опыт работы положительно связан с латентной заработной платой, но отдача от опыта убывает по мере его роста.

Рассчитаем предельные эффекты для женщины со следующими характеристиками:

$$educ = 12, \quad exper = 10, \quad age = 40.$$

Для выбранного индивида по оценённой модели:

$$\hat{\mu}_i = x_i \hat{\beta} = 1.0561, \quad \hat{\sigma} = 4.4399, \quad \frac{\hat{\mu}_i}{\hat{\sigma}} = 0.2379.$$

Также:

$$\Phi\left(\frac{\hat{\mu}_i}{\hat{\sigma}}\right) = 0.5940, \quad \varphi\left(\frac{\hat{\mu}_i}{\hat{\sigma}}\right) = 0.3878.$$

Так как опыт входит в модель нелинейно, его предельное влияние на линейный индекс равно:

$$\frac{\partial \mu_i}{\partial \text{exper}_i} = \beta_{\text{exper}} + 2\beta_{\text{exper}^2} \text{exper}_i.$$

Для выбранного индивида:

$$\frac{\partial \hat{\mu}_i}{\partial \text{exper}_i} = 0.4536 + 2 \cdot (-0.0077) \cdot 10 \approx 0.3004.$$

Тогда предельные эффекты рассчитываются следующим образом:

$$\frac{\partial E(\text{wage}_i^* | x_i)}{\partial \text{exper}_i} = \beta_{\text{exper}} + 2\beta_{\text{exper}^2} \text{exper}_i = 0.3004.$$

$$\frac{\partial E(\text{wage}_i | x_i)}{\partial \text{exper}_i} = \Phi\left(\frac{\mu_i}{\sigma}\right) (\beta_{\text{exper}} + 2\beta_{\text{exper}^2} \text{exper}_i) = 0.5940 \cdot 0.3004 \approx 0.1784.$$

$$\frac{\partial P(\text{wage}_i > 0 | x_i)}{\partial \text{exper}_i} = \varphi\left(\frac{\mu_i}{\sigma}\right) \frac{\beta_{\text{exper}} + 2\beta_{\text{exper}^2} \text{exper}_i}{\sigma} = 0.3878 \cdot \frac{0.3004}{4.4399} \approx 0.0262.$$

Итоговые расчёты представлены в Table 5.

Таблица 5: Предельные эффекты переменной **exper** в Тобит-модели с нелинейным эффектом опыта

<i>Model: Tobit with nonlinear effect</i>		
Dependent variable: wage		
Характеристики индивида		
Переменная	Значение	Описание
educ	12	число лет образования женщины
exper	10	опыт работы женщины
age	40	возраст женщины
Используемые расчетные величины		
Показатель	Значение	Описание
$\hat{\sigma}$	4.4399	стандартное отклонение ошибки
$\hat{\mu}_i = x_i \hat{\beta}$	1.0561	линейный индекс
$\hat{\mu}_i / \hat{\sigma}$	0.2379	стандартизированный индекс
$\Phi(\hat{\mu}_i / \hat{\sigma})$	0.5940	вероятность положительной заработной платы
$\varphi(\hat{\mu}_i / \hat{\sigma})$	0.3878	плотность стандартного нормального распределения
$\partial \hat{\mu}_i / \partial \text{exper}_i$	0.3004	производная линейного индекса по опыту
Предельные эффекты		
Показатель	Значение	Формула
Эффект на $E(\text{wage}_i^* x_i)$	0.3004	$\hat{\beta}_{\text{exper}} + 2\hat{\beta}_{\text{exper}^2} \text{exper}_i$
Эффект на $E(\text{wage}_i x_i)$	0.1784	$\Phi(\hat{\mu}_i / \hat{\sigma})(\hat{\beta}_{\text{exper}} + 2\hat{\beta}_{\text{exper}^2} \text{exper}_i)$
Эффект на $P(\text{wage}_i > 0 x_i)$	0.0262	$\varphi(\hat{\mu}_i / \hat{\sigma})(\hat{\beta}_{\text{exper}} + 2\hat{\beta}_{\text{exper}^2} \text{exper}_i) / \hat{\sigma}$

Таким образом, после добавления квадрата опыта предельный эффект **exper** зависит от конкретного значения опыта работы. Для женщины с 10 годами опыта дополнительный год опыта повышает ожидаемую латентную часовую заработную плату на 0.3004, ожидаемую наблюдаемую часовую заработную плату на 0.1784, а вероятность положительной заработной платы / работы – примерно на 0.0262, то есть на 2.62 процентного пункта.

2.7. LR-тест на гомоскедастичность в Тобит-модели

При помощи LR-теста проверьте гипотезу о гомоскедастичности в Тобит-модели, предварительно формально записав предполагаемые нулевой гипотезой ограничения на параметры, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и максимизируемую в гетероскедастичной Тобит-модели функцию правдоподобия. При этом уравнение дисперсии должно включать по крайней мере одну переменную, не

входящую в основное уравнение. Укажите негативные последствия, к которым может приводить отсутствие учета гетероскедастичности при условии ее наличия в Тобит-модели.

Ответ:

Проверим гипотезу о гомоскедастичности в Тобит-модели. Основное уравнение задаётся как:

$$wage_i^* = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 age_i + \varepsilon_i.$$

Наблюдаемая заработная плата задаётся правилом левого цензурирования:

$$wage_i = \begin{cases} 0, & \text{если } wage_i^* \leq 0, \\ wage_i^*, & \text{если } wage_i^* > 0. \end{cases}$$

В гомоскедастичной модели предполагается постоянная дисперсия ошибки:

$$\varepsilon_i \sim N(0, \sigma^2).$$

В гетероскедастичной спецификации зададим уравнение масштаба:

$$\log(\sigma_i) = \delta_0 + \delta_1 kids5_i + \delta_2 nwifeinc_i.$$

Переменные `kids5` и `nwifeinc` не входят в основное уравнение заработной платы, поэтому требование задания выполняется. Тогда:

$$\sigma_i = \exp(z_i \delta).$$

Для наблюдений с $wage_i = 0$ вклад в правдоподобие равен:

$$\Phi\left(\frac{-x_i \beta}{\sigma_i}\right).$$

Для наблюдений с $wage_i > 0$ вклад равен:

$$\frac{1}{\sigma_i} \varphi\left(\frac{wage_i - x_i \beta}{\sigma_i}\right).$$

Следовательно, логарифм функции правдоподобия гетероскедастичной Тобит-модели:

$$\ln L(\beta, \delta) = \sum_{i:wage_i=0} \ln \Phi\left(\frac{-x_i \beta}{\sigma_i}\right) + \sum_{i:wage_i>0} \left[-\ln \sigma_i + \ln \varphi\left(\frac{wage_i - x_i \beta}{\sigma_i}\right) \right].$$

Проверяемая нулевая гипотеза о гомоскедастичности:

$$H_0 : \delta_1 = 0, \quad \delta_2 = 0.$$

Альтернативная гипотеза:

$$H_1 : \exists j \in \{1, 2\} : \delta_j \neq 0.$$

LR-статистика рассчитывается как:

$$LR = 2 (\ln L_{het} - \ln L_{homo}).$$

При верной нулевой гипотезе:

$$LR \overset{a}{\sim} \chi^2(q), \quad q = 2.$$

Результаты оценки гетероскедастичной Тобит-модели представлены в Table 6.

Таблица 6: Результаты оценки гетероскедастичной Тобит-модели

<i>Dependent variable:</i>				
wage				
Standardized residuals				
Min	1Q	Median	3Q	Max
-1.8046	-0.1134	0.2185	0.6384	6.1791
Coefficients: location model				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.9605*	1.3827	-2.1410	0.0323
educ	0.5891***	0.0770	7.6470	2.05e-14
exper	0.2088***	0.0223	9.3840	< 2.2e-16
age	-0.1261***	0.0235	-5.3680	7.961e-08
Scale model with log link				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.0320***	0.0939	10.9970	< 2.2e-16
kids5	0.4022***	0.0997	4.0330	5.52e-05
nwifeinc	0.0182***	0.0043	4.1900	2.79e-05
Качество модели				
Тип модели	Heteroskedastic Tobit model			
Распределение случайной ошибки	Gaussian			
Точка левого цензурирования	0			
Уравнение масштаба	log-link: kids5, nwifeinc			
Число наблюдений	753			
Число оцениваемых параметров	7			
Log-likelihood	-1443.691			
Число итераций BFGS	16			

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Результаты LR-теста представлены в Table 7.

Таблица 7: Результаты LR-теста на гомоскедастичность в Тобит-модели

Тест	$\ln L_{homo}$	$\ln L_{het}$	LR-статистика	df	p-value
LR-тест на гомоскедастичность	-1462.673	-1443.691	37.9652	2	5.701e-09

По результатам теста:

$$LR = 2(-1443.691 - (-1462.673)) = 37.9652, \quad p\text{-value} = 5.701 \cdot 10^{-9}.$$

Так как $p\text{-value} < 0.01$, нулевая гипотеза о гомоскедастичности отвергается. Следовательно, есть статистические свидетельства в пользу гетероскедастичности случайной ошибки в Тобит-модели.

Это согласуется с уравнением масштаба: коэффициенты при `kids5` и `nwifeinc` положительны и статистически значимы. Значит, рост числа детей младше 5 лет и рост семейного дохода без дохода женщины связаны с увеличением условного стандартного отклонения ошибки.

Если гетероскедастичность присутствует, но не учитывается, функция правдоподобия гомоскедастичной Тобит-модели оказывается неверно специфицированной. В нелинейных моделях это может приводить не только к некорректным стандартным ошибкам, но и к несостоятельности оценок коэффициентов. Также искажаются z -статистики, $p\text{-value}$, доверительные интервалы, прогнозы, вероятности и предельные эффекты.

Таким образом, LR-тест показывает, что предположение о гомоскедастичности отвергается, поэтому более корректной является гетероскедастичная Тобит-модель с уравнением масштаба, зависящим от `kids5` и `nwifeinc`.

2.8. Предельные эффекты в гетероскедастичной Тобит-модели

Для индивида с произвольными характеристиками в Тобит-модели с гетероскедастичной случайной ошибкой рассчитайте, предварительно записав соответствующую формулу, предельный эффект переменной, входящей и в основное уравнение, и в уравнение дисперсии, на:

А) $E(y^*)$

Б) $E(y)$

В) вероятность того, что индивид работает

Ответ:

Рассмотрим гетероскедастичную Тобит-модель с левым цензурированием в нуле:

$$wage_i^* = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 age_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma_i^2),$$

$$wage_i = \begin{cases} 0, & \text{если } wage_i^* \leq 0, \\ wage_i^*, & \text{если } wage_i^* > 0. \end{cases}$$

Уравнение масштаба задаётся как:

$$\log(\sigma_i) = \gamma_0 + \gamma_1 age_i + \gamma_2 kids5_i + \gamma_3 nwifeinc_i, \quad \sigma_i = \exp(z_i \gamma).$$

Таким образом, переменная **age** входит одновременно в основное уравнение и в уравнение масштаба. Результаты оценки модели представлены в Table 8.

Таблица 8: Результаты оценки гетероскедастичной Тобит-модели

<i>Dependent variable:</i>				
wage				
Coefficients: location model				
Переменная	Estimate	Std. Error	<i>z</i> value	Pr(> <i>z</i>)
(Intercept)	-2.0806	1.3410	-1.5520	0.1210
educ	0.6141***	0.0759	8.0860	6.16e-16
exper	0.2234***	0.0235	9.4910	< 2.2e-16
age	-0.1567***	0.0245	-6.4060	1.489e-10
Scale model with log link				
Переменная	Estimate	Std. Error	<i>z</i> value	Pr(> <i>z</i>)
(Intercept)	0.1070	0.2265	0.4720	0.6370
age	0.0207***	0.0048	4.3300	1.490e-05
kids5	0.5984***	0.1086	5.5120	3.54e-08
nwifeinc	0.0185***	0.0044	4.1960	2.712e-05
Качество модели				
Тип модели	Heteroskedastic Tobit model			
Распределение случайной ошибки	Gaussian			
Точка левого цензурирования	0			
Уравнение масштаба	age, kids5, nwifeinc			
Число наблюдений	753			
Log-likelihood	-1434.154			
AIC	2884.308			
BIC	2921.301			

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Рассмотрим индивида со следующими характеристиками:

$$educ = 12, \quad exper = 10, \quad age = 40, \quad kids5 = 1, \quad nwifeinc = 20.$$

Для него получены следующие значения:

$$\hat{\mu}_i = x_i \hat{\beta} = 1.2538, \quad \widehat{\log(\sigma_i)} = z_i \hat{\gamma} = 1.9023, \quad \hat{\sigma}_i = \exp(1.9023) \approx 6.7012.$$

Стандартизированный индекс равен:

$$\hat{a}_i = \frac{\hat{\mu}_i}{\hat{\sigma}_i} = \frac{1.2538}{6.7012} \approx 0.1871,$$

откуда:

$$\Phi(\hat{a}_i) \approx 0.5742, \quad \varphi(\hat{a}_i) \approx 0.3920.$$

Поскольку **age** входит в оба уравнения, необходимо учитывать два канала влияния:

$$\frac{\partial \hat{\mu}_i}{\partial age_i} = \hat{\beta}_{age} = -0.1567,$$

$$\frac{\partial \hat{\sigma}_i}{\partial age_i} = \hat{\sigma}_i \hat{\gamma}_{age} = 6.7012 \cdot 0.0207 \approx 0.1384.$$

А) Предельный эффект age на $E(wage_i^*)$

Для латентной заработной платы:

$$E(wage_i^* | x_i) = \mu_i.$$

Следовательно:

$$\frac{\partial E(wage_i^* | x_i)}{\partial age_i} = \beta_{age}.$$

По оценкам модели:

$$\frac{\partial \hat{E}(wage_i^* | x_i)}{\partial age_i} = -0.1567.$$

Б) Предельный эффект age на $E(wage_i)$

Для наблюдаемой заработной платы:

$$E(wage_i | x_i, z_i) = \Phi(a_i)\mu_i + \sigma_i\varphi(a_i), \quad a_i = \frac{\mu_i}{\sigma_i}.$$

Если переменная входит и в основное уравнение, и в уравнение масштаба, то:

$$\frac{\partial E(wage_i | x_i, z_i)}{\partial age_i} = \Phi(a_i) \frac{\partial \mu_i}{\partial age_i} + \varphi(a_i) \frac{\partial \sigma_i}{\partial age_i}.$$

Подставляя оценки, получаем:

$$\frac{\partial \hat{E}(wage_i | x_i, z_i)}{\partial age_i} = 0.5742 \cdot (-0.1567) + 0.3920 \cdot 0.1384 \approx -0.0357.$$

В) Предельный эффект age на вероятность того, что индивид работает

В Тобит-модели вероятность положительной заработной платы равна:

$$P(wage_i > 0 \mid x_i, z_i) = P(wage_i^* > 0 \mid x_i, z_i) = \Phi(a_i).$$

Тогда предельный эффект равен:

$$\frac{\partial P(wage_i > 0 \mid x_i, z_i)}{\partial age_i} = \varphi(a_i) \left(\frac{\beta_{age}}{\sigma_i} - a_i \gamma_{age} \right).$$

Подставляя оценки, получаем:

$$\frac{\partial \hat{P}(wage_i > 0 \mid x_i, z_i)}{\partial age_i} = 0.3920 \left(\frac{-0.1567}{6.7012} - 0.1871 \cdot 0.0207 \right) \approx -0.0107.$$

Итоговые расчёты представлены в Table 9.

Таким образом, для выбранного индивида увеличение возраста на один год снижает ожидаемую латентную часовую заработную плату на 0.1567, ожидаемую наблюдаемую часовую заработную плату на 0.0357, а вероятность положительной заработной платы / работы - примерно на 0.0107, то есть на 1.07 процентного пункта. В гетероскедастичной Тобит-модели эффект переменной **age** складывается из двух каналов: влияния на латентное среднее и влияния на индивидуальную дисперсию случайной ошибки.

Таблица 9: Предельные эффекты переменной **age** в гетероскедастичной Тобит-модели

<i>Model: Heteroskedastic Tobit</i>		
Dependent variable: wage		
Характеристики индивида		
Переменная	Значение	Описание
educ	12	число лет образования женщины
exper	10	опыт работы женщины
age	40	возраст женщины
kids5	1	число детей младше 5 лет
nwifeinc	20	семейный доход за вычетом дохода женщины
Используемые расчетные величины		
Показатель	Значение	Описание
$\hat{\mu}_i = x_i \hat{\beta}$	1.2538	линейный индекс основного уравнения
$\widehat{\log(\sigma_i)}$	1.9023	линейный индекс уравнения масштаба
$\hat{\sigma}_i$	6.7012	индивидуальное стандартное отклонение ошибки
$\hat{a}_i = \hat{\mu}_i / \hat{\sigma}_i$	0.1871	стандартизированный индекс
$\Phi(\hat{a}_i)$	0.5742	вероятность положительной заработной платы
$\varphi(\hat{a}_i)$	0.3920	плотность стандартного нормального распределения
$\partial \hat{\mu}_i / \partial age_i$	-0.1567	производная основного уравнения по age
$\partial \hat{\sigma}_i / \partial age_i$	0.1384	производная масштаба по age
Предельные эффекты		
Показатель	Значение	Формула
Эффект на $E(wage_i^* x_i)$	-0.1567	$\hat{\beta}_{age}$
Эффект на $E(wage_i x_i, z_i)$	-0.0357	$\Phi(\hat{a}_i) \hat{\beta}_{age} + \varphi(\hat{a}_i) \hat{\sigma}_i \hat{\gamma}_{age}$
Эффект на $P(wage_i > 0 x_i, z_i)$	-0.0107	$\varphi(\hat{a}_i) (\hat{\beta}_{age} / \hat{\sigma}_i - \hat{a}_i \hat{\gamma}_{age})$

Часть 3. Модель Хекмана

3.1. Оцените модель Хекмана с помощью метода максимального правдоподобия, предварительно записав максимизируемую функцию правдоподобия и указав независимые переменные в уравнении занятости, которое должно иметь по крайней мере одну переменную, не входящую в уравнение зарплаты. Результат представьте в форме таблицы

Ответ:

Оценим модель Хекмана с неслучайным отбором. Заработная плата женщины наблюдается только при условии занятости, поэтому отдельно задаются уравнение занятости и уравнение зарплаты.

Уравнение занятости:

$$lfp_i^* = z_i\gamma + u_i, \quad lfp_i = \begin{cases} 1, & \text{если } lfp_i^* > 0, \\ 0, & \text{если } lfp_i^* \leq 0. \end{cases}$$

В работе используется спецификация:

$$lfp_i^* = \gamma_0 + \gamma_1 age_i + \gamma_2 kids5_i + \gamma_3 nwifeinc_i + u_i.$$

Уравнение зарплаты:

$$wage_i^* = x_i\beta + \varepsilon_i,$$

$$wage_i^* = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 age_i + \varepsilon_i.$$

Заработная плата наблюдается только если $lfp_i = 1$. Переменные `kids5` и `nwifeinc` входят в уравнение занятости, но не входят в уравнение зарплаты, поэтому условие задания об исключяющей переменной выполнено.

Предполагается совместная нормальность ошибок:

$$\begin{pmatrix} u_i \\ \varepsilon_i \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho\sigma \\ \rho\sigma & \sigma^2 \end{pmatrix} \right).$$

Для неработающих женщин вклад в правдоподобие равен:

$$P(lfp_i = 0 \mid z_i) = \Phi(-z_i\gamma).$$

Для работающих женщин вклад равен:

$$f(wage_i, lfp_i = 1 \mid x_i, z_i) = \frac{1}{\sigma} \varphi \left(\frac{wage_i - x_i \beta}{\sigma} \right) \Phi \left(\frac{z_i \gamma + \rho \frac{wage_i - x_i \beta}{\sigma}}{\sqrt{1 - \rho^2}} \right).$$

Следовательно, максимизируемая функция правдоподобия:

$$L(\gamma, \beta, \sigma, \rho) = \prod_{i:lfp_i=0} \Phi(-z_i \gamma) \prod_{i:lfp_i=1} \frac{1}{\sigma} \varphi \left(\frac{wage_i - x_i \beta}{\sigma} \right) \Phi \left(\frac{z_i \gamma + \rho \frac{wage_i - x_i \beta}{\sigma}}{\sqrt{1 - \rho^2}} \right).$$

Логарифм функции правдоподобия:

$$\ln L = \sum_{i:lfp_i=0} \ln \Phi(-z_i \gamma) + \sum_{i:lfp_i=1} \left[-\ln \sigma + \ln \varphi \left(\frac{wage_i - x_i \beta}{\sigma} \right) + \ln \Phi \left(\frac{z_i \gamma + \rho \frac{wage_i - x_i \beta}{\sigma}}{\sqrt{1 - \rho^2}} \right) \right].$$

В выборке содержится 753 наблюдения: 428 работающих и 325 неработающих женщин. Результаты оценки представлены в Table 10.

Таблица 10: Результаты оценки модели Хекмана методом максимального правдоподобия

<i>Heckman selection model</i>				
Maximum-likelihood estimator				
Selection equation: lfp				
Переменная	Estimate	Std. Error	z value	Pr(> z)
age	-0.0137*	0.0057	-2.3843	0.0171
kids5	-0.1492*	0.0685	-2.1779	0.0294
nwifeinc	-0.0052*	0.0021	-2.5122	0.0120
Threshold				
Popor	Estimate	Std. Error	z value	Pr(> z)
cut1	-0.8226**	0.2646	-3.1093	0.0019
Outcome equation: wage_heckman				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.5498	1.1703	0.4698	0.6385
educ	0.1900**	0.0606	3.1328	0.0017
exper	0.0519***	0.0145	3.5719	0.0004
age	-0.0511*	0.0247	-2.0712	0.0383
Variance and covariance parameters				
Параметр	Estimate	Std. Error	z value	Pr(> z)
$\hat{\sigma}^2$	18.3160***	3.6720	4.9880	6.101e-07
$\hat{\sigma}$	4.2797			
$\widehat{Cov}(u_i, \varepsilon_i)$	4.2200***	0.4461	9.4603	< 2.2e-16
$\hat{\rho}$	0.9861			
Качество модели				
Число наблюдений				753
Работающие женщины				428
Неработающие женщины				325
Log-likelihood				-1504.2756
AIC				3028.5511
BIC				3074.7920

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

По результатам оценки уравнения занятости переменные age, kids5 и nwifeinc

статистически значимы на уровне 5% и имеют отрицательные коэффициенты. Следовательно, больший возраст, наличие детей младше 5 лет и более высокий семейный доход без дохода женщины связаны со снижением латентной склонности к занятости.

В уравнении зарплаты коэффициенты при `educ` и `exper` положительны и статистически значимы, что указывает на положительную отдачу от образования и опыта работы. Коэффициент при `age` отрицателен и статистически значим.

Оценка дисперсии ошибки уравнения зарплаты составляет:

$$\hat{\sigma}^2 = 18.3160, \quad \hat{\sigma} = 4.2797.$$

Оценка ковариации ошибок:

$$\widehat{Cov}(u_i, \varepsilon_i) = 4.2200.$$

Соответственно:

$$\hat{\rho} = \frac{\widehat{Cov}(u_i, \varepsilon_i)}{\hat{\sigma}} = \frac{4.2200}{4.2797} \approx 0.9861.$$

Положительное и близкое к единице значение $\hat{\rho}$ указывает на сильную положительную связь между ненаблюдаемыми факторами занятости и заработной платы, то есть на существенную неслучайность отбора.

3.2. Опишите отличия модели Хекмана от модели Тобина

Ответ:

Модель Тобина и модель Хекмана применяются в ситуациях, когда зависимая переменная наблюдается не для всех индивидов в обычном непрерывном виде, однако их эконометрический смысл различается.

В модели Тобина существует одна латентная переменная:

$$y_i^* = x_i\beta + \varepsilon_i.$$

Наблюдаемая переменная получается в результате цензурирования этой же латентной переменной. Поэтому один и тот же латентный процесс определяет и величину зависимой переменной, и факт того, окажется ли она выше точки цензурирования. В данной задаче Тобит-модель трактует нулевую зарплату как результат цензурирования латентной зарплаты в нуле.

Модель Хекмана устроена иначе: она отдельно моделирует процесс отбора и процесс формирования результата. Уравнение отбора:

$$lfp_i^* = z_i\gamma + u_i, \quad lfp_i = \begin{cases} 1, & \text{если } lfp_i^* > 0, \\ 0, & \text{если } lfp_i^* \leq 0. \end{cases}$$

Основное уравнение:

$$wage_i^* = x_i\beta + \varepsilon_i,$$

причём зарплата наблюдается только при $lfp_i = 1$.

Главное отличие состоит в том, что Тобит-модель рассматривает нулевые значения как результат цензурирования, а модель Хекмана рассматривает ненаблюдаемость зависимой переменной как результат отдельного процесса отбора. В модели Хекмана зарплата неработающих женщин не считается равной нулю, а считается ненаблюдаемой.

В используемой спецификации:

$$wage_i^* = \beta_0 + \beta_1educ_i + \beta_2exper_i + \beta_3age_i + \varepsilon_i,$$

$$lfp_i^* = \gamma_0 + \gamma_1age_i + \gamma_2kids5_i + \gamma_3nwifeinc_i + u_i.$$

Переменные `kids5` и `nwifeinc` входят только в уравнение занятости. Это отражает предположение, что наличие маленьких детей и семейный доход без дохода женщины прежде всего влияют на решение работать, но не обязательно напрямую определяют часовую ставку заработной платы.

Следовательно, модель Хекмана содержательно более гибкая: она позволяет разделить решение о занятости и процесс формирования заработной платы.

3.3. Воспользуйтесь методом Хекмана, основанным на двухшаговой процедуре, и сравните оценки с полученными с использованием метода Хекмана, основанного на методе максимального правдоподобия. Опишите относительные преимущества и недостатки обоих методов

Ответ:

Модель Хекмана была оценена двумя способами: методом максимального правдоподобия и двухшаговой процедурой.

На первом шаге двухшаговой процедуры оценивается пробит-модель занятости:

$$lfp_i^* = \gamma_0 + \gamma_1age_i + \gamma_2kids5_i + \gamma_3nwifeinc_i + u_i.$$

Для работающих женщин рассчитывается обратное отношение Миллса:

$$\hat{\lambda}_i = \frac{\varphi(z_i \hat{\gamma})}{\Phi(z_i \hat{\gamma})}.$$

На втором шаге по подвыборке работающих женщин оценивается уравнение зарплаты:

$$wage_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 age_i + \theta \hat{\lambda}_i + v_i.$$

Коэффициент при $\hat{\lambda}_i$ оценивает величину $\rho\sigma$. Если он статистически значим, это указывает на наличие неслучайного отбора.

Результаты двухшаговой оценки представлены в Table 11.

Таблица 11: Результаты оценки модели Хекмана двухшаговым методом

Heckman selection model				
Two-step estimator				
Selection equation: lfp				
Переменная	Estimate	Std. Error	z value	Pr(> z)
age	-0.0348***	0.0066	-5.2447	1.566e-07
kids5	-0.7995***	0.1125	-7.1052	1.201e-12
nwifeinc	-0.0114**	0.0043	-2.6406	0.0083
Threshold				
Попор	Estimate	Std. Error	z value	Pr(> z)
cut1	-2.0802***	0.3078	-6.7572	1.407e-11
Outcome equation: wage_heckman				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.7974*	1.1919	-2.3471	0.0189
educ	0.4924***	0.0685	7.1895	6.501e-13
exper	0.0207	0.0266	0.7791	0.4359
age	0.0064	0.0322	0.1998	0.8416
Selectivity term				
Переменная	Estimate	Std. Error	z value	Pr(> z)
lambda1	0.3154	0.9044	0.3488	0.7272
Качество модели				
Число наблюдений				753
R ² уравнения зарплаты				0.1214
Adjusted R ² уравнения зарплаты				0.1131
Leave-one-out CV RMSE				3.1444

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

Сравнение оценок уравнения зарплаты представлено в Table 12.

Таблица 12: Сравнение оценок уравнения зарплаты в моделях Хекмана

Переменная	Heckman MLE	Heckman 2-step	Разница
(Intercept)	0.5498	-2.7974	-3.3472
educ	0.1900	0.4924	0.3025
exper	0.0519	0.0207	-0.0312
age	-0.0511	0.0064	0.0575

Сравнение оценок уравнения занятости представлено в Table 13.

Таблица 13: Сравнение оценок уравнения занятости в моделях Хекмана

Переменная	Heckman MLE	Heckman 2-step	Разница
age	-0.0137	-0.0348	-0.0211
kids5	-0.1492	-0.7995	-0.6503
nwifeinc	-0.0052	-0.0114	-0.0062

В уравнении занятости знаки коэффициентов совпадают: **age**, **kids5** и **nwifeinc** отрицательно связаны с вероятностью занятости. Однако по модулю оценки двухшаговой процедуры заметно выше, особенно для **kids5**.

В уравнении зарплаты различия существеннее. В обеих моделях эффект образования положителен, но в MLE-модели коэффициент при **educ** равен 0.1900, а в двухшаговой модели – 0.4924. В MLE-модели **exper** положителен и значим, а **age** отрицателен и значим. В двухшаговой модели **exper** и **age** статистически незначимы.

Коэффициент при selectivity term в двухшаговой модели:

$$\hat{\theta} = 0.3154, \quad p\text{-value} = 0.7272.$$

Следовательно, двухшаговая процедура не выявляет статистически значимого неслучайного отбора. При этом в MLE-модели ковариация ошибок положительна и статистически значима:

$$\widehat{Cov}(u_i, \varepsilon_i) = 4.2200, \quad p\text{-value} < 2.2 \cdot 10^{-16}.$$

Преимущество MLE состоит в том, что все параметры оцениваются одновременно по полной функции правдоподобия; при корректной спецификации и совместной нормальности ошибок MLE эффективнее двухшагового метода и напрямую оценивает дисперсию, ковариацию и корреляцию ошибок. Недостатки MLE – высокая зависимость от распределительных предпосылок и возможные вычислительные проблемы оптимизации.

Двухшаговый метод проще и нагляднее: сначала оценивается пробит занятости, затем в уравнение зарплаты добавляется $\hat{\lambda}_i$. Его недостатки – меньшая эффективность, необходимость корректировки стандартных ошибок из-за сгенерированного регрессора и чувствительность второго шага к качеству оценки первого шага.

Итак, оба метода дают одинаковое направление влияния переменных в уравнении занятости, но заметно различаются по величинам коэффициентов и выводам о значимости отбора. MLE указывает на сильную связь ошибок, а двухшаговая процедура не выявляет значимого selectivity term.

3.4. Проинтерпретируйте значимость и значение оценки корреляции между случайными ошибками в обоих оцененных моделях. Укажите, можно ли было бы обойтись оценением обычной МНК модели

Ответ:

В модели Хекмана неслучайный отбор определяется связью между ошибкой уравнения занятости u_i и ошибкой уравнения зарплаты ε_i . Если $\rho \neq 0$, то ненаблюдаемые факторы, влияющие на занятость, связаны с ненаблюдаемыми факторами, влияющими на зарплату. В этом случае МНК по подвыборке работающих женщин может давать смещённые и несостоятельные оценки.

При $\rho = 0$ неслучайный отбор отсутствует, и уравнение зарплаты можно оценивать обычным МНК по работающим женщинам. При $\rho \neq 0$ условное ожидание зарплаты среди работающих женщин равно:

$$E(wage_i | lfp_i = 1, x_i, z_i) = x_i\beta + \rho\sigma\lambda_i,$$

где

$$\lambda_i = \frac{\varphi(z_i\gamma)}{\Phi(z_i\gamma)}.$$

Если $\rho\sigma\lambda_i$ не учитывается, возникает проблема пропущенной переменной.

В MLE-модели:

$$\widehat{\text{Cov}}(u_i, \varepsilon_i) = 4.2200, \quad p\text{-value} < 2.2 \cdot 10^{-16}.$$

Так как $\hat{\sigma} = 4.2797$, получаем:

$$\hat{\rho} = \frac{\widehat{\text{Cov}}(u_i, \varepsilon_i)}{\hat{\sigma}} = \frac{4.2200}{4.2797} \approx 0.9861.$$

Это означает очень сильную положительную связь между ненаблюдаемыми факторами, повышающими вероятность занятости, и ненаблюдаемыми факторами, повышающими заработную плату.

В двухшаговой модели коэффициент при обратном отношении Миллса оценивает $\rho\sigma$:

$$\hat{\theta} = \widehat{\rho\sigma} = 0.3154, \quad p\text{-value} = 0.7272.$$

Следовательно, по двухшаговой модели selectivity term статистически незначим. Если использовать остаточное стандартное отклонение второго шага $\hat{\sigma} \approx 3.118$, то приближённо:

$$\hat{\rho} \approx \frac{0.3154}{3.118} \approx 0.1012.$$

Итоговая интерпретация представлена в Table 14.

Таблица 14: Интерпретация связи случайных ошибок в моделях Хекмана

Метод оценки	Показатель	Значение	Интерпретация
MLE	$\widehat{\text{Cov}}(u_i, \varepsilon_i)$	4.2200	Положительная и статистически значимая ковариация
MLE	$\hat{\rho}$	0.9861	Очень сильная положительная корреляция ошибок
Two-step	$\widehat{\rho\sigma}$	0.3154	Положительный, но статистически незначимый selectivity term
Two-step	Approx. $\hat{\rho}$	0.1012	Слабая положительная корреляция по приближённой оценке

Результаты двух методов различаются. MLE показывает сильную и статистически значимую положительную связь между ошибками занятости и зарплаты, что говорит в пользу модели Хекмана вместо обычного МНК. Двухшаговая процедура, напротив, даёт статистически незначимый коэффициент при обратном отношении Миллса, поэтому по её результатам нельзя отвергнуть гипотезу об отсутствии отбора.

Следовательно, если ориентироваться только на двухшаговую процедуру, формально можно было бы рассматривать обычное МНК-оценивание уравнения зарплаты по работающим женщинам. Однако MLE-модель показывает крайне сильную и статистически значимую корреляцию ошибок, поэтому полностью ограничиваться МНК рискованно.

Содержательно обычная МНК-модель может быть недостаточной, поскольку зарплата наблюдается только для работающих женщин, а решение работать может быть неслучайным. Ненаблюдаемая мотивация, способности или карьерная ориентация могут одновременно повышать и вероятность занятости, и заработную плату. Поэтому МНК можно использовать как базовую модель для сравнения, но более корректным итоговым подходом является модель Хекмана, явно учитывающая потенциальный неслучайный отбор.

3.5. Условные ожидания и предельные эффекты в модели Хекмана

В любой из двух оценённых в данном разделе моделей для индивида с произвольными характеристиками рассчитайте:

А) $E(y^* \mid z = 1)$ и $E(y^* \mid z = 0)$

Б) предельный эффект любой переменной, входящей линейно и в основное уравнение, и в уравнение занятости, на $E(y^* | z = 1)$ и $E(y^* | z = 0)$

Ответ:

Для расчётов используем модель Хекмана, оценённую методом максимального правдоподобия. Рассмотрим женщину со следующими характеристиками:

$$educ = 12, \quad exper = 10, \quad age = 40, \quad kids5 = 1, \quad nwifeinc = 20.$$

Основное уравнение заработной платы:

$$wage_i^* = x_i\beta + \varepsilon_i, \quad x_i\beta = \beta_0 + \beta_1educ_i + \beta_2exper_i + \beta_3age_i.$$

Уравнение занятости:

$$z_i^* = w_i\gamma + u_i, \quad z_i = \begin{cases} 1, & \text{если } z_i^* > 0, \\ 0, & \text{если } z_i^* \leq 0. \end{cases}$$

Предполагается совместная нормальность ошибок:

$$\begin{pmatrix} u_i \\ \varepsilon_i \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho\sigma \\ \rho\sigma & \sigma^2 \end{pmatrix} \right).$$

По оценкам MLE-модели:

$$\hat{\beta}_0 = 0.5498, \quad \hat{\beta}_{educ} = 0.1900, \quad \hat{\beta}_{exper} = 0.0519, \quad \hat{\beta}_{age} = -0.0511,$$

$$\hat{\gamma}_{age} = -0.0137, \quad \hat{\gamma}_{kids5} = -0.1492, \quad \hat{\gamma}_{nwifeinc} = -0.0052, \quad \widehat{cut}_1 = -0.8226,$$

$$\widehat{\rho\sigma} = \widehat{\text{Cov}}(u_i, \varepsilon_i) = 4.2200, \quad \hat{\sigma} = 4.2797, \quad \hat{\rho} = 0.9861.$$

Линейный индекс уравнения зарплаты:

$$\hat{\mu}_i = x_i\hat{\beta} = 0.5498 + 0.1900 \cdot 12 + 0.0519 \cdot 10 - 0.0511 \cdot 40 \approx 1.3060.$$

Индекс уравнения занятости в используемой параметризации:

$$\hat{a}_i = w_i\hat{\gamma} - \widehat{cut}_1.$$

Для выбранного индивида:

$$w_i \hat{\gamma} = -0.0137 \cdot 40 - 0.1492 \cdot 1 - 0.0052 \cdot 20 \approx -0.8014,$$

$$\hat{a}_i = -0.8014 - (-0.8226) \approx 0.0212.$$

Следовательно:

$$\Phi(\hat{a}_i) \approx 0.5085, \quad \varphi(\hat{a}_i) \approx 0.3989.$$

А) Расчёт $E(y^* | z = 1)$ и $E(y^* | z = 0)$

Для работающего индивида:

$$E(y_i^* | z_i = 1, x_i, w_i) = x_i \beta + \rho \sigma \frac{\varphi(a_i)}{\Phi(a_i)}.$$

Обозначим:

$$\lambda_1(a_i) = \frac{\varphi(a_i)}{\Phi(a_i)}.$$

Для выбранного индивида:

$$\lambda_1(\hat{a}_i) = \frac{0.3989}{0.5085} \approx 0.7844.$$

Тогда:

$$\hat{E}(y_i^* | z_i = 1) = 1.3060 + 4.2200 \cdot 0.7844 \approx 4.6163.$$

Для неработающего индивида:

$$E(y_i^* | z_i = 0, x_i, w_i) = x_i \beta - \rho \sigma \frac{\varphi(a_i)}{1 - \Phi(a_i)}.$$

Обозначим:

$$\lambda_0(a_i) = \frac{\varphi(a_i)}{1 - \Phi(a_i)}.$$

Для выбранного индивида:

$$\lambda_0(\hat{a}_i) = \frac{0.3989}{1 - 0.5085} \approx 0.8114.$$

Тогда:

$$\hat{E}(y_i^* | z_i = 0) = 1.3060 - 4.2200 \cdot 0.8114 \approx -2.1183.$$

Б) Предельный эффект переменной age

В качестве переменной, входящей линейно и в основное уравнение, и в уравнение занятости, выберем age.

Для работающих индивидов:

$$E(y_i^* | z_i = 1) = \mu_i + \rho\sigma\lambda_1(a_i), \quad \lambda_1(a_i) = \frac{\varphi(a_i)}{\Phi(a_i)}.$$

Производная обратного отношения Миллса:

$$\lambda_1'(a_i) = -\lambda_1(a_i) [a_i + \lambda_1(a_i)].$$

Следовательно:

$$\frac{\partial E(y_i^* | z_i = 1)}{\partial age_i} = \beta_{age} + \rho\sigma\lambda_1'(a_i)\gamma_{age}.$$

Подставляя оценки:

$$\lambda_1'(\hat{a}_i) = -0.7844(0.0212 + 0.7844) \approx -0.6320,$$

$$\frac{\partial \hat{E}(y_i^* | z_i = 1)}{\partial age_i} = -0.0511 + 4.2200 \cdot (-0.6320) \cdot (-0.0137) \approx -0.0146.$$

Для неработающих индивидов:

$$E(y_i^* | z_i = 0) = \mu_i - \rho\sigma\lambda_0(a_i), \quad \lambda_0(a_i) = \frac{\varphi(a_i)}{1 - \Phi(a_i)}.$$

Производная:

$$\lambda_0'(a_i) = \lambda_0(a_i) [\lambda_0(a_i) - a_i].$$

Тогда:

$$\frac{\partial E(y_i^* | z_i = 0)}{\partial age_i} = \beta_{age} - \rho\sigma\lambda_0'(a_i)\gamma_{age}.$$

Подставляя оценки:

$$\lambda_0'(\hat{a}_i) = 0.8114(0.8114 - 0.0212) \approx 0.6412,$$

$$\frac{\partial \hat{E}(y_i^* | z_i = 0)}{\partial age_i} = -0.0511 - 4.2200 \cdot 0.6412 \cdot (-0.0137) \approx -0.0140.$$

Итоговые расчёты представлены в Table 15.

Таблица 15: Расчёт условных ожиданий и предельных эффектов в модели Хекмана

<i>Heckman selection model</i>		
Maximum-likelihood estimator		
Характеристики индивида		
Переменная	Значение	Описание
educ	12	число лет образования женщины
exper	10	опыт работы женщины
age	40	возраст женщины
kids5	1	число детей младше 5 лет
nwifeinc	20	семейный доход за вычетом дохода женщины
Расчётные величины		
Показатель	Значение	Описание
$\hat{\mu}_i = x_i \hat{\beta}$	1.3060	линейный индекс уравнения зарплаты
$\hat{a}_i$	0.0212	индекс уравнения занятости
$\Phi(\hat{a}_i)$	0.5085	вероятность занятости
$\varphi(\hat{a}_i)$	0.3989	плотность стандартного нормального распределения
$\lambda_1(\hat{a}_i)$	0.7844	обратное отношение Миллса для $z_i = 1$
$\lambda_0(\hat{a}_i)$	0.8114	обратное отношение Миллса для $z_i = 0$
$\widehat{\rho\sigma}$	4.2200	ковариация ошибок уравнений занятости и зарплаты
Условные ожидания		
Показатель	Значение	Формула
$\widehat{E}(y_i^* z_i = 1)$	4.6163	$\hat{\mu}_i + \widehat{\rho\sigma} \lambda_1(\hat{a}_i)$
$\widehat{E}(y_i^* z_i = 0)$	-2.1183	$\hat{\mu}_i - \widehat{\rho\sigma} \lambda_0(\hat{a}_i)$
Предельные эффекты переменной age		
Показатель	Значение	Формула
Эффект на $E(y_i^* z_i = 1)$	-0.0146	$\hat{\beta}_{age} + \widehat{\rho\sigma} \lambda'_1(\hat{a}_i) \hat{\gamma}_{age}$
Эффект на $E(y_i^* z_i = 0)$	-0.0140	$\hat{\beta}_{age} - \widehat{\rho\sigma} \lambda'_0(\hat{a}_i) \hat{\gamma}_{age}$

Итак, для выбранного индивида ожидаемая латентная заработная плата при условии занятости равна 4.6163, а при условии незанятости равна -2.1183. Такое различие связано с положительной оценкой $\widehat{\rho\sigma}$: ненаблюдаемые факторы, повышающие вероятность занятости, также связаны с более высокой латентной заработной платой. Предельный эффект возраста на $E(y_i^* | z_i = 1)$ составляет -0.0146, а на $E(y_i^* | z_i = 0)$ составляет -0.0140, то есть в обоих случаях увеличение возраста снижает условную ожидаемую латентную заработную плату.

Часть 4. Модель Ньюи

4.1. Опишите преимущества и недостатки метода Ньюи по сравнению с методом Хекмана

Ответ:

Метод Хекмана и метод Ньюи решают проблему неслучайного отбора: заработная плата наблюдается только для работающих женщин, поэтому оценивание уравнения зарплаты только по работающим может быть некорректным, если занятость связана с ненаблюдаемыми факторами заработной платы.

В классической модели Хекмана предполагается совместная нормальность ошибок уравнения отбора и основного уравнения:

$$\begin{pmatrix} u_i \\ \varepsilon_i \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho\sigma \\ \rho\sigma & \sigma^2 \end{pmatrix} \right).$$

При этом корректирующий член имеет параметрический вид:

$$\lambda_i = \frac{\varphi(z_i\gamma)}{\Phi(z_i\gamma)}, \quad E(\varepsilon_i \mid z_i = 1, w_i, x_i) = \rho\sigma\lambda_i.$$

Метод Ньюи является более гибкой альтернативой. Он не требует жёстко задавать совместное распределение ошибок, а аппроксимирует условное ожидание ошибки основного уравнения полиномом:

$$E(\varepsilon_i \mid z_i = 1, w_i, x_i) \approx \sum_{t=0}^k \tau_t g(w_i\gamma)^t,$$

где $g(w_i\gamma)$ – сглаживающая функция, например линейный индекс отбора или обратное отношение Миллса, а k – степень полинома.

На втором шаге оценивается уравнение:

$$y_i = x_i\beta + \tau_1 g(w_i\hat{\gamma}) + \tau_2 g(w_i\hat{\gamma})^2 + \dots + \tau_k g(w_i\hat{\gamma})^k + v_i.$$

Главное преимущество метода Ньюи состоит в ослаблении распределительных предположений модели Хекмана. Если ошибки уравнения отбора и уравнения зарплаты не являются совместно нормальными, классическая модель Хекмана может быть неверно специфицирована, тогда как метод Ньюи допускает более гибкую форму correction term.

Недостатки метода Ньюи связаны с большей сложностью: необходимо выбрать сглаживающую функцию $g(\cdot)$, степень полинома k , способ подбора k и корректный способ расчёта стандартных ошибок. При малом k возможна грубая аппроксимация и смещение, при большом k – рост дисперсии оценок и коллинеарность между

степенями сглаживающей функции. Кроме того, интерпретация коэффициентов менее прозрачна, чем в модели Хекмана, где коэффициент при обратном отношении Миллса связан с $\rho\sigma$.

Таким образом, метод Ньюи предпочтителен, если важно снизить зависимость результатов от предположения о совместной нормальности ошибок. Метод Хекмана предпочтителен, если предположение нормальности выглядит приемлемым и требуется более простая, эффективная и лучше интерпретируемая параметрическая модель.

4.2. Взяв за основу любую модель бинарного выбора, произвольную сглаживающую функцию и используя leave-one-out кросс-валидацию для подбора степени полинома, оцените модель Ньюи, описав осуществленные для ее построения шаги. Результат представьте в форме таблицы, содержащей оценки и бутстрапированные стандартные ошибки. Сравните оценки модели Ньюи и моделей Хекмана, основанных на двухшаговой процедуре и ММП

Ответ:

Оценим модель Ньюи для коррекции неслучайного отбора. Зависимая переменная уравнения заработной платы задаётся как:

$$\text{wage_heckman}_i = \begin{cases} \text{wage}_i, & \text{если } \text{lf}p_i = 1, \\ NA, & \text{если } \text{lf}p_i = 0. \end{cases}$$

На первом шаге оценивается пробит-модель занятости:

$$\text{lf}p_i^* = \gamma_0 + \gamma_1 \text{age}_i + \gamma_2 \text{kids5}_i + \gamma_3 \text{nwif}einc_i + u_i,$$

$$\text{lf}p_i = \begin{cases} 1, & \text{если } \text{lf}p_i^* > 0, \\ 0, & \text{если } \text{lf}p_i^* \leq 0. \end{cases}$$

После оценки пробит-модели рассчитывается индекс отбора:

$$\hat{s}_i = w_i \hat{\gamma}.$$

В качестве сглаживающей функции используется обратное отношение Миллса:

$$g(\hat{s}_i) = \hat{\lambda}_i = \frac{\varphi(\hat{s}_i)}{\Phi(\hat{s}_i)}.$$

На втором шаге по подвыборке работающих женщин оценивается модель:

$$wage_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 age_i + \sum_{t=1}^k \tau_t \hat{\lambda}_i^t + v_i.$$

Степень полинома выбиралась из множества:

$$k \in \{1, 2, 3, 4\}$$

по минимальному значению leave-one-out cross-validation RMSE. Результаты представлены в Table 16.

Таблица 16: Выбор степени полинома в модели Ньюи по LOOCV

Степень полинома	LOOCV RMSE
1	3.144401
2	3.143557
3	3.150704
4	3.156654

Минимальное значение LOOCV RMSE достигается при степени:

$$\hat{k} = 2.$$

Следовательно, итоговая модель Ньюи имеет вид:

$$wage_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 age_i + \tau_1 \hat{\lambda}_i + \tau_2 \hat{\lambda}_i^2 + v_i.$$

Стандартные ошибки основных коэффициентов были рассчитаны бутстрапом на 300 итерациях. На каждой итерации заново выполнялись все шаги: формировалась бутстрап-выборка, оценивалась пробит-модель занятости, рассчитывалась сглаживающая функция, заново выбиралась степень полинома по LOOCV и оценивалось уравнение зарплаты. Частоты выбора степеней полинома:

$$k = 1 : 134, \quad k = 2 : 118, \quad k = 3 : 32, \quad k = 4 : 16.$$

Чаще всего выбирались степени $k = 1$ и $k = 2$, то есть данные поддерживают относительно простую форму корректирующего полинома.

Таблица 17: Результаты оценки модели Ньюи

<i>Newey selection correction model</i>		
Dependent variable: wage_heckman		
Основные коэффициенты уравнения зарплаты		
Переменная	Estimate	Bootstrap Std. Error
(Intercept)	-3.7288	5.3462
educ	0.4864	0.0671
exper	0.0235	0.0259
age	-0.0172	0.0400
Корректирующие члены выбранной модели, $k = 2$		
Переменная	Estimate	Usual Std. Error
$\hat{\lambda}_i$	5.7868	3.8733
$\hat{\lambda}_i^2$	-3.3747	2.3376
Качество модели		
Выбранная степень полинома		2
Residual standard error		3.114
R^2		0.1257
Adjusted R^2		0.1153
LOOCV RMSE		3.143557
Число bootstrap-итераций		300

Для корректирующих членов $\hat{\lambda}_i$ и $\hat{\lambda}_i^2$ приведены обычные стандартные ошибки итоговой регрессии, поскольку на бутстрап-итерациях степень полинома выбиралась заново, и размерность блока корректирующих членов могла меняться.

Сравнение оценок модели Ньюи с моделями Хекмана представлено в Table 18.

Таблица 18: Сравнение оценок моделей Хекмана и Ньюи

Переменная	MLE	2-step	Newey	Boot. SE
(Intercept)	0.5498	-2.7974	-3.7288	5.3462
educ	0.1900	0.4924	0.4864	0.0671
exper	0.0519	0.0207	0.0235	0.0259
age	-0.0511	0.0064	-0.0172	0.0400

Модель Ньюи даёт оценки, близкие к двухшаговой модели Хекмана. Особенно это видно по коэффициенту при **educ**: в модели Ньюи он равен 0.4864, а в двухшаговой модели Хекмана – 0.4924. В MLE-модели Хекмана оценка заметно ниже и составляет 0.1900.

Коэффициент при **exper** в модели Ньюи равен 0.0235, что также близко к двухшаговой модели Хекмана, где он равен 0.0207. Однако с учётом бутстрапированной стандартной ошибки 0.0259 эффект опыта нельзя считать устойчивым. Коэффициент при **age** в модели Ньюи отрицателен и равен -0.0172 , но при стандартной ошибке 0.0400 также не является устойчивым.

Корректирующие члены $\hat{\lambda}_i$ и $\hat{\lambda}_i^2$ имеют разные знаки: первый положителен, второй отрицателен. Это означает, что модель Ньюи допускает нелинейную форму коррекции отбора, в отличие от классической двухшаговой модели Хекмана с одним обратным отношением Миллса.

Итоговый вывод: модель Ньюи близка к двухшаговой модели Хекмана по основным коэффициентам уравнения зарплаты, но задаёт более гибкую коррекцию отбора. Наиболее устойчивый содержательный результат – положительная связь образования с заработной платой среди работающих женщин. Эффекты опыта и возраста менее устойчивы относительно бутстрапированных стандартных ошибок.

Часть 4.1. Модель Хекмана и модель Ньюи. Логарифмированная целевая переменная

Ответ:

В основной части работы модели Хекмана и Ньюи сначала оценивались для заработной платы в уровнях. Однако в модели Хекмана, оценённой методом максимального правдоподобия, была получена очень высокая оценка корреляции ошибок:

$$\hat{\rho} \approx 0.9861.$$

Такое значение указывает на сильный положительный самоотбор, но одновременно выглядит достаточно чувствительным к спецификации, поскольку двухшаговая модель Хекмана и модель Ньюи в уровнях не подтвердили статистически значимый корректирующий член. Поэтому дополнительно была проведена проверка устойчивости результатов с использованием логарифма заработной платы.

Для работающих женщин была создана переменная:

$$\log_wage_heckman_i = \log(wage_i), \quad \text{если } lfp_i = 1.$$

Для неработающих женщин значение логарифма заработной платы было задано как пропущенное:

$$\log_wage_heckman_i = NA, \quad \text{если } lfp_i = 0.$$

Такой подход соответствует логике модели Хекмана: заработная плата неработающих женщин не равна нулю, а не наблюдается. В выборке 753 наблюдения, из которых 428 женщин работают, а 325 женщин не работают.

Результаты оценки модели Хекмана методом максимального правдоподобия с зависимой переменной $\log(wage)$ представлены в Table 19.

Таблица 19: Результаты оценки модели Хекмана MLE с логарифмом заработной платы

<i>Heckman selection model</i>				
Dependent variable: log_wage_heckman				
Selection equation: lfp				
Переменная	Estimate	Std. Error	z value	Pr(> z)
age	-0.0349***	0.0067	-5.2122	1.866e-07
kids5	-0.8021***	0.1134	-7.0733	1.512e-12
nwifeinc	-0.0112*	0.0048	-2.3242	0.0201
cut1	-2.0810***	0.3079	-6.7583	1.397e-11
Outcome equation: log_wage_heckman				
Переменная	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.3520	0.2782	-1.2653	0.2058
educ	0.1100***	0.0143	7.6795	1.599e-14
exper	0.0162**	0.0051	3.1956	0.0014
age	-0.0009	0.0063	-0.1367	0.8913
Parameters of selection correction				
Параметр	Estimate	Std. Error	z value	Pr(> z)
$\widehat{Var}(\varepsilon_i)$	0.4451***	0.0520	8.5560	< 2.2e-16
$\widehat{\sigma}$	0.6672			
$\widehat{Cov}(u_i, \varepsilon_i)$	-0.0401	0.2241	-0.1788	0.8581
$\widehat{\rho}$	-0.0601			
Качество модели				
Число наблюдений				753
Log-likelihood				-912.0600
AIC				1844.1200
BIC				1890.3610

Signif. codes: *** 0.001; ** 0.01; * 0.05; · 0.1; 1

В логарифмической спецификации уравнение занятости даёт ожидаемые результаты: возраст, число детей младше 5 лет и семейный доход без дохода женщины отрицательно и статистически значимо связаны с вероятностью занятости. Это означает, что более старший возраст, наличие маленьких детей и более высокий альтернативный семейный доход снижают вероятность участия женщины в рабочей силе.

В уравнении логарифма заработной платы статистически значимыми являются образование и опыт. Коэффициент при `educ` равен 0.1100, следовательно, дополнительный год образования связан примерно с увеличением заработной платы на 11%. Коэффициент при `exper` равен 0.0162, то есть дополнительный год опыта связан примерно с увеличением заработной платы на 1.6%. Переменная `age` в уравнении логарифма заработной платы статистически незначима.

Ключевое отличие от модели в уровнях состоит в оценке самоотбора. В log-спецификации ковариация ошибок уравнения занятости и уравнения заработной платы равна -0.0401 , p-value равно 0.8581, а оценка корреляции ошибок составляет:

$$\hat{\rho} = -0.0601.$$

Следовательно, в отличие от модели в уровнях, MLE-модель с логарифмом заработной платы не даёт статистически значимых свидетельств самоотбора.

Далее модель Хекмана была оценена двухшаговым методом. Сравнение оценок MLE и 2-step представлено в Table 20.

Таблица 20: Сравнение MLE и двухшаговой модели Хекмана с логарифмом заработной платы

Переменная	Heckman MLE log	Heckman 2-step log	Разница
(Intercept)	-0.3520	-0.3525	-0.0004
educ	0.1100	0.1101	0.0001
exper	0.0162	0.0162	0.0000
age	-0.0009	-0.0008	0.0000

Из Table 20 видно, что MLE и двухшаговый метод дают практически одинаковые оценки в уравнении логарифма заработной платы. Это важный результат, поскольку в модели в уровнях оценки MLE и 2-step заметно расходились. После логарифмирования зависимой переменной результаты стали существенно более устойчивыми.

В двухшаговой модели коэффициент при обратном отношении Миллса также оказался статистически незначимым:

$$\hat{\lambda} = -0.0422, \quad p\text{-value} = 0.8296.$$

В ручной реализации двухшагового метода коэффициент при λ также незначим:

$$\hat{\lambda} = -0.0422, \quad p\text{-value} = 0.8062.$$

Следовательно, двухшаговая модель Хекмана также не подтверждает наличие статистически значимого самоотбора в log-спецификации.

Дополнительно была оценена модель Ньюи с зависимой переменной $\log(wage)$. Степень полинома выбиралась по leave-one-out cross-validation. Результаты выбора степени представлены в Table 21.

Таблица 21: Выбор степени полинома в модели Ньюи с логарифмом заработной платы

Степень полинома	LOOCV RMSE
1	0.6752088
2	0.6759480
3	0.6763960
4	0.6778199

Минимальное значение LOOCV RMSE достигается при степени $k = 1$. Следовательно, для log-спецификации достаточно одного корректирующего члена $\hat{\lambda}_i$; более высокие степени полинома не улучшают качество модели. В бутстрапе степень $k = 1$ также выбиралась чаще всего: 164 раза из 300 итераций.

Результаты оценки модели Ньюи с bootstrap-стандартными ошибками представлены в Table 22.

Таблица 22: Результаты оценки модели Ньюи с логарифмом заработной платы

<i>Newey selection correction model</i>		
Dependent variable: log_wage_heckman		
Переменная	Estimate	Bootstrap Std. Error
(Intercept)	-0.3525	1.3341
educ	0.1101	0.0138
exper	0.0162	0.0049
age	-0.0008	0.0074
Корректирующий член		
Переменная	Estimate	Usual Std. Error
$\hat{\lambda}_i$	-0.0422	0.1721
Качество модели		
Выбранная степень полинома		1
Residual standard error		0.6704
R^2		0.1487
Adjusted R^2		0.1406
LOOCV RMSE		0.6752088
Число bootstrap-итераций		300

В модели Ньюи корректирующий член $\hat{\lambda}_i$ статистически незначим:

$$\hat{\lambda} = -0.0422, \quad p\text{-value} = 0.8062.$$

Следовательно, модель Ньюи также не подтверждает наличие значимого самоотбора после перехода к логарифму заработной платы.

Сравнение моделей Хекмана и Ньюи с логарифмом заработной платы представлено в Table 23.

Таблица 23: Сравнение моделей Хекмана и Ньюи с логарифмом заработной платы

Переменная	Heckman MLE log	Heckman 2-step log	Newey log	Newey Bootstrap SE
(Intercept)	-0.3520	-0.3525	-0.3525	1.3341
educ	0.1100	0.1101	0.1101	0.0138
exper	0.0162	0.0162	0.0162	0.0049
age	-0.0009	-0.0008	-0.0008	0.0074

Table 23 показывает, что все три модели – Heckman MLE, Heckman 2-step и Newey – дают практически одинаковые оценки в log-спецификации. Это является сильным аргументом в пользу устойчивости результатов после логарифмирования зависимой переменной.

Для выбранного индивида с характеристиками

$$educ = 12, \quad exper = 10, \quad age = 40, \quad kids5 = 1, \quad nwifeinc = 20$$

условные ожидания в MLE-модели Хекмана с логарифмом заработной платы представлены в Table 24.

Таблица 24: Условные ожидания в MLE-модели Хекмана с логарифмом заработной платы

Показатель	Значение
$\hat{\mu}_i$	1.0958
$\hat{a}_i$	-0.3427
$\Phi(\hat{a}_i)$	0.3659
$\varphi(\hat{a}_i)$	0.3762
$\lambda_1(\hat{a}_i)$	1.0281
$\lambda_0(\hat{a}_i)$	0.5933
$\hat{E}(\log(wage_i)^* z_i = 1)$	1.0546
$\hat{E}(\log(wage_i)^* z_i = 0)$	1.1195
$\partial \hat{E}(\log(wage_i)^* z_i = 1) / \partial age_i$	-0.0018
$\partial \hat{E}(\log(wage_i)^* z_i = 0) / \partial age_i$	-0.0016

Так как оценка $\widehat{\rho\sigma}$ в log-спецификации мала и статистически незначима, условные ожидания для работающих и неработающих индивидов различаются слабо. Это также согласуется с общим выводом об отсутствии статистически значимого самоотбора.

Таким образом, дополнительная проверка с логарифмом заработной платы существенно меняет интерпретацию результатов по сравнению с моделью в уровнях. В модели в уровнях MLE давала очень высокую оценку корреляции ошибок, что указывало на сильный самоотбор, но этот результат не подтверждался двухшаговой моделью и моделью Ньюи. После перехода к $\log(wage)$ все три подхода – Heckman MLE, Heckman 2-step и Newey – дают согласованные результаты: корректирующие

члены статистически незначимы, а оценка корреляции ошибок близка к нулю. Поэтому в log-спецификации статистически значимый самоотбор не обнаруживается.

Основной устойчивый содержательный вывод состоит в том, что образование и опыт положительно связаны с заработной платой. Дополнительный год образования связан примерно с ростом заработной платы на 11%, а дополнительный год опыта – примерно с ростом заработной платы на 1.6%. Возраст после контроля образования и опыта статистически значимого эффекта на логарифм заработной платы не имеет.

Часть 5. Модель с усечением по центру

5.1. Самостоятельно реализуйте модель усечённой регрессии, в которой значения зависимой переменной не наблюдаются в случае, когда зависимая переменная попадает в интервал (a, b) . Придумайте сюжет, в котором применяется такая модель и реализуйте его на симулированных данных. Затем продемонстрируйте, что ваша модель корректно оценивает регрессионные коэффициенты, а также рассчитайте стандартные ошибки оценок параметров модели

Ответ:

Рассмотрим следующую гипотетическую ситуацию. Пусть исследуется потенциальный ежемесячный расход клиента на доставку еды. В аналитическую базу попадают только нетипичные клиенты: с очень низкими расходами или с очень высокими расходами. Клиенты со средними расходами не попадают в базу, поскольку сервис не сохраняет такие наблюдения в специальной аналитической выборке. Следовательно, значения зависимой переменной не наблюдаются, если расход клиента попадает в некоторый центральный интервал.

Пусть латентная зависимая переменная задаётся моделью:

$$y_i^* = x_i\beta + \varepsilon_i,$$

где

$$\varepsilon_i \sim N(0, \sigma^2).$$

Наблюдение попадает в выборку только в том случае, если:

$$y_i^* \leq a \quad \text{или} \quad y_i^* \geq b.$$

Если же

$$a < y_i^* < b,$$

то наблюдение полностью отсутствует в выборке. В симуляции были выбраны следующие границы центрального усечения:

$$a = 6, \quad b = 8.$$

Истинная модель генерации данных имела вид:

$$y_i^* = 7.0 + 1.2 \text{income_index}_i - 0.8 \text{discount_index}_i + 0.6 \text{activity_index}_i + \varepsilon_i,$$

$$\varepsilon_i \sim N(0, 2^2).$$

То есть истинные параметры равны:

$$\beta_0 = 7.0, \quad \beta_1 = 1.2, \quad \beta_2 = -0.8, \quad \beta_3 = 0.6, \quad \sigma = 2.0.$$

Было сгенерировано 50000 наблюдений. После удаления наблюдений, попавших в центральный интервал (6, 8), осталось 34874 наблюдения. Информация об усечении представлена в Table 25.

Таблица 25: Информация о центральном усечении выборки

Показатель	Значение
Полная выборка	50000
Наблюдаемая выборка	34874
Удалено из-за центрального усечения	15126
Доля наблюдаемых	0.6975

Так как наблюдение попадает в выборку только вне интервала (a, b) , для оценивания необходимо использовать условную плотность наблюдаемого значения. Для одного наблюдения:

$$f(y_i \mid y_i \leq a \text{ или } y_i \geq b, x_i) = \frac{\frac{1}{\sigma} \varphi\left(\frac{y_i - x_i \beta}{\sigma}\right)}{\Phi\left(\frac{a - x_i \beta}{\sigma}\right) + 1 - \Phi\left(\frac{b - x_i \beta}{\sigma}\right)}.$$

Знаменатель отражает вероятность попадания наблюдения в выборку:

$$P(y_i^* \leq a \mid x_i) + P(y_i^* \geq b \mid x_i) = \Phi\left(\frac{a - x_i\beta}{\sigma}\right) + 1 - \Phi\left(\frac{b - x_i\beta}{\sigma}\right).$$

Следовательно, логарифм функции правдоподобия имеет вид:

$$\ln L(\beta, \sigma) = \sum_{i=1}^{n_{obs}} \left[-\ln \sigma + \ln \varphi\left(\frac{y_i - x_i\beta}{\sigma}\right) - \ln \left\{ \Phi\left(\frac{a - x_i\beta}{\sigma}\right) + 1 - \Phi\left(\frac{b - x_i\beta}{\sigma}\right) \right\} \right].$$

Оценивание было выполнено методом максимального правдоподобия. Для сравнения также была оценена наивная МНК-модель по усечённой выборке, которая не учитывает механизм центрального усечения. Результаты представлены в Table 26.

Таблица 26: Сравнение истинных параметров, наивного МНК и ММП для модели с центральным усечением

Переменная	True	Naive OLS	MLE	Std. Error	z value	p-value
(Intercept)	7.0000	7.0170	7.0159	0.0097	719.5834	< 2.2e-16
income_index	1.2000	1.4768	1.2067	0.0101	119.1435	< 2.2e-16
discount_index	-0.8000	-0.9951	-0.8130	0.0099	-82.0810	< 2.2e-16
activity_index	0.6000	0.7233	0.5915	0.0098	60.4061	< 2.2e-16

Оценка параметра стандартного отклонения случайной ошибки представлена в Table 27.

Таблица 27: Оценка стандартного отклонения ошибки в модели с центральным усечением

Параметр	True	Naive OLS	MLE	Std. Error
σ	2.0000	2.2140	2.0023	0.0069

Стандартные ошибки оценок параметров были рассчитаны через обратный Гессиян логарифма функции правдоподобия. Поскольку максимизировался логарифм правдоподобия, асимптотическая ковариационная матрица оценок имеет вид:

$$\widehat{Var}(\hat{\theta}) = (-H)^{-1},$$

где H – матрица вторых производных логарифма функции правдоподобия в точке максимума. Для параметра σ использовался дельта-метод, поскольку в оптимизации оценивался $\log(\sigma)$:

$$se(\hat{\sigma}) = \hat{\sigma} \cdot se(\widehat{\log \sigma}).$$

Для дополнительной проверки корректности оценивания были построены 95%-е доверительные интервалы для коэффициентов. Результаты представлены в Table 28.

Таблица 28: Доверительные интервалы для ММП-оценок модели с центральным усечением

Переменная	Estimate	Std. Error	95% CI Low	95% CI High	True
(Intercept)	7.0159	0.0097	6.9968	7.0350	7.0000
income_index	1.2067	0.0101	1.1869	1.2266	1.2000
discount_index	-0.8130	0.0099	-0.8324	-0.7936	-0.8000
activity_index	0.5915	0.0098	0.5723	0.6107	0.6000

Все истинные значения коэффициентов попадают в соответствующие 95%-е доверительные интервалы. Это показывает, что реализованная ММП-модель корректно восстанавливает параметры исходного процесса генерации данных.

Сравнение абсолютных ошибок наивного МНК и ММП представлено в Table 29.

Таблица 29: Сравнение абсолютных ошибок наивного МНК и ММП

Переменная	Abs. Error OLS	Abs. Error MLE
(Intercept)	0.0170	0.0159
income_index	0.2768	0.0067
discount_index	0.1951	0.0130
activity_index	0.1233	0.0085

Из Table 29 видно, что ММП-оценки существенно ближе к истинным значениям параметров, чем оценки наивного МНК по усечённой выборке. Особенно заметна разница для коэффициентов при `income_index`, `discount_index` и `activity_index`. Например, для `income_index` абсолютная ошибка МНК равна 0.2768, тогда как абсолютная ошибка ММП составляет только 0.0067.

Таким образом, наивный МНК по центрально усечённой выборке даёт смещённые оценки, поскольку не учитывает, что наблюдения со средними значениями зависимой переменной систематически отсутствуют в данных. Реализованная ММП-модель учитывает вероятность попадания наблюдения в выборку и поэтому корректно восстанавливает регрессионные коэффициенты и параметр σ .

5.2. Напишите функцию, позволяющую оценивать условное математическое ожидание зависимой переменной в вашей модели, и продемонстрируйте её применение на конкретном примере

Ответ:

В модели с центральным усечением наблюдение попадает в выборку только в том случае, если зависимая переменная находится вне интервала (a, b) . То есть:

$$y_i = y_i^* \quad \text{наблюдается только если} \quad y_i^* \leq a \quad \text{или} \quad y_i^* \geq b.$$

При этом латентная зависимая переменная задаётся моделью:

$$y_i^* = x_i\beta + \varepsilon_i,$$

$$\varepsilon_i \sim N(0, \sigma^2).$$

Обозначим:

$$\mu_i = x_i\beta,$$

$$z_{a,i} = \frac{a - \mu_i}{\sigma}, \quad z_{b,i} = \frac{b - \mu_i}{\sigma}.$$

Вероятность того, что наблюдение попадёт в выборку, равна:

$$P_i^{obs} = P(y_i^* \leq a \mid x_i) + P(y_i^* \geq b \mid x_i).$$

Для нормального распределения:

$$P_i^{obs} = \Phi(z_{a,i}) + 1 - \Phi(z_{b,i}).$$

Условное математическое ожидание зависимой переменной при условии попадания наблюдения в выборку имеет вид:

$$E(y_i^* \mid y_i^* \leq a \text{ или } y_i^* \geq b, x_i) = \mu_i + \sigma \frac{\varphi(z_{b,i}) - \varphi(z_{a,i})}{\Phi(z_{a,i}) + 1 - \Phi(z_{b,i})}.$$

В данной формуле $\Phi(\cdot)$ – функция распределения стандартного нормального распределения, а $\varphi(\cdot)$ – плотность стандартного нормального распределения.

Реализовать функцию для расчёта условного математического ожидания можно следующим образом:

```
center_trunc_conditional_mean <- function(x, beta, sigma, a, b) {
  mu <- sum(x * beta)

  z_a <- (a - mu) / sigma
  z_b <- (b - mu) / sigma

  p_obs <- pnorm(z_a) + 1 - pnorm(z_b)

  cond_mean <- mu + sigma * (dnorm(z_b) - dnorm(z_a)) / p_obs

  return(list(
```

```

mu = mu,
z_a = z_a,
z_b = z_b,
p_obs = p_obs,
conditional_mean = cond_mean
))
}

```

Для демонстрации рассмотрим клиента со следующими характеристиками:

$$income_index = 0.5, \quad discount_index = -0.2, \quad activity_index = 1.0.$$

По ранее оценённой модели:

$$\hat{\beta}_0 = 7.0159, \quad \hat{\beta}_{income} = 1.2067, \quad \hat{\beta}_{discount} = -0.8130, \quad \hat{\beta}_{activity} = 0.5915,$$

$$\hat{\sigma} = 2.0023.$$

Границы центрального усечения:

$$a = 6, \quad b = 8.$$

Сначала рассчитаем линейный индекс:

$$\hat{\mu}_i = 7.0159 + 1.2067 \cdot 0.5 - 0.8130 \cdot (-0.2) + 0.5915 \cdot 1.0.$$

Отсюда:

$$\hat{\mu}_i = 8.3734.$$

Стандартизированные границы равны:

$$\hat{z}_{a,i} = \frac{6 - 8.3734}{2.0023} \approx -1.1853,$$

$$\hat{z}_{b,i} = \frac{8 - 8.3734}{2.0023} \approx -0.1865.$$

Вероятность попадания наблюдения в выборку:

$$\hat{P}_i^{obs} = \Phi(-1.1853) + 1 - \Phi(-0.1865) \approx 0.6919.$$

Следовательно, условное математическое ожидание зависимой переменной при условии, что наблюдение попало в выборку, равно:

$$\widehat{E}(y_i^* \mid y_i^* \leq 6 \text{ или } y_i^* \geq 8, x_i) = 8.9361.$$

Таблица 30: Условное математическое ожидание в модели с центральным усечением

Показатель	Значение
$\hat{\mu}_i = x_i \hat{\beta}$	8.3734
$\hat{z}_{a,i}$	-1.1853
$\hat{z}_{b,i}$	-0.1865
$\hat{P}_i^{obs}$	0.6919
$\widehat{E}(y_i^* \mid y_i^* \leq a \text{ или } y_i^* \geq b, x_i)$	8.9361

Таким образом, для выбранного клиента безусловное латентное ожидание равно 8.3734, а условное ожидание при условии попадания в наблюдаемую выборку равно 8.9361. Условное ожидание выше, поскольку при данном значении $\hat{\mu}_i$ и границах (6, 8) условие наблюдаемости сильнее отбирает правый хвост распределения, то есть клиентов с более высокими значениями зависимой переменной.