Домашнее задание №1

Пространственная эконометрика

Пространственные признаки в прогнозировании розничного товарооборота магазинов «Пятерочка»

Воспроизведение исходного ансамбля и результаты эксперимента

Выполнили:

Гончаров Алексей
Дугарев Денис
Русских Никита
Смирнов Владимир
Хмельницкий Богдан

Москва 2026

Постановка задачи и данные

Цель эксперимента - проверить, могут ли пространственные признаки повысить точность прогноза розничного товарооборота (РТО) магазинов «Пятерочка». В основной части исследования пространственные связи изучались эконометрическими методами. Здесь использован более прикладной подход; характеристики соседних населенных пунктов добавлены к признакам моделей градиентного бустинга, после чего сравнивается качество прогнозов.

В исходных данных 485 082 наблюдения за январь 2023 - февраль 2025 года. Каждая строка соответствует магазину в определенном месяце; задача - спрогнозировать РТО за март 2025 года. Соревновательная оценка основана на средней абсолютной процентной ошибке (MAPE):

$$\mathrm{MAPE} = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{\widehat{y}_i - y_i}{y_i}\right|, \qquad S = 100\left(1 - \frac{\min(\mathrm{MAPE}, 100)}{100}\right)^2. \tag{1}$$

В качестве отправной точки взят исходный ансамбль четырех моделей градиентного бустинга над решающими деревьями [3]. Он получил 90,64 балла на публичной части теста и 90,78 балла на полном итоговом тесте. Все результаты нового эксперимента далее приводятся именно для полного теста, если не указано иное. В таблице ниже отдельно указаны результаты для обогащенного пространственными признаками ансамбля из градиентных бустингов и несколько иным видом агрегации прогнозов базовых моделей.

Таблица 1. Сравнение исходного и итогового результатов

Вариант	Публичная часть	Полный тест
Исходный ансамбль	90,64	90,78
Ансамбль с пространственными признаками	-	**90,83**

Источник: расчеты авторов по данным X5 Group.

Исходное решение: отбор признаков и ансамблирование

Процесс отбора признаков здесь достаточно непримечателен, хотя, в двух словах отметить стоит. Для исходного признакового набора генерируется порядка 380 фичей (скользящие окна, лаги, агрегаты и прочие). Далее проводится своего рода скорректированный под особенности задачи Forward Selection с нуля - считаем важность по лоссу базовой модели; например, CatBoost глубиной 5 в качестве базовой модели для всего признакового пространства, а после итеративно отбираем по одной фиче из отсортированного по важности по вкладу в лосс в пул выбранных фичей. Каждые несколько фичей важность исходного набора (уже из оставшихся признаков) пересчитывается и процесс отбора сверху вниз запускается заново (это что-то вроде страховки против дублирования сигналов, а также возможность учета перекрестных значимостей). Само значение вклада в лосс считается усреднением между 5 различными фолдами-месяцами

в данных с различными весами.

Процесс подбора гиперпараметров аналогично проводился по взвешенному значению метрики на валидации, но уже на 3-х фолдах (использовалась Optuna, метод - multivariate TPE) [8, 9].

Но более интересна здесь все же сама модель.

Подсвечу, что отбор признаков происходил для разных моделей вида градиентного бустинга; под разными имею в виду обучение на разных таргетах - логарифм розничного товарооборота и лог-дифференцированное значение розничного товарооборота. Соответственно, признаки были отобраны несколько разные для каждого из бустингов, но с некоторыми пересечениями.

После получения прогнозов на тестовых данных значения прогнозов усреднялись 4-мя различными методами усреднения, а после еще раз усреднялись простым арифметическим средним для итогового предикта.

В общем, фактически, был реализован частный случай стекинга - блендинг с некоторой добавленной стохастичностью. Почему это работает?

Вспомним, что чем менее скоррелированы между собой ошибки базовых алгоритмов, тем сильнее мы снизим дисперсию итогового прогноза:

$$E_N = E_1 \left(\rho + \frac{1 - \rho}{N} \right).$$

Или же словами:

Дисперсия ошибки композиции (ансамбля) из N моделей = Дисперсия ошибки одной из отдельных моделей * (коэффициент корреляции + (1 - коэф. корреляции) / N), где коэффициент корреляции ответственен за корреляцию между ошибками базовых моделей

В задаче, справедливости ради, прогнозы были достаточно схожими (то есть, высокая корреляция перебивала полезный эффект от N моделей), поэтому эффект не был в достаточной мере большим, но так или иначе среднее сглаживало перепрогнозы и недопрогнозы отдельных моделей.

Сама формула, скорее, схематично показывает причину улучшения итогового скора на лидерборде, так как, с большой вероятностью, при ансамблировании ансамблей она становится заметно сложнее, но, тем не менее, по сути является таковой в обычном бэггинге.

Может ли быть оптимальное число моделей в таком ансамбле? Обратимся к комбинаторной теории переобучения:

- Если у нас есть хорошая модель, а остальные - плохие, то хорошая модель будет превалировать и мы не будем переобучаться;
- Если есть много похожих друг на друга хороших моделей, мы тоже не будем переобучаться, так как эффективная сложность совокупности похожих друг на друга моделей невелика;
- Но если получится так, что модели существенно различные и все примерно оди-

наково плохие, то переобучение будет очень сильным, а сам эффект переобучения растет по мере роста числа моделей [1].

Отсюда заметим, что, в целом, если все модели достаточно хорошие, имеет смысл увеличивать их количество; тем не менее, на практике достаточно понять на валидации оптимальное минимальное число.

Прикрепляю схему алгоритма. Так немного проще визуально понять, что именно и каким образом реализуется.

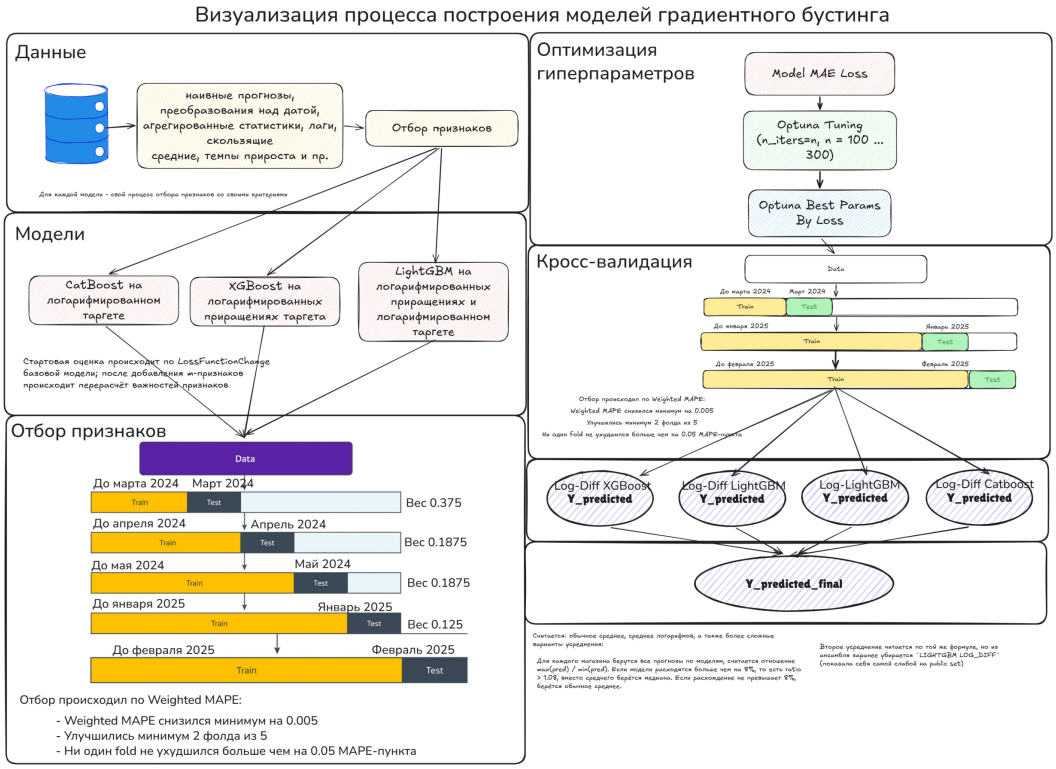


Рисунок 1. Схема алгоритма исходного ансамбля
Источник: составлено авторами.

Состав моделей и правило объединения прогнозов

В новом эксперименте исходные признаки, преобразования целевой переменной и параметры обучения сохранены. Это позволяет отдельно оценить эффект пространственных признаков, не смешивая его с результатом дополнительного подбора гиперпараметров.

Таблица 2. Модели исходного ансамбля

Модель	Целевая переменная	Число деревьев
CatBoost [10]	$\log(1+y)$	6500
LightGBM (приросты) [5]	$\Delta \log y$	7000
LightGBM (уровни)	$\log(1+y)$	8000
XGBoost (приросты) [2]	$\Delta \log y$	3750

Источник: составлено авторами.

Прогнозы моделей, обученных на логарифме РТО, возвращаются к исходной шкале с помощью $\exp(\widehat{z}) - 1$. Для моделей, прогнозирующих логарифмический прирост, применяется $y_{i,t-1}\exp(\widehat{g}_{it})$, где $g_{it} = \log y_{it} - \log y_{i,t-1}$. Ошибка обучения рассчитывается для преобразованной целевой переменной, а итоговая MAPE - для РТО в исходной шкале.

Для четырех прогнозов $p_1, \ldots, p_4$ арифметическое и логарифмическое средние имеют вид:

$$A = \frac{1}{4}\sum_{m=1}^{4} p_m, \qquad L = \exp\left(\frac{1}{4}\sum_{m=1}^{4}\log(1+p_m)\right) - 1. \tag{2}$$

Дополнительно используются два пороговых правила, обозначенные G и H. В G арифметическое среднее заменяется медианой, когда $\max p_m / \min p_m > 1{,}08$; в H действует аналогичное правило, но без модели LightGBM, прогнозирующей приросты. В принятой реализации итоговый прогноз равен:

$$P = \exp\left(\frac{1}{4}\sum_{q\in\{A,L,G,H\}}\log(1+q)\right) - 1. \tag{3}$$

Именно это правило объединения прогнозов было сохранено при основном сравнении составов ансамбля.

Построение пространственных признаков

Основная идея взята из пространственной модели SLX [4], в которой наряду с собственными характеристиками объекта используются характеристики его соседей:

$$y = X\beta + WX\theta + \varepsilon. \tag{4}$$

Здесь W - матрица пространственных весов [6], а WX - взвешенные характеристики соседних территорий. В отличие от линейной модели SLX, в нашем эксперименте WX используется только как дополнительный набор входных признаков бустинга. Прямые и косвенные причинные эффекты не оцениваются.

Прогноз строился для 18 657 магазинов в 3 360 населенных пунктах. Пространственные признаки рассчитывались на уровне населенного пункта, а затем присоединялись к наблюдениям отдельных магазинов. Таким образом, исходная панель магазинов не заменялась агрегированными данными.

Для построения W проверены два варианта соседства: по 6 и по 12 ближайшим населенным пунктам (kNN6 и kNN12). Расстояния между пунктами рассчитывались в метрической проекции Альберса с эллипсоидом Красовского. Если один населенный пункт входит в список ближайших соседей другого, связь учитывается в обе стороны. Затем веса нормируются так, чтобы их сумма для каждой строки равнялась единице:

$$w_{rv} = \frac{a_{rv}}{\sum_u a_{ru}}, \qquad w_{rr} = 0, \qquad \sum_v w_{rv} = 1. \tag{5}$$

Для числового признака сначала находится среднее по магазинам населенного пункта, затем - взвешенное среднее по соседним пунктам:

$$\overline{x}_{rjt} = \frac{1}{|\mathcal{I}_{rj}^{\text{obs}}(t)|} \sum_{i \in \mathcal{I}_{rj}^{\text{obs}}(t)} x_{ijt}, \qquad (WX)_{rjt} = \sum_v w_{rv} \overline{x}_{vjt}. \tag{6}$$

Магазины одного населенного пункта не считаются соседями друг для друга при расчете WX. Для каждой модели формируется свой набор пространственных признаков на основе доступных исходных переменных; идентификаторы и технические поля в него не включаются. В итоге к CatBoost было добавлено 39 признаков, к LightGBM приростов - 22, к LightGBM уровней - 33, к XGBoost - 14. Часть общих календарных признаков после пространственного усреднения остается неизменной и не дает нового сигнала.

Для прогноза марта использовались только сведения, доступные к концу февраля. Фактический мартовский РТО не применялся при построении признаков; исторические лаги, напротив, были допустимы. Это важно, чтобы избежать утечки целевой переменной. Пропущенные значения в пространственных признаках сохранялись без дополнительного заполнения.

Эксперименты и результаты

Выбор пространственных признаков на исторических данных

Для каждой из четырех моделей были проверены исходная версия без WX и два варианта с kNN6 и kNN12. Сначала варианты сравнивались по средней MAPE за август, ноябрь и декабрь 2024 года. Затем выбранные пространственные версии и исходные модели проверялись на январе и феврале 2025 года. В каждом случае обучение проводилось только на предшествующих месяцах.

Таблица 3. MAPE на этапе отбора пространственных признаков, %

Модель	Без WX	kNN6	kNN12	Выбор
CatBoost, уровни	4,333	4,238	4,217	$k = 12$
LGB, приросты	5,335	4,179	4,080	$k = 12$
LGB, уровни	3,766	3,786	3,812	$k = 6$
XGBoost, приросты	4,864	4,744	4,664	$k = 12$

Источник: расчеты авторов по данным X5 Group и GeoNames.

Таблица 4. MAPE на проверке в январе и феврале 2025 года, %

			Январь		Февраль	
Модель	Деревья	k	До	С WX	До	С WX
CatBoost, уровни	6 500	12	4,276	3,961	4,264	4,448
LGB, приросты	7 000	12	4,003	4,000	5,122	4,689
LGB, уровни	8 000	6	4,179	4,242	4,645	5,169
XGBoost, приросты	3 750	12	4,030	4,064	4,428	4,714

Источник: расчеты авторов по данным X5 Group и GeoNames.

Здесь результаты получились неоднозначными. CatBoost стал точнее в январе, но хуже в феврале. LightGBM, прогнозирующий логарифмические приросты, улучшил MAPE в обоих месяцах; в феврале ошибка снизилась с 5,122 до 4,689%. Два других бустинга - LightGBM уровней и XGBoost - на этих месяцах уступили исходным версиям. Поэтому по предварительному критерию для замены в ансамбле подходил только LightGBM приростов.

Результаты отдельных моделей на мартовском тесте

Таблица 5. Итоговый балл отдельных моделей до и после добавления WX

Модель	Без WX	С WX	Изменение
CatBoost, уровни	90,55	90,39	-0,16
LGB, приросты	90,32	90,24	-0,08
LGB, уровни	90,57	90,55	-0,02
XGBoost, приросты	90,45	90,58	0,13

Источник: расчеты авторов по данным X5 Group и GeoNames.

На полном тесте марта результат улучшился только у XGBoost: с 90,45 до 90,58 балла. CatBoost потерял 0,16 балла, LightGBM приростов - 0,08, LightGBM уровней - 0,02. Следовательно, преимущество LightGBM приростов на январе и феврале не перенеслось на март, а XGBoost, наоборот, показал улучшение.

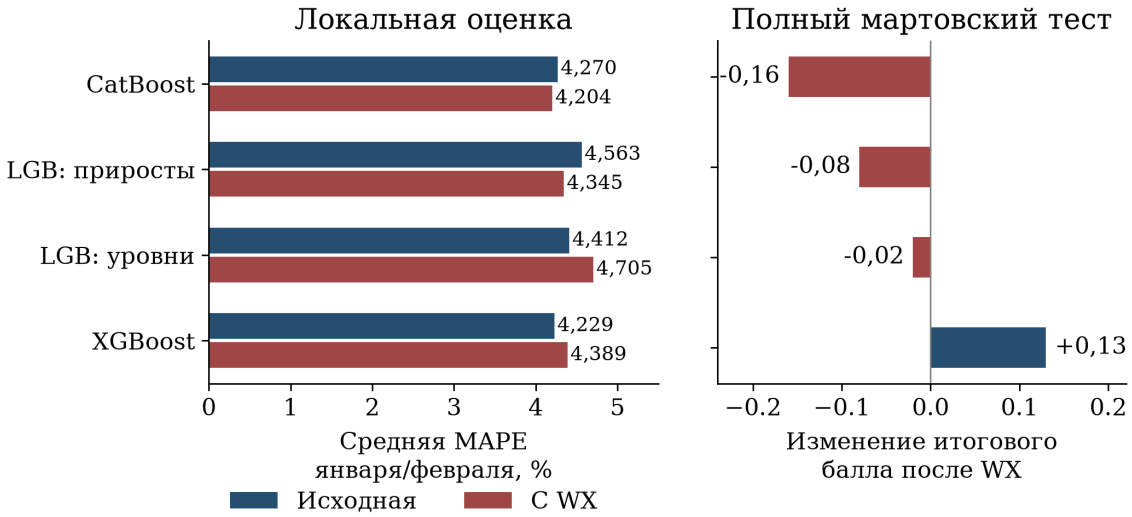


Рисунок 2. Изменение ошибок на исторических месяцах и баллов на мартовском тесте
Источник: составлено авторами по данным X5 Group и GeoNames.

Эти результаты наглядно показывают, что качество отдельных моделей на исторических месяцах не всегда соответствует их результату на итоговом тестовом наборе данных в рамках соревнования. При этом важно оценивать не только отдельные прогнозы, но и их сочетание в ансамбле.

Сравнение составов ансамбля

Чтобы сравнение было корректным, формула объединения прогнозов (3) не менялась. В каждом варианте заменялись только отдельные исходные модели на версии с пространственными признаками.

Таблица 6. Сравнение составов ансамбля

Модели с пространственными признаками	Январь, %	Февраль, %	Балл за март
Нет (исходный ансамбль)	3,811945	4,265305	90,78
Только LightGBM приростов	3,807809	4,209390	90,78
Все четыре модели	3,763799	4,263002	90,79
Только XGBoost	3,796333	4,291810	90,80
CatBoost и XGBoost	3,754268	4,209174	90,76
XGBoost и LightGBM приростов	3,789656	4,240780	90,82
XGBoost и LightGBM уровней	3,805225	4,402870	90,81
XGBoost и оба LightGBM	3,799520	4,349020	**90,83**

Источник: расчеты авторов по данным X5 Group и GeoNames.

Предварительно выбранная замена LightGBM приростов уменьшила среднюю MAPE января и февраля с 4,038625 до 4,008600%, но на мартовском тесте балл остался равным 90,78. Сочетание CatBoost и XGBoost с WX, лучшее среди приведенных вариантов по историческим месяцам, получило только 90,76.

Лучший мартовский результат, 90,83, получен при сохранении исходного CatBoost и замене XGBoost и двух LightGBM на версии с WX. При этом средняя MAPE января и февраля у этого ансамбля составила 4,074270% против 4,038625% у исходного. Таким образом, отбор по январю и февралю не привел бы к выбору именно этого состава.

Важно, что замена LightGBM, взятая отдельно, могла ухудшить его балл, но оказаться полезной в ансамбле. По сути, это не является противоречием; вклад модели в итоговый прогноз зависит также от ошибок других компонентов.

Дополнительное сравнение способов усреднения

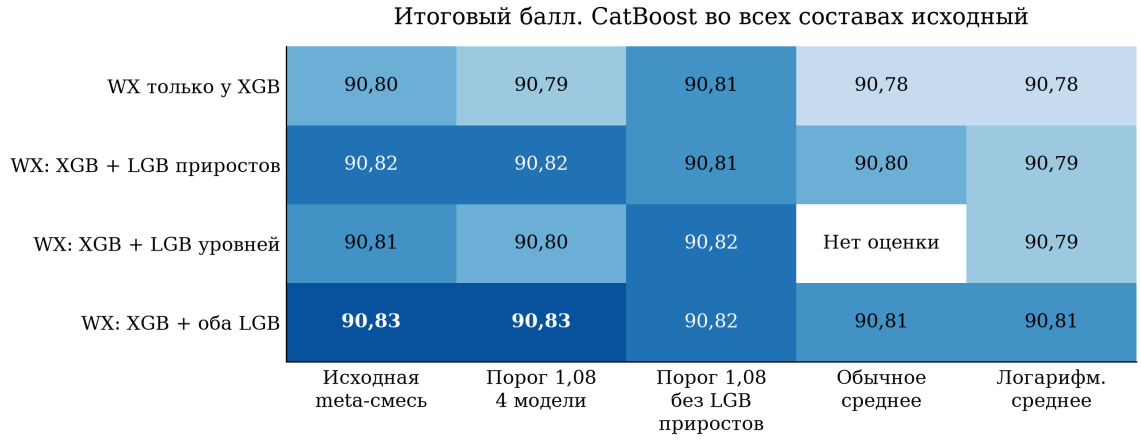


Рисунок 3. Результаты вариантов усреднения на мартовском тесте
Источник: составлено авторами по данным X5 Group и GeoNames.

Максимальные 90,83 балла получили два варианта: исходное правило ансамблирования с WX у XGBoost и обоих LightGBM (далее A) и вариант той же четверки с

пороговым выбором медианы при расхождении прогнозов более 1,08 (далее B). Простое арифметическое и логарифмическое средние этих четырех моделей дали по 90,81 балла.

Также были рассмотрены два состава с результатом 90,82: C - с WX у XGBoost и LightGBM приростов и пороговым правилом; D - с WX у XGBoost и LightGBM уровней, без LightGBM приростов. Заключительная проверка касалась пяти способов объединения готовых ансамблей:

Таблица 7. Сравнение комбинаций готовых ансамблей

№	Способ объединения	Балл за март
1	Арифметическое среднее A, B	90,83
2	Логарифмическое среднее A, B	90,83
3	Арифметическое среднее A, B, C	90,83
4	Арифметическое среднее A, B, D	90,83
5	Логарифмическое среднее A, B, D	90,83

Источник: расчеты авторов по данным X5 Group и GeoNames.

Ни один вариант не превысил результат 90,83 балла после округления. Для окончательного решения оставлен ансамбль A: он обеспечивает тот же результат без дополнительного уровня усреднения. Однако по опубликованным округленным оценкам нельзя утверждать, что его точная ошибка минимальна среди всех проверенных вариантов.

Пространственная зависимость ошибок и ограничения

Для февраля 2025 года дополнительно рассчитан индекс Морана [7] по средним относительным ошибкам магазинов внутри населенных пунктов:

$$e_r = \text{mean}_{i \in r} \left[\frac{y_i - \widehat{y}_i}{y_i} \right]. \tag{7}$$

Значимость проверялась перестановочным тестом с 999 перестановками. Здесь, в отличие от MAPE по магазинам, каждая территория имеет одинаковый вес.

Таблица 8. Индекс Морана для ошибок прогноза, февраль 2025 года

Модель	k	До	С WX	p-значение
CatBoost, уровни	12	0,0657	0,0565	0,001
LGB, приросты	12	0,0559	0,0524	0,001
LGB, уровни	6	0,0960	0,0980	0,001
XGBoost, приросты	12	0,0710	0,0470	0,001

Источник: расчеты авторов по данным X5 Group и GeoNames.

Пространственная зависимость ошибок сохраняется. Например, у XGBoost индекс Морана уменьшился с 0,0710 до 0,0470, хотя февральская MAPE выросла с 4,428 до 4,714%. Следовательно, уменьшение пространственной автокорреляции само по себе еще не означает улучшения точности прогноза.

До основного эксперимента также рассматривались признаки на основе истории соседей, локальных пространственных статистик и собственных векторов матрицы весов, а также варианты пространственных эконометрических моделей. Некоторые из них улучшали показатели на отдельных исторических периодах, но не дали устойчивого выигрыша на мартовском тесте. В отдельной проверке ранняя остановка при обучении также ухудшила качество относительно исходного режима. Поэтому эти варианты не вошли в окончательный ансамбль.

Есть важное ограничение: после получения результатов полного мартовского теста они использовались при сравнении составов ансамбля. Следовательно, 90,83 балла - результат на конкретном уже проверенном тесте, а не независимая оценка качества на будущих месяцах. Кроме того, без истинных значений мартовского РТО нельзя изучить корреляции ошибок базовых моделей и проверить статистическую устойчивость полученного улучшения.

Выводы

Добавление пространственных признаков позволило повысить результат исходного ансамбля с **90,78 до 90,83 балла** на полном мартовском тесте. По формуле соревновательной метрики это приблизительно соответствует снижению MAPE с 4,7215 до 4,6952%, то есть на **0,0262 процентного пункта**, или примерно на 0,56% относительно исходной ошибки. Значения MAPE приближенные, поскольку баллы опубликованы с округлением.

При улучшении итогового результата с **90,78 до 90,83 балла** команда поднялась бы с **21-22-го на 12-е место** в общем рейтинге и с **8-го на 5-е место** среди команд, приглашенных на защиту. Таким образом, даже относительно небольшое улучшение качества прогноза позволило бы существенно повысить позицию команды в итоговом рейтинге.

Наиболее полезной отдельной пространственной версией оказалась XGBoost. Но в лучшем ансамбле были также заменены оба LightGBM, хотя по отдельности их баллы ухудшились. CatBoost остался без пространственных добавок. Эксперименты с дополнительным усреднением не улучшили округленный итоговый результат.

Таким образом, пространственные характеристики соседних населенных пунктов могут давать дополнительный сигнал для прогнозирования РТО, но эффект в этом эксперименте оказался небольшим и зависел от состава ансамбля; тем не менее, как таковой выигрыш от новых признаков заметен.

Материалы эксперимента

Для воспроизведения результатов использованы исходные данные и ноутбук конкурсного решения, сохраненные прогнозы и материалы семинаров по пространственной эконометрике. Рабочие файлы, таблицы и результаты проверок собраны в отдельном каталоге проекта. Исходные файлы основного эконометрического исследования не изменялись.

Список литературы

[1] Воронцов, К. В. Математические методы прогнозирования объемов продаж / К. В. Воронцов // ПостНаука : канал YouTube. - 2016. - 25 февраля. - URL: https://www.youtube.com/watch?v=u3lhVV3wAKk (дата обращения: 13.10.2026).

[2] Chen, T. XGBoost: A Scalable Tree Boosting System / T. Chen, C. Guestrin // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. - 2016. - P. 785-794.

[3] Friedman, J. H. Greedy Function Approximation: A Gradient Boosting Machine / J. H. Friedman // Annals of Statistics. - 2001. - Vol. 29, No. 5. - P. 1189-1232.

[4] Halleck Vega, S. The SLX Model / S. Halleck Vega, J. P. Elhorst // Journal of Regional Science. - 2015. - Vol. 55, No. 3. - P. 339-363.

[5] LightGBM: A Highly Efficient Gradient Boosting Decision Tree / G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, T.-Y. Liu // Advances in Neural Information Processing Systems. - 2017. - Vol. 30. - P. 3146-3154.

[6] LeSage, J. Introduction to Spatial Econometrics / J. LeSage, R. K. Pace. - Boca Raton : Chapman and Hall/CRC, 2009.

[7] Moran, P. A. P. Notes on Continuous Stochastic Phenomena / P. A. P. Moran // Biometrika. - 1950. - Vol. 37, No. 1/2. - P. 17-23.

[8] Optuna: A Next-generation Hyperparameter Optimization Framework / T. Akiba, S. Sano, T. Yanase, T. Ohta, M. Koyama // Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. - 2019. - P. 2623-2631.

[9] Algorithms for Hyper-Parameter Optimization / J. Bergstra, R. Bardenet, Y. Bengio, B. Kegl // Advances in Neural Information Processing Systems. - 2011. - Vol. 24. - P. 2546-2554.

[10] CatBoost: Unbiased Boosting with Categorical Features / L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin // Advances in Neural Information Processing Systems. - 2018. - Vol. 31. - P. 6638-6648.