Пространственная эконометрика

Пространственные эффекты в выручке продуктового ритейла

Моделирование розничного товарооборота магазинов сети «Пятерочка» по локальным рынкам России

Гончаров Алексей · Дугарев Денис · Русских Никита
Смирнов Владимир · Хмельницкий Богдан

Домашнее задание

Москва, 2026

Вопрос исследования и план

Исследовательский вопрос

Как выручка магазина связана с конкуренцией и окружением соседних локальных рынков?

1. **Часть I. Объяснение выручки**
   Данные и гипотезы; срез, панель, динамика и GWR; выводы
2. **Часть II. Прогноз на март 2025 года**
   Ансамбль бустингов; пространственные признаки; качество прогноза

Соседство может расширять спрос и одновременно усиливать конкуренцию

Часть I.

Пространственная эконометрика

Данные: локальный рынок и выручка магазина

X5 Group + Росстат + GeoNames. Январь 2023 - февраль 2025

933 населенных пункта, 67 регионов, 15 683 магазина; не менее 3 магазинов сети на рынок. Панель: $933 \times 26 = 24\,258$

Зависимая переменная: панель и срез

Панель: рынок *i*, месяц *t*

$$y_{it} = \ln\left(\frac{1}{n_i}\sum_{k\in i} RTO_{kt}^{\text{real}}\right)$$

Срез: среднее за 26 месяцев

$$\bar{y}_i = \frac{1}{26}\sum_{t=1}^{26} y_{it}$$

n_i - число магазинов рынка; реальная выручка в ценах января 2023 года

$\bar{y}_i$ используется в SDM и GWR; y_{it} - в панели и динамике

Признаки: население, домохозяйства, пеший и автомобильный трафик; конкуренты и плотность сети; инфраструктура и формат магазина; зарплата и безработица

Координаты доступны на уровне населенного пункта; агрегирование снижает индивидуальный шум. Выводы относятся к рынкам с несколькими магазинами сети

Локальные рынки в нашей выборке



933 населенных пункта в 67 субъектах. Размер точки - число магазинов сети. Источник: расчеты авторов по X5 Group и GeoNames

Гипотезы: конкуренция и связи соседних рынков

H1 Соседние рынки образуют кластеры схожей выручки
$H_0 : I = E(I), \qquad H_1 : I > E(I)$

H2 Связь с выручкой соседей сохраняется при учете характеристик
$H_0 : \rho = 0, \qquad H_1 : \rho \neq 0$

H3 Больше конкурентов и магазинов своей сети - ниже выручка
$H_0 : ADE_m = 0, \quad H_1 : ADE_m < 0, \quad m \in \{comp, dens\}$

H4 Выручка связана с характеристиками соседних рынков
$H_0 : AIE_m = 0, \qquad H_1 : AIE_m \neq 0$

H5 Пространственная модель лучше МНК описывает выручку
$H_0 : \rho = 0$ и $\theta = 0, \quad H_1 : \rho \neq 0$ или $\theta \neq 0$

H6 Месячные отклонения соседей связаны после FE рынка и месяца
SAR FE: $H_0 : \rho = 0, \quad H_1 : \rho \neq 0$
SEM FE: $H_0 : \lambda = 0, \quad H_1 : \lambda \neq 0$

ADE/AIE - средние прямой/косвенный эффекты; *comp* - конкуренты, *dens* - плотность сети. В H3 и H4 показатели проверяются отдельно

Матрицы весов: что сравнили и выбрали

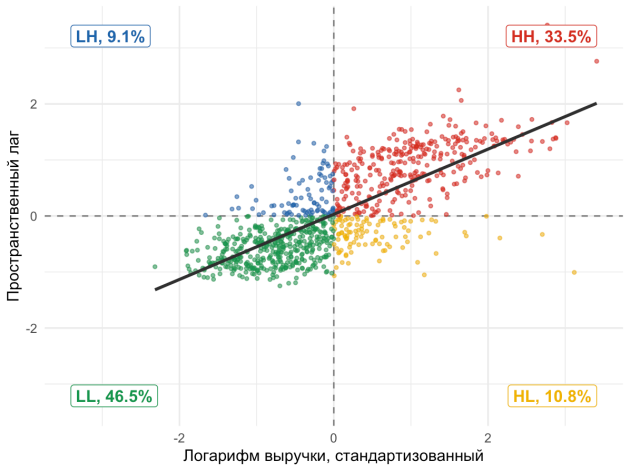
- **Экспоненциальные веса: масштаб 50 км, отсечение 300 км**
- 8 ближайших соседей (kNN), связи симметризованы
- Обратные расстояния $1/d$, до 200 км
- Обратные квадраты расстояний $1/d^2$, до 400 км
- Пороговая матрица: соседи в радиусе 100 км
- Экономическая близость: 10 соседей по логарифму населения

$$\widetilde{w}_{ij} = e^{-d_{ij}/50}\mathbf{1}\{d_{ij} < 300 \text{ км}\}, \quad w_{ij} = \frac{\widetilde{w}_{ij}}{\sum_{k \neq i} \widetilde{w}_{ik}}, \quad w_{ii} = 0$$

Почему выбрали: наибольшее правдоподобие SAR и SDM среди шести W при одинаковых данных и регрессорах

d_{ij} - расстояние в км, 50 км задает скорость убывания весов. Глобальный индекс Морана $I = 0{,}582$, $p = 0{,}001$ (999 перестановок). Источник: расчеты авторов

Пространственная связь выручки: глобальные индексы



Глобальный индекс Морана *I*
$0{,}582$, $p = 0{,}001$

Глобальный индекс Гири *C*
$0{,}434$, $p < 0{,}001$

Статистика Гетиса-Орда *G*
$0{,}02637$, $p < 0{,}001$

HH + LL: около 80% рынков

На осях: стандартизованный показатель $\bar{y}_i$ и его пространственный лаг. Для *I*: 999 перестановок; для *G*: уровни реальной выручки и бинарное соседство 100 км. Источник: расчеты авторов

Где находятся кластеры высокой и низкой выручки



Локальный индекс Морана I_i

HH: высокий - высокий
224 населенных пункта

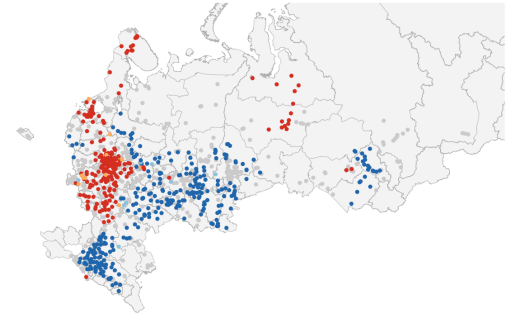
LL: низкий - низкий
212 населенных пунктов

Всего значимы **484 из 933** рынков

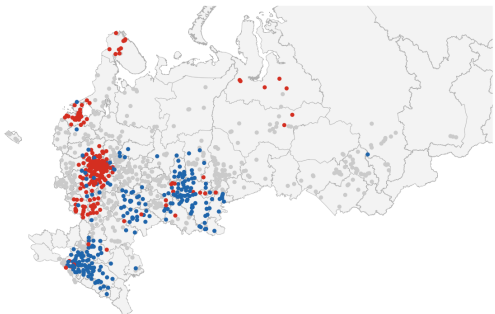
Границы субъектов сохранены. Двусторонний перестановочный тест, 9999 перестановок, BH-FDR 5%.
Источник: расчеты авторов

Локальные статистики: Гири и Гетис-Орд

Локальный индекс Гири



Статистика Гетиса-Орда G_i^*



BH-FDR 5%. Гири: 248 пунктов со сходством высоких и 294 со сходством низких значений. Гетис-Орд: 246 пунктов в горячих и 241 в холодных зонах. Источник: расчеты авторов

Выбор пространственной модели

Два подхода к выбору спецификации

От частной к общей: МНК, LM / робастные LM $\longrightarrow$ SAR
От общей к частной: GNS и LR-тесты $\longrightarrow$ SDM

$$\text{GNS:} \quad \bar{y} = \rho W\bar{y} + \alpha\mathbf{1} + X\beta + WX^D\theta + u, \qquad u = \lambda Wu + \varepsilon$$

$\rho W\bar{y}$ - связь усредненной выручки соседей; $X\beta$ - свои характеристики
$WX^D\theta$ - характеристики соседей; λWu - зависимость ошибок

X^D: население, домохозяйства, оба вида трафика, конкуренты, плотность сети. В X также входят остальные контроли со слайда данных

Выбрана SDM: $\lambda = 0$, сохраняются $W\bar{y}$ и WX^D
LR: $\lambda = 0$ в GNS: $p = 0{,}271$; $\theta = 0$ в SDM: $p < 0{,}001$

SAR - предварительный выбор: оба робастных LM значимы. Дополнительно: AIC/BIC и остатки; ML и пространственный 2МНК с ошибками Уайта. Инструменты X, WX, W^2X для $W\bar{y}$ требуют экзогенности X

SDM: конкуренция и региональная среда

	Основная SDM	SDM + FE субъектов
ρ	$0{,}474^{***}$	$0{,}204^{***}$
Прямой эффект конкурентов	$-0{,}027^{***}$	$-0{,}026^{***}$
Косвенный эффект населения	$-0{,}110^{***}$	$-0{,}004$
Косвенный эффект автотрафика	$0{,}121^{**}$	$0{,}008$
Косвенный эффект плотности сети	$0{,}153^{**}$	$0{,}075$

Источник: расчеты авторов. ML для $\bar{y}_i$, $N = 933$; ** $p < 0{,}05$, *** $p < 0{,}01$. Для эффектов - 2000 симуляций

Связь с конкурентами устойчива; косвенные эффекты зависят от учета регионов

+1 к среднему числу конкурентов в радиусе 500 м: $100(e^{-0{,}027} - 1) = -2{,}66\%$. Прямой эффект собственной сети незначим

2МНК: $\rho = 0{,}495$ (SE $0{,}052$); робастный Wald для $\theta = 0$: $p < 0{,}001$. AIC предпочитает SDM, BIC - SAR

Панель: связь месячных отклонений

$$y_{it} = \rho \sum_j w_{ij} y_{jt} + x'_{it}\beta + \mu_i + \tau_t + u_{it},$$

$$u_{it} = \lambda \sum_j w_{ij} u_{jt} + \varepsilon_{it}$$

SARAR FE: обе компоненты; SAR FE: $\lambda = 0$; SEM FE: $\rho = 0$

μ_i - постоянный уровень рынка; τ_t - общий эффект месяца
x_{it} - логарифм реальной зарплаты и безработица; постоянные признаки поглощаются μ_i.
$N = 933$, $T = 26$

Отдельная проверка: эффекты «субъект $\times$ месяц»

$$y_{it} = \mu_i + \delta_{r(i),t} + e_{it}$$

$\delta_{r(i),t}$ - свой месячный уровень каждого субъекта

Пространственного лага нет; W используется при проверке остатков. Постоянные признаки поглощены μ_i; зарплата и безработица - $\delta_{r(i),t}$

Панель: общие шоки имеют значение

Параметр	SAR FE	SEM FE	SARAR FE
Лаг выручки ρ	$0{,}671^{***}$		$0{,}357^{*}$
Ошибка λ		$0{,}672^{***}$	$0{,}447^{***}$

ML; * $p < 0{,}10$, *** $p < 0{,}01$. SARAR: $p_\rho = 0{,}058$, $p_\lambda = 0{,}009$. SE не учитывают связь ошибок во времени

Средний по месяцам глобальный индекс Морана I остатков: FE $0{,}242$; SAR FE $-0{,}002$; SEM FE $-0{,}001$

Отдельная FE-проверка региональных месячных шоков

Диагностика остатков	FE рынка и месяца	FE рынка и «субъект $\times$ месяц»
Глобальный индекс Морана I / Диапазон по месяцам	$0{,}17 \ldots 0{,}35$	$-0{,}03 \ldots 0{,}08$
CD-статистика Песарана	$47{,}2^{***}$	$26{,}3^{***}$

Региональные шоки важны; зависимость между рынками сохраняется

Динамика: инерция и связь во времени

Обычная динамическая панель

$$y_{it} = \gamma y_{i,t-1} + x'_{it}\beta + \mu_i + \tau_t + \varepsilon_{it}$$

γ - инерция выручки. МНК и FE сопоставляются с Ареллано-Бондом и системным GMM; проверяем AR(2) и J-тест

Пространственная динамика $y_t = (y_{1t}, \ldots, y_{Nt})'$

$$y_t = \gamma y_{t-1} + \rho W y_t + \eta W y_{t-1} + X_t\beta + WX_t\theta + \mu + \tau_t \mathbf{1} + \varepsilon_t$$

ρ - одновременная связь; η - связь с прошлой выручкой соседей. В динамической SAR $\theta = 0$; в SDM лагируются региональные регрессоры

Оценивание

ML с двунаправленными FE и коррекцией смещения Ли-Ю. Она нужна из-за смещения порядка $1/T$ при конечном числе месяцев

Динамика: инерция и ограничения GMM

Метод	$\widehat{\gamma}$ (SE)	J, p	AR(2), p
МНК с эффектами времени	$0{,}983$ $(0{,}002)$		
FE	$0{,}758$ $(0{,}008)$		
Ареллано-Бонд, лаги 2-4	$0{,}817$ $(0{,}034)$	$< 0{,}001$	$0{,}226$
Системный GMM, лаги 2-4	$0{,}958$ $(0{,}021)$	$< 0{,}001$	$0{,}150$

J: моментные условия отвергнуты; AR(2): автокорреляция 2-го порядка не выявлена

Источник: расчеты авторов. МНК/FE: кластеризация SE по рынкам; GMM: робастные двухшаговые SE. Сопоставимые месяцы 3-26

Пространственная SAR после коррекции: $\gamma = 0{,}831$, $\rho = 0{,}643$, $\eta = -0{,}520$.
Ограничение $\eta + \gamma\rho = 0$: $p = 0{,}066$

Инерция выражена, но GMM не проходит проверку моментных условий

Ограничение не отвергается на 5%; это не доказывает отсутствие передачи прошлой выручки

GWR: одинаковы ли связи по территории?

$$\bar{y}_i = \beta_0(u_i, v_i) + \sum_m \beta_m(u_i, v_i) x_{im} + \varepsilon_i$$

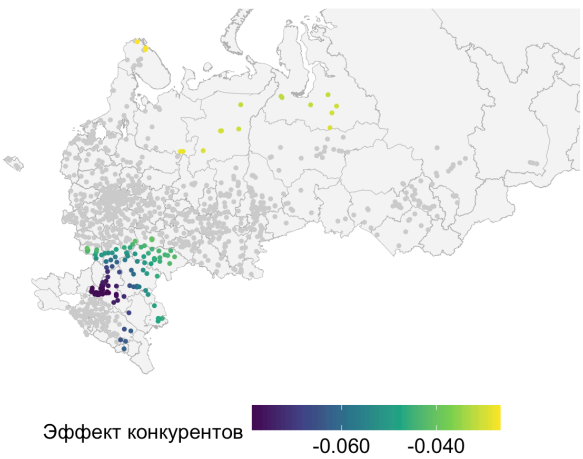
$\bar{y}_i$ - показатель среза; (u_i, v_i) - координаты рынка. Коэффициенты оцениваются локально, с большим весом ближайших наблюдений

- Адаптивное гауссовское окно: кросс-валидация выбрала **61 ближайший населенный пункт**
- Проверяем постоянство коэффициентов и локальные оценки с поправкой Бонферрони
- Сравниваем GWR, МНК и SDM по **одному критерию AICc**

Локальные различия связей

Оцениваем все характеристики рынка. Карта конкурентов показывает, где отрицательная связь с выручкой сильнее

GWR: конкуренция почти везде отрицательна



Локальный коэффициент конкурентов

Диапазон: $-0{,}079 \ldots 0{,}003$
Медиана: $-0{,}029$

После Бонферрони значимы **124 оценки**, все отрицательные

Автотрафик: 35 значимых оценок, все положительные

AICc, меньше лучше

МНК: общие β	$-525{,}3$
GWR: местные β_i	$-730{,}0$
SDM: связи соседей	$-819{,}6$

Источник: расчеты авторов. Глобальный индекс Морана I остатков GWR $= 0{,}102$: ошибки пространственно зависимы, локальная значимость предварительна. Бонферрони структуру ошибок не исправляет

Часть I: результаты проверки гипотез

Гипотеза и итог	Показатель из работы
H1. Кластеры выручки Поддержана	Глобальный индекс Морана $I = 0{,}582$ Перестановочный тест: $p = 0{,}001$
H2. Связь выручки соседей Поддержана	SDM: $\rho = 0{,}474^{***}$ С FE субъектов: $\rho = 0{,}204^{***}$
H3. Конкуренция и своя сеть Частично: только конкуренты	Конкуренты: $ADE = -0{,}027^{***}$ Плотность сети: $ADE = 0{,}002$, $p = 0{,}89$
H4. Характеристики соседей Неустойчива к FE субъектов	Население: $AIE = -0{,}110^{***} \rightarrow -0{,}004$ с FE Автотрафик и сеть: с FE незначимы
H5. SDM лучше МНК Поддержана	$LR = 308{,}9$, $p < 0{,}001$ AIC: $-525{,}8 \rightarrow -820{,}7$
H6. Месячная связь соседей Поддержана при предпосылках ML	SAR FE: $\rho = 0{,}671^{***}$ SEM FE: $\lambda = 0{,}672^{***}$

Условные связи; панельная значимость зависит от предпосылок ML. *** $p < 0{,}01$

Часть II.

Прогнозирование

Исходное решение: как устроен ансамбль

Градиентный бустинг для прогноза РТО магазинов за март 2025 года

Подготовка признаков

Около **380 признаков**: лаги, скользящие средние, агрегаты и темпы прироста

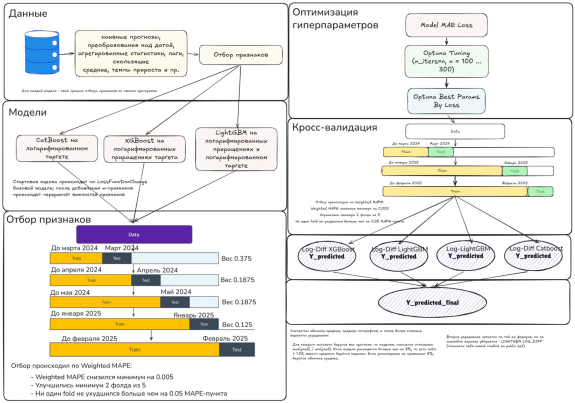
Отбор и настройка

Forward Selection: оценка важности на **5 месячных фолдах** с периодическим пересчетом
Optuna: взвешенная MAPE на **3 фолдах**

Итоговый прогноз

Четыре модели с разными признаками и двумя целевыми переменными. Далее - **блендинг**

Визуализация процесса построения моделей градиентного бустинга



Подробная схема обучения, проверки и объединения моделей

Почему ансамбль может улучшать прогноз?

Разные целевые переменные, наборы признаков и ошибки моделей

Четыре модели в исходном решении

Модель	Целевая переменная
CatBoost	$\log(1+y)$
LightGBM уровней	$\log(1+y)$
LightGBM приростов	$\Delta \log y$
XGBoost приростов	$\Delta \log y$

Для каждой модели признаки отбирались отдельно; наборы совпадали лишь частично

Как объединялись прогнозы

Четыре правила: арифметическое, логарифмическое и два пороговых (медиана при расхождении свыше **8%**). Затем логарифмическое усреднение

Интуиция снижения дисперсии

$$E_N = E_1\left(\rho + \frac{1-\rho}{N}\right)$$

Здесь N - число моделей, ρ - корреляция их ошибок, E_1 - дисперсия ошибки одной модели. Формула относится к среднему моделей с одинаковой дисперсией ошибок и общей попарной корреляцией

- **Низкая корреляция** ошибок усиливает эффект усреднения
- Слишком похожие модели дают небольшой дополнительный выигрыш
- Важно сочетать **достаточно точные и разные** прогнозы, а не просто увеличивать число моделей

Наш эксперимент: пространственные признаки *WX*

Учитываем характеристики соседних населенных пунктов, не меняя исходные модели

От пространственной модели SLX к бустингу

$$y = X\beta + WX\theta + \varepsilon$$

В бустинге *WX* используется как **дополнительный набор признаков**, без оценивания причинных эффектов SLX

1. Строим матрицу весов W по **6 или 12 ближайшим** населенным пунктам, нормируем строки
2. Усредняем признаки магазинов в каждом пункте и рассчитываем среднее по соседям:

$$(WX)_{rjt} = \sum_{v} w_{rv}\, \overline{x}_{vjt}$$

3. Присоединяем полученные признаки к наблюдениям магазинов

Масштаб данных

18 657	**3 360**
магазинов	населенных пунктов

Количество добавленных *WX*-признаков

CatBoost	**39**
LightGBM приростов	**22**
LightGBM уровней	**33**
XGBoost	**14**

Для мартовского прогноза использовались только сведения, доступные к концу февраля

Итог: пространственные признаки и качество прогноза

Полный мартовский тест соревнования, балл по MAPE

Результат отдельных составов ансамбля

Модели с *WX*	**Балл**
Без *WX* (исходный ансамбль)	90,78
Только XGBoost	90,80
XGBoost и LightGBM приростов	90,82
XGBoost и оба LightGBM	**90,83**

- CatBoost в лучшем составе остался **исходным**
- XGBoost отдельно: **90,45** $\rightarrow$ **90,58**; оба LightGBM по отдельности ухудшились
- Дополнительное усреднение готовых ансамблей не повысило округленный балл

Изменение итоговой метрики

90,78 $\longrightarrow$ **90,83**

MAPE: $4{,}7215\%$ $\rightarrow$ $4{,}6952\%$

Снижение примерно на **0,0262 процентного пункта**

Если пересчитать места в рейтинге

Общее место: **21-22** $\rightarrow$ **12**

Среди приглашенных на защиту: **8** $\rightarrow$ **5**

Ограничение: составы сравнивались с учетом баллов полного теста. Это не независимая оценка качества на будущих месяцах

Пространственная эконометрика

Пространственные эффекты в выручке продуктового ритейла

Моделирование розничного товарооборота магазинов сети «Пятерочка» по локальным рынкам России

Гончаров Алексей · Дугарев Денис · Русских Никита
Смирнов Владимир · Хмельницкий Богдан

Домашнее задание

Москва, 2026