Факультет Экономических Наук

Департамент прикладной экономики

Москва, НИУ ВШЭ, 22.09.2026

Лекция 3.
Базовые пространственные модели для данных типа cross-section

Демидова Ольга Анатольевна, Профессор ДПЭ ФЭН,
demidova@hse.ru

План лекции 3

- Тесты для выявления пространственной зависимости в ошибках регрессии,
- Модель пространственной ошибки (SEM),
- Модель пространственной автокорреляции (SAR)
- Модель Дарбина (SDM)
- Выбор между моделями

Тесты для выявления пространственной зависимости в ошибках регрессии

Когда в линейных регрессионных моделях в качестве объектов наблюдений используются страны, регионы и т.д. имеющие общие границы, потоки товаров и услуг и т.п., то предположение и независимости этих наблюдений, которое входит в условие теоремы Гаусса-Маркова, является нереалистичным. Если пространственная зависимость между факторами в моделях, оцениваемым по таким наблюдениям, не учтена, то она проявится в ошибках регрессии.

Поэтому при моделировании процессов с использованием региональных данных широкое распространение получили модели с пространственной зависимостью в ошибках.

Модель с пространственной зависимостью в ошибках

Пространственную зависимость шоков для соседних географических единиц можно учитывать с помощью модели с пространственной зависимостью в ошибках SEM (spatial error model):

$$Y = X\beta + \varepsilon, \varepsilon = \lambda W\varepsilon + u$$

Модель с пространственной зависимостью в ошибках

$$Y = X\beta + \varepsilon, \varepsilon = \lambda W\varepsilon + u,$$

n – число наблюдений, Y – зависимая переменная, i_n единичный n-мерный вектор, X – матрица объясняющих переменных, β – оцениваемые коэффициенты, ε – ошибки регрессии, W - пространственная матрица, λ – коэффициент пространственной корреляции ошибок регрессии, u – независимые одинаково распределенные случайные величины с дисперсией σ_u^2 (обычно делается предположение, что они нормально распределены).

Модель с пространственной зависимостью в ошибках

$$Y = X\beta + \varepsilon,\ \varepsilon = \lambda W\varepsilon + u \Rightarrow\ \varepsilon = (I - \lambda W)^{-1}u.$$

Поскольку ковариационная матрица ошибок регрессии в случае их пространственной зависимости не пропорциональна единичной, а именно, $var[\varepsilon] = \sigma_u^2(I - \lambda W)^{-1}(I - \lambda W')^{-1}$, то оценки параметров β методом наименьших квадратов будут несмещенными, но их стандартные ошибки (а следовательно, и t-статистики для проверки значимости) будут вычислены неверно.

Способы оценки моделей SEM

$$Y = X\beta + \varepsilon, \varepsilon = \lambda W\varepsilon + u,$$

Существует 2 основных способа оценки моделей SEM:

1) Maximum Likelihood (ML)
2) Feasible GLS (FGLS)

Оценки моделей SEM с помощью ML

$$Y = X\beta + \varepsilon,\ \mathrm{u} \sim \mathrm{N}(0, \sigma_u^2 \mathrm{I})$$

$$\varepsilon = \lambda W\varepsilon + u \ \Rightarrow \varepsilon = (I - \lambda W)^{-1}u,$$

$$Y = X\beta + (I - \lambda W)^{-1}u,$$

$$\mathrm{E}(Y) = \mathrm{E}(X\beta + (I - \lambda W)^{-1}u) = X\beta,$$

$$var(Y) = E(Y - E(Y))(Y - E(Y))^T = var((I - \lambda W)^{-1}u) =$$

$$= (I - \lambda W)^{-1}\mathrm{var}(u)\,[(I - \lambda W)^{-1}]^T = \sigma_u^2\Omega,$$

где $\Omega = (I - \lambda W)^{-1}[(I - \lambda W)^{-1}]^T$

Оценки моделей SEM с помощью ML

$$Y = X\beta + \varepsilon,\ \varepsilon = (I - \lambda W)^{-1}u,\ u \sim N(0, \sigma_u^2 I)$$

Функция правдоподобия:

$$\mathrm{L}(\beta, \lambda, \sigma_u^2) =$$

$$= (2\pi)^{-n/2}\ (\sigma_u^2)^{\ -n/2} |\Omega|^{-1/2}\ exp\left\{-\frac{1}{2\sigma_u^2}(Y - X\beta)^T\ \Omega^{-1}\ (Y - X\beta)\right\},$$

$$|\Omega| = \det\{(I - \lambda W)^{-1}[(I - \lambda W)^{-1}]^T\} =$$

$$\det\{(I - \lambda W)^{-1}\}\det\{[(I - \lambda W)^{-1}]^T\} =$$

$$= \det\{(I - \lambda W)\}^{-2}$$

Оценки моделей SEM с помощью ML

$$L(\beta, \lambda, \sigma_u^2) =$$

$$= (2\pi)^{-n/2} (\sigma_u^2)^{-n/2} |\Omega|^{-1/2} \exp\left\{-\frac{1}{2\sigma_u^2}(Y - X\beta)^T \Omega^{-1} (Y - X\beta)\right\},$$

Логарифмическая функция правдоподобия:

$$l(\beta, \lambda, \sigma_u^2) = \ln(L(\beta, \lambda, \sigma_u^2)) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma_u^2) + \ln|I - \lambda W| -$$

$$-\frac{1}{2\sigma_u^2}(Y - X\beta)^T [(I - \lambda W)^{-1}(I - \lambda W^T)^{-1}]^{-1} (Y - X\beta) =$$

$$= \ln(L(\beta, \lambda, \sigma_u^2)) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma_u^2) + \ln|I - \lambda W| -$$

$$-\frac{1}{2\sigma_u^2}(Y - X\beta)^T [(I - \lambda W^T)(I - \lambda W)](Y - X\beta)$$

Максимум этой функции может быть найден только численно.

Оценки моделей SEM с помощью ML

Проблема при максимизации функции правдоподобия при больших n: вычисление $\ln|I - \lambda W|$ на каждом шаге максимизации.

Обычно по предложению Орда (Ord, 1975) это делают следующим образом:

$\ln|I - \lambda W| = \ln[\prod_{i=1}^{n}(1 - \lambda v_i)] = \sum_{i=1}^{n} \ln(1 - \lambda v_i)$, где v_i - собственные числа матрицы W.

Однако вычислительные проблемы при больших все равно остаются.

Оценки моделей SEM с помощью ML

Concentrated ML –еще один способ получить оценки ML

Из $\frac{\partial l(\beta, \lambda, \sigma_u^2)}{\partial \beta} = 0$ получаем:

$\hat{\beta}(\lambda) = (X^T \Omega^{-1}(\lambda) X)^{-1} X^T \Omega^{-1}(\lambda) Y$,

из $\frac{\partial l(\beta, \lambda, \sigma_u^2)}{\partial \sigma_u^2} = 0$ получаем:

$\hat{\sigma}_u^2(\lambda) = \frac{1}{n}(e^T \Omega^{-1}(\lambda) e)$, где e – вектор остатков регрессии.

Подставляя $\hat{\beta}(\lambda)$ и $\hat{\sigma}_u^2$ в $l(\beta, \lambda, \sigma_u^2)$, получаем

$l_c(Y|\lambda) = \text{const} + \sum_{i=1}^{n} \ln(1 - \lambda v_i) - \frac{n}{2} \ln\left(\frac{1}{n}(e^T \Omega^{-1}(\lambda) e)\right)$ – это функция одной переменной.

Одного шага оптимизации недостаточно, используется итерационная процедура.

Оценки моделей SEM с помощью ML

Итерационная процедура для получения оценок concentrated ML

1) Регрессия Y на X.

2) Вычисление начального вектора остатков регрессии $e = Y - X\beta$.

3) Подстановка этих остатков в $l_c(Y|\lambda) = \text{const} + \sum_{i=1}^{n} \ln(1 - \lambda v_i) - \frac{n}{2}\ln\left(\frac{1}{n}\left(e^T \Omega^{-1}(\lambda)e\right)\right)$ и нахождение λ, при котором эта функция достигает максимума.

Оценки моделей SEM с помощью ML

4) Подстановка этого λ в и вычисление новых остатков регрессии.

5) Возвращение на шаг 3, если не достигли сходимости. $\hat{\beta}(\lambda)$

6) После того, как функция $l_c(Y|\ \lambda)$ будет отличаться от предыдущей не более заданного уровня точности (т.е. сходимость будет достигнута), фиксируются значения λ и соответствующего $\hat{\beta}(\lambda)$. И находится оценка $\hat{\sigma}_u^2(\lambda)$ при этом λ.

Оценки моделей SEM с помощью FGLS

1) Регрессия Y на X.
2) Вычисление начального вектора остатков регрессии $e = Y - X\beta$.
3) Оценка параметра λ для модели $e = \lambda We + u$.
4) Оценка с помощью МНК невозможна, поскольку λWe и u коррелируют. Поэтому для нахождения оценки λ используется обобщенный метод моментов с моментными тождествами, которые предложили Kelejian H. и Prucha I. (1999).

Оценки моделей SEM с помощью FGLS

5) С помощью найденной оценки параметра $\hat{\lambda}$ производится преобразование переменных (аналогичное преобразованию Кокрена-Оркутта для случая автокорреляции остатков временных рядов):

$Y^* = (I - \hat{\lambda}W)Y$, $X^* = (I - \hat{\lambda}W)X$

$Y = X\beta + (I - \lambda W)^{-1}u$,

откуда $(I - \hat{\lambda}W)\,Y = (I - \hat{\lambda}W)X\beta + u$,

$Y^* = X^*\beta + u$

Оценки моделей SEM с помощью FGLS

$$Y^* = X^* \beta + \mathrm{u}$$

$$\hat{\beta} = (X^{*T} X^*)^{-1} X^{*T} Y^*,$$

$$\hat{\beta}_{FGLS} = (X^T \hat{\Omega}^{-1} X)^{-1} X^T \hat{\Omega}^{-1} Y$$

Пример

Y – Кражи со взломом жилых помещений и кражи транспортных средств,

X1 – Стоимость жилья,

X2 – доход домохозяйства.

Оценивается модель SEM.

Пример

The ML estimation of the SEM is:

```
Coefficients: (asymptotic standard errors)
             Estimate Std. Error z value  Pr(>|z|)
(Intercept) 61.053619   5.314875 11.4873 < 2.2e-16
HOVAL       -0.307979   0.092584 -3.3265 0.0008794
INC         -0.995473   0.337025 -2.9537 0.0031398
Rho: 0.52089, LR test value: 6.4441, p-value: 0.011132
Asymptotic standard error: 0.14129
    z-value: 3.6868, p-value: 0.00022713
Wald statistic: 13.592, p-value: 0.00022713
Log likelihood: -184.1552 for error model
ML residual variance (sigma squared): 99.98, (sigma: 9.999)
Number of observations: 49
Number of parameters estimated: 5
```

Пример

The Feasible GLS estimation of the SEM is:

```
Type: GM SAR estimator
Coefficients: (GM standard errors)
             Estimate Std. Error z value  Pr(>|z|)
(Intercept) 63.487150   5.083612 12.4886 < 2.2e-16
HOVAL       -0.300365   0.096799 -3.1030 0.0019160
INC         -1.180414   0.341788 -3.4536 0.0005531

Rho: 0.3643 (standard error): 0.4318 (z-value): 0.84366
Residual variance (sigma squared): 109.37, (sigma: 10.458)
GM argmin sigma squared: 108.93
Number of observations: 49
Number of parameters estimated: 5
```

Модель с пространственной зависимостью в ошибках

$$Y = X\beta + \varepsilon, \varepsilon = \lambda W\varepsilon + u$$

Оценки коэффициентов β в модели с пространственной зависимостью в ошибках интерпретируются традиционным для линейных моделей образом: если коэффициент β_j при переменной X_j значим, то при увеличении X_j на одну единицу, зависимая переменная изменится $\hat{\beta}_j$ единиц.

Модель с пространственной зависимостью в ошибках

Для интерпретации коэффициента пространственной корреляции λ ошибок регрессии удобно использовать следующее представление ошибок регрессии:

$$\varepsilon = (I - \lambda W)^{-1} u = (I + \lambda W + \lambda^2 W^2 + \cdots) u$$
$$= u + \lambda W u + \lambda^2 W^2 u + \cdots,$$

где

$$\varepsilon = (\varepsilon_1, \ldots, \varepsilon_n)', \qquad u = (u_1, \ldots, u_n)',$$

$Wu = \big((Wu)_1, \ldots, (Wu)_n\big)', (Wu)_i = \sum_{j=1}^{n} w_{ij} u_j$ и т.д.

Модель с пространственной зависимостью в ошибках

$$\varepsilon = (I - \lambda W)^{-1}u = u + \lambda Wu + \lambda^2 W^2 u + \cdots,$$

В этом разложении u_i характеризует шоки рассматриваемого i-го региона, $(Wu)_i$ – средние шоки соседних с i-м регионов, $(W^2u)_i$ – шоки в соседних с соседними регионами и т.д. Чем меньше $|\lambda|$, тем быстрее затухает влияние шоков в соседних регионах.

Модель пространственной автокорреляции

Если в число объясняющих переменных включается пространственный лаг зависимой переменной WY, то соответствующая модель

$$Y = X\beta + \rho WY + \varepsilon$$

называется моделью пространственной авторегрессии (SAR, spatial autoregressive model), ρ — коэффициент пространственной автокорреляции.

Модель пространственной автокорреляции

ρ — коэффициент пространственной автокорреляции.

Если этот коэффициент незначим, то взаимное влияние регионов отсутствует, если положительный и значимый, то изменения в выбранном регионе и соседних регионах имеют одинаковую направленность, а если он отрицательный и значимый, то противоположную направленность.

Модель пространственной автокорреляции

$$Y = X\beta + \rho WY + \varepsilon$$

Поскольку WY и ε коррелируют, то существует проблема эндогенности, оценки коэффициентов с помощью МНК не будут состоятельными.

Существует 2 основных способа оценки моделей SEM:

1) Maximum Likelihood (ML)
2) Two-stage Least Squares (2SLS)

Оценки моделей SAR с помощью ML

$Y = X\beta + \rho WY + \varepsilon \Rightarrow (I - \rho W)Y = X\beta + \varepsilon \Rightarrow$

$Y = (I - \rho W)^{-1}(X\beta + \varepsilon)$

Обычно предположение $\varepsilon \sim N(0, \sigma_\varepsilon^2 I)$, тогда

$Y \sim N((I - \rho W)^{-1}X\beta, \sigma_\varepsilon^2 \Omega)$,

где $\Omega = (I - \rho W)^{-1}[(I - \rho W)^{-1}]^T$

Оценки моделей SAR с помощью ML

$$Y \sim N((I-\rho W)^{-1}X\beta, \sigma_\varepsilon^2\Omega),\ \Omega = (I-\rho W)^{-1}[(I-\rho W)^{-1}]^T$$

Функция правдоподобия

$$L(\beta,\rho,\sigma_\varepsilon^2) = (2\pi)^{-n/2}(\sigma_\varepsilon^2)^{-n/2}|\Omega|^{-1/2} \cdot$$

$$\cdot \exp\left\{-\frac{1}{2\sigma_\varepsilon^2}(Y-(I-\rho W)^{-1}X\beta)^T\,\Omega^{-1}\,(Y-(I-\rho W)^{-1}X\beta)\right\}$$

$$|\Omega| = \det\{(I-\rho W)^{-1}[(I-\rho W)^{-1}]^T\} =$$

$$\det\{(I-\rho W)^{-1}\}\det\{[(I-\rho W)^{-1}]^T\} =$$

$$= \det\{(I-\rho W)\}^{-2}$$

Оценки моделей SAR с помощью ML

Функция правдоподобия $\Omega = (I - \rho W)^{-1}[(I - \rho W)^{-1}]^{T}$

$$L(\beta,\rho,\sigma_\varepsilon^2) = (2\pi)^{-n/2}(\sigma_\varepsilon^2)^{-n/2}|\Omega|^{-1/2} \cdot$$

$$\cdot \exp\left\{-\frac{1}{2\sigma_\varepsilon^2}(Y - (I - \rho W)^{-1}X\beta)^{T}\,\Omega^{-1}\,(Y - (I - \rho W)^{-1}X\beta)\right\}$$

Логарифмическая функция правдоподобия:

$$l(\beta,\rho,\sigma_\varepsilon^2) = \ln(L(\beta,\rho,\sigma_\varepsilon^2)) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma_\varepsilon^2) + \ln|I - \rho W| -$$

$$-\frac{1}{2\sigma_\varepsilon^2}(Y - (I - \rho W)^{-1}X\beta)^{T}(I - \rho W^{T})(I - \rho W)(Y - (I - \rho W)^{-1}X\beta)$$

Максимум этой функции может быть найден только численно.

И опять проблемы с вычислением $\ln|I - \rho W|$ при больших n.

Оценки моделей SAR с помощью ML

Concentrated ML –еще один способ получить оценки ML

Из $\frac{\partial l(\beta,\rho,\sigma_\varepsilon^2)}{\partial \beta} = 0$ получаем:

$$\hat{\beta}(\rho) = (X^T X)^{-1} X^T (I - \rho W)Y =$$

$$= (X^T X)^{-1} X^T Y - \rho (X^T X)^{-1} X^T WY = b_0 - \rho b_L,$$

где $b_0 = (X^T X)^{-1} X^T Y$,

$b_L = (X^T X)^{-1} X^T WY$

Оценки моделей SAR с помощью ML

Из $\frac{\partial l(\beta,\rho,\sigma_\varepsilon^2)}{\partial \sigma_\varepsilon^2} = 0$ получаем:

$$\hat{\sigma}_\varepsilon^2 = \frac{1}{n}[Y - \rho WY - X\hat{\beta}(\rho)]^T [Y - \rho WY - X\hat{\beta}(\rho)] =$$

$$= \frac{1}{n} Y^T (I - \rho W)^T N (I - \rho W) Y = \frac{1}{n}(e_0 - \rho e_L)^T (e_0 - \rho e_L),$$ где

$N = I - X(X^T X)^{-1} X^T$,

$e_0 = Y - X b_0$,

$e_L = WY - X b_L$

Оценки моделей SAR с помощью ML

Подставляя $\hat{\beta}(\rho)$ и $\hat{\sigma}_\varepsilon^2$ в $l(\beta,\rho,\sigma_\varepsilon^2)$, получаем

$$l_c(Y|\rho) = \text{const} + \ln|I - \rho W| - \frac{n}{2}\ln\left(\frac{1}{n}(e_0 - \rho e_L)^T(e_0 - \rho e_L)\right) =$$

$$= \text{const} + \sum_{i=1}^{n}\ln(1 - \rho v_i) - \frac{n}{2}\ln\left(\frac{1}{n}(e_0 - \rho e_L)^T(e_0 - \rho e_L)\right),$$

где v_i - собственные числа матрицы W.

Эту функцию необходимо максимизировать по ρ. При этом на ρ действует ограничение: $v_{max}^{-1} < \rho < v_{min}^{-1}$

Оценки моделей SAR с помощью ML

Алгоритм нахождения оценки максимального правдоподобия параметра ρ.

1) Оцениваем регрессию Y на X и получаем остатки e_0.
2) Оцениваем регрессию WY на X и получаем остатки e_L.
3) Подставляем эти остатки в $l_c(\mathrm{Y}|\rho)$ и максимизируем функцию

$$l_c(\mathrm{Y}|\rho) = \text{const} + \sum_{i=1}^{n} \ln(1 - \rho v_i) - \frac{\mathrm{n}}{2} \ln\left(\frac{1}{n}(e_0 - \rho e_L)^T (e_0 - \rho e_L)\right)$$

по ρ, находим $\hat{\rho}$.

4) Подставляем $\hat{\rho}$ в формулы для $\hat{\beta}(\rho)$ и $\hat{\sigma}_\varepsilon^2$.

Оценки моделей SAR с помощью 2SLS

$$Y = X\beta + \rho WY + \varepsilon$$

WY и ε коррелируют, поэтому для WY требуются инструменты.

Заметим, что $(I - \rho W)^{-1} = I + \rho W + \rho^2 W^2 + \rho^3 W^3 + \ldots$, если $|\rho| < 1$.

$E(WY) = W(I + \rho W + \rho^2 W^2 + \rho^3 W^3 + \ldots)X\beta =$

$= W X\beta + \rho W^2 X\beta + \rho^2 W^3 X\beta + \ldots$

Поэтому в качестве инструментов для WY могут служить X, W X, W^2 X (Kelejian, Prucha, 1998).

Оценки моделей SAR с помощью 2SLS

$$Y = X\beta + \rho WY + \varepsilon$$

2SLS

1-ый шаг: строим регрессию WY на X, W X, W^2 X, получаем $\widehat{WY}$.

2-ой шаг: оцениваем регрессию

$$Y = X\beta + \rho\widehat{WY} + \varepsilon$$

И находим оценки параметров β и ρ.

Пример

Y – Кражи со взломом жилых помещений и кражи транспортных средств,

X1 – Стоимость жилья,

X2 – доход домохозяйства.

Оценивается модель SAR.

Пример

The ML estimation of the SLM is:

```
Coefficients: (asymptotic standard errors)
             Estimate Std. Error z value  Pr(>|z|)
(Intercept) 46.851431   7.314754  6.4051 1.503e-10
INC         -1.073533   0.310872 -3.4533 0.0005538
HOVAL       -0.269997   0.090128 -2.9957 0.0027381
Lambda: 0.40389, LR test value: 8.4179, p-value: 0.0037154
Asymptotic standard error: 0.12071
    z-value: 3.3459, p-value: 0.00082027
Wald statistic: 11.195, p-value: 0.00082027
Log likelihood: -183.1683 for lag model
ML residual variance (sigma squared): 99.164, (sigma: 9.9581)
Number of observations: 49
Number of parameters estimated: 5
AIC: 376.34, (AIC for lm: 382.75)
```

Пример

The 2SLS of the SLM (Spatial Two Stage Least Squares) is:

```
Coefficients:
             Estimate Std. Error t value  Pr(>|t|)
Lambda       0.454638   0.191446  2.3748  0.017561
(Intercept) 44.116386  11.171790  3.9489 7.851e-05
INC         -1.007722   0.391139 -2.5764  0.009984
HOVAL       -0.269503   0.093368 -2.8865  0.003896

Residual variance (sigma squared): 106.99, (sigma: 10.344)
```

Пространственная модель Дарбина (SDM)

$$Y = \rho WY + X\beta + WX\theta + \varepsilon$$

Модель Дарбина включает пространственные лаги как зависимой переменной WY, так и объясняющих переменных WX.

Эта модель оценивается аналогично SAR.

Связь SDM и SEM

Модель SEM: $Y = X\beta + \varepsilon, \varepsilon = \rho W\varepsilon + u$

$Y = X\beta + \varepsilon, \varepsilon = \rho W\varepsilon + u \Rightarrow \ \varepsilon = (I - \rho W)^{-1}u$

$(I - \rho W)Y = (I - \rho W)\, X\beta + u,$

$Y = \rho W Y + X\beta - WX\rho\beta + u.$

Если $\theta = -\rho\beta$, то модель SDM сводится к модели SEM.

Выбор между моделями

Два основных подхода:

- От простой модели к сложной (Anselin et al., 1996)
- От общей модели к упрощенной(Elhorst (2014), LeSage, Pace (2009), Kelejian, Prucha (2010))

От простой модели к сложной

Подход (Anselin et al., 1996) состоит в оценке линейной модели $Y = X\beta + \varepsilon$, сохранении остатков этой регрессии $e' = (e_1, \dots, e_n)$ и проверке гипотез

1) H_0: $Y = X\beta + \varepsilon$, $\varepsilon = \lambda W\varepsilon + u, \lambda = 0$, т.е. пространственная зависимость в ошибках регрессии отсутствует,

H_1: $Y = X\beta + \varepsilon$, $\varepsilon = \lambda W\varepsilon + u, \lambda \neq 0$, т.е. это модель SEM,

с помощью теста Лагранжа и тестовой статистики (Fischer, Wang, 2010, p.36):

$$LM(error) = \left(\frac{e\prime We}{e\prime en^{-1}}\right)^2 \frac{1}{tr[W'W+W^2]} \underset{\sim}{H_0} \chi^2(1),$$

2) H_0: $Y = X\beta + \varepsilon$, $\rho = 0$, т.е. пространственный лаг зависимой переменной отсутствует,

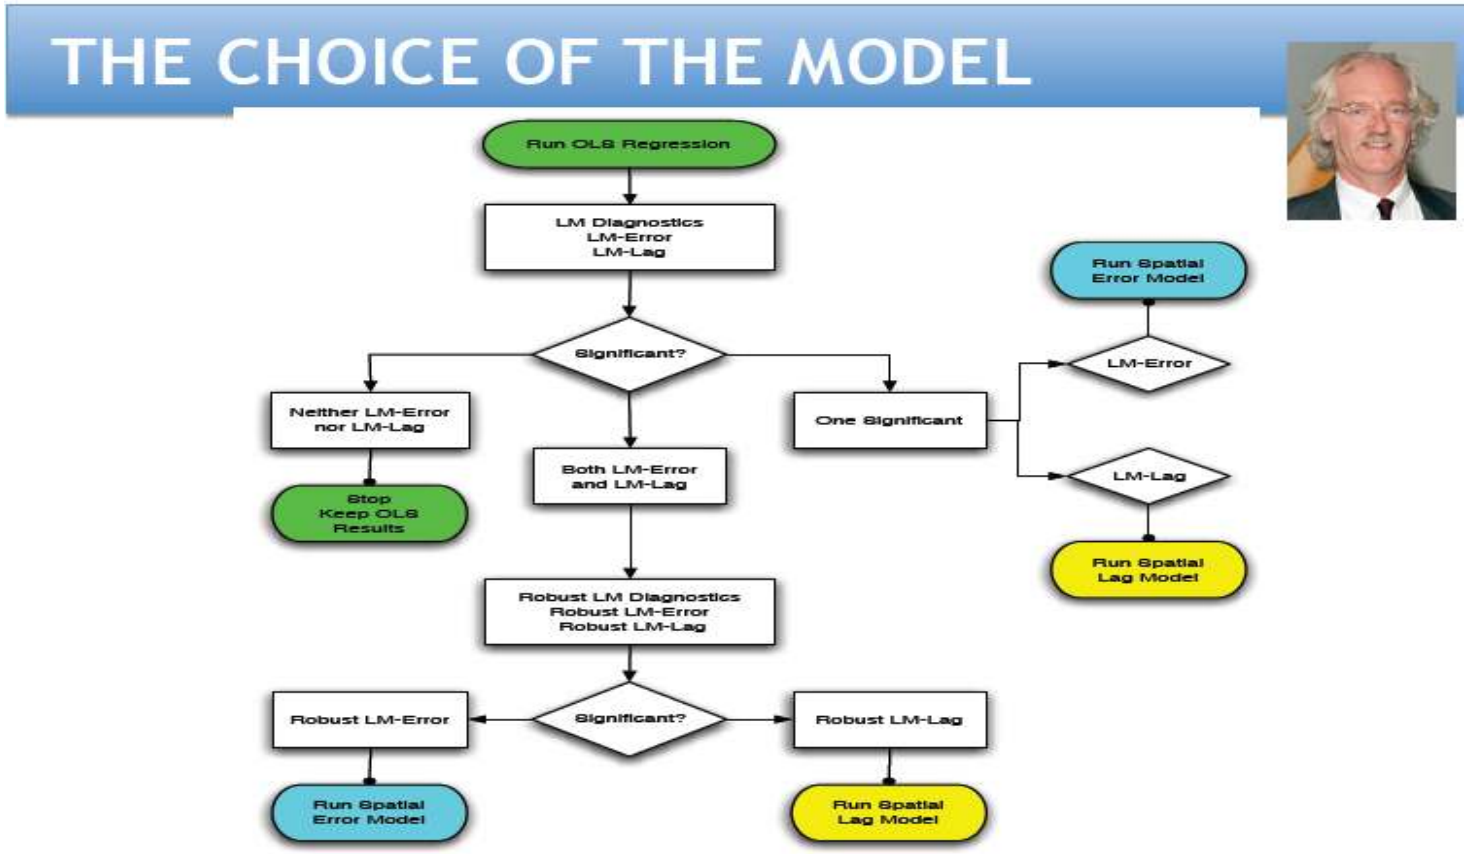
H_1: $Y = \rho WY + X\beta + \varepsilon$, $\rho \neq 0$, т.е. это модель SAR,

с помощью теста Лагранжа и тестовой статистики

$$LM(lag) = \left(\frac{e\prime WY}{e\prime en^{-1}}\right)^2 \frac{1}{H} \underset{\sim}{H_0} \chi^2(1),$$

$$\text{H} = \{(\text{WX}\hat{\beta})'\left[I - X(X'X)^{-1}X'\right]\left(WX\hat{\beta}\right)\hat{\sigma}_{\varepsilon}^{-2}\} + tr(W'W + W^2).$$

От простой модели к сложной



От общей модели к упрощенной

Если и в случае (1), и в случае (2) лучшей оказывается модель SEM или SAR, то выполняются робастные тесты (Anselin, 1996)

For this reason Anselin *et al.* (1996) proposed a robust version of both tests which can be expressed as:

$$RLM_{SEM} = \frac{1}{T(1-TQ)^{-1}}\left[\frac{ne^T We}{e^T e} - TQ^{-1}\frac{ne^T Wy}{e^T e}\right]^2 \sim \chi^2_{(1)}$$

$$RLM_{LAG} = \frac{1}{Q-T}\left[\frac{ne^T Wy}{e^T e} - \frac{ne^T We}{e^T e}\right]^2 \sim \chi^2_{(1)}$$

$$Q = \left(WX\hat{\beta}\right)^T (I - M_x)\frac{WX\hat{\beta}}{\hat{\sigma}^2_\varepsilon} + T \qquad T = tr\left(W^T W + WW\right) \qquad M_x = X\left(X^T X\right)X^T$$

От общей модели к упрощенной

При втором подходе (Elhorst (2014), LeSage, Pace (2009), Kelejian, Prucha (2010)) вначале оценивается наиболее общая модель (GNS – general nesting spatial model):

$$Y = X\beta + \rho WY + WX\theta + u, \varepsilon = \lambda W\varepsilon + u,$$

а потом с помощью теста Лагранжа или Вальда проверяются гипотезы:

От общей модели к упрощенной

1) При $H_0: \lambda = 0$ (тогда модель сводится к SDM),

2) $H_0: \rho = 0, \lambda = 0$ (тогда модель сводится к SLX),

3) $H_0: \theta = 0, \lambda = 0$ (тогда модель сводится к SAR),

4) $H_0: \rho = 0, \theta = 0, \lambda = 0$ (тогда модель сводится к линейной регрессионной модели),

5) $H_0: \theta + \rho\beta = 0$ (тогда модель сводится к SEM).

От общей модели к упрощенной

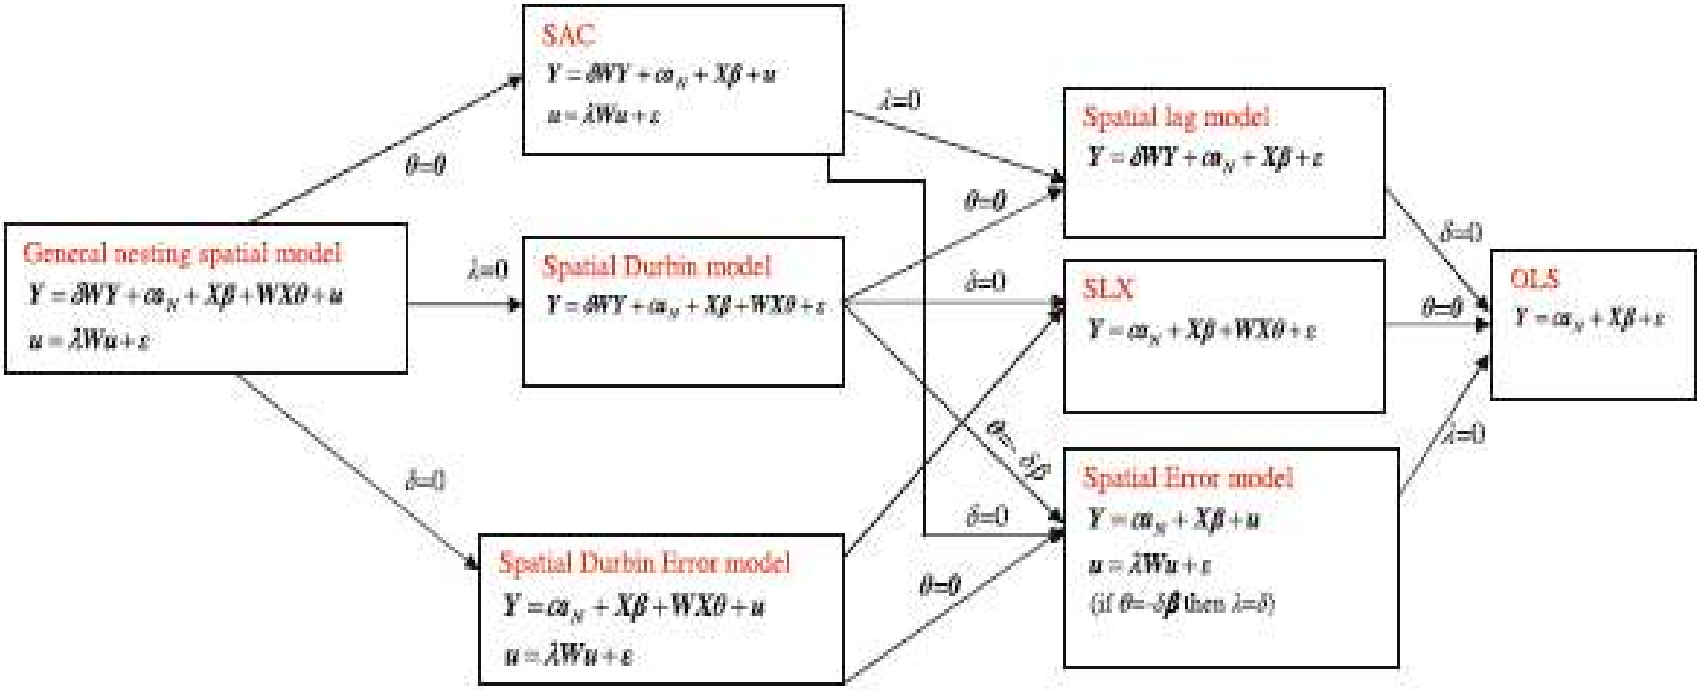


Fig. 2.1 The relationships between different spatial dependence models for cross-section data (*source* Halleck Vega and Elhorst 2012)



Спасибо за внимание!